



UNIVERSITY OF CAGLIARI

Department of Engineering

MASTER'S DEGREE IN "COMPUTER ENGINEERING,
CYBERSECURITY AND ARTIFICIAL INTELLIGENCE"

**Experimental Evaluation of the Robustness of
AI-Based Forensic Tools for Automated Image
Classification Under Adversarial and
Anti-Forensic Attacks**

Advisor:

Prof. Davide Maiorca

Co-Advisor:

PhD Silvia Lucia Sanna

Author:

Lello Molinaro

Academic Year 2025/2026
Cagliari

Table of Contents

List of Figures	iv
List of Tables	vi
1 Introduzione	1
1.1 Digitalizzazione, minacce e centralità della Digital Forensics	1
1.2 Automazione dell'analisi forense e ruolo dell'AI	2
1.3 Robustezza dei sistemi basati su AI e minacce avversariali e anti-forensi	2
1.4 Problema di ricerca e rilevanza in scenari forensi realistici	3
1.5 Obiettivi della ricerca	4
1.6 Contributo della tesi	4
1.7 Rilevanza tecnico-forense e profili di affidabilità probatoria	5
1.8 Struttura della tesi	6
2 Technical Background Concepts	8
2.1 Introduzione alla Computer Law	8
2.2 La prova digitale e i requisiti di ammissibilità	9
2.3 Normativa e giurisprudenza di riferimento	9
2.3.1 Italia	9
2.3.2 Europa	10
2.3.3 Standard internazionali	10
2.4 Decisioni algoritmiche e implicazioni giuridiche	10
2.5 Introduzione alla Digital Forensics	11
2.6 Tecniche di acquisizione e analisi forense	13
2.7 Aspetti legali della Digital Forensics	15
2.8 AI nella Digital Forensics	20
2.8.1 Evoluzione e motivazioni dell'uso dell'AI nella Digital Forensics	21
2.8.2 Strumenti AI-based in ambito forense	21
2.9 Attacchi avversariali nei sistemi di Machine Learning	23
2.9.1 Modello di minaccia negli attacchi avversariali	23
2.9.2 Tipologie di attacchi avversariali	24
2.9.3 Adversarial examples nei sistemi di computer vision	25
2.9.4 Implicazioni di sicurezza	25
2.10 Immagini avversariali e tecniche di perturbazione	25
2.10.1 Concetti fondamentali negli attacchi avversariali	25
2.10.2 Applicazioni forensi	29
2.11 Robustezza dei Sistemi AI-based	30
2.11.1 Contromisure e difese	30
2.12 Criticità probatorie nell'uso di AI nella Digital Forensics	31
2.13 Conclusioni critiche	31
A Repository and Reproducibility Artifacts	33
A.1 Struttura della repository	33
A.2 Artefatti sperimentali principali	34

A.3	Ambiente software e librerie utilizzate	34
A.4	Manifest, hash e tracciabilità	35
A.5	Comandi principali per la riproducibilità	35
A.6	Esempi di log e output	35
A.7	Repository e disponibilità del codice	36
References		37

List of Figures

2.1	Pipeline forense secondo le linee guida NIST SP 800-86 e ACPO: fasi operative principali dalla raccolta dell'evidenza alla presentazione in giudizio.	12
2.2	Timeline di adozione dei principali standard e modelli forensi.	13
2.3	Fasi della catena di custodia nell'ambito della digital forensics.Fonte: [39].	18
2.4	Catena di custodia	19
2.5	Principali tool AI-based in digital forensics e tipologie di task supportati.	22
2.6	Fasi generali di un attacco adversarial: dal calcolo o stima del gradiente, alla generazione e applicazione della perturbazione, fino all'analisi della predizione.	27
2.7	Classificazione degli attacchi adversariali in base alla conoscenza del modello (white-box vs black-box) e all'obiettivo (targeted vs untargeted).	28
A.1	QR code per l'accesso diretto alla repository GitHub della tesi.	34

List of Tables

2.1	Flusso tipico di acquisizione e gestione di un'evidenza digitale in scenari cross-border.	17
2.2	Confronto tra principali normative internazionali rilevanti per la digital forensics.	17
2.3	Confronto tra principali standard e linee guida operative in ambito digital forensics.	20
2.4	Confronto tra principali strumenti forensi AI-based: tecnologie impiegate, funzionalità e contesto operativo.	22
2.5	Confronto tra tecniche di perturbazione anti-forense e adversarial: meccanismo, obiettivo, visibilità.	29
2.6	Confronto tra principali tecniche di difesa contro input adversariali.	31
A.1	Principali artefatti sperimentali della pipeline.	34
A.2	Principali librerie e strumenti software utilizzati nella pipeline sperimentale.	35

Chapter 1

Introduzione

1.1 Digitalizzazione, minacce e centralità della Digital Forensics (DF)

La progressiva digitalizzazione della società contemporanea ha trasformato in profondità le modalità con cui le informazioni vengono prodotte, archiviate, trasmesse e analizzate. Infrastrutture cloud, servizi distribuiti, dispositivi mobili interconnessi, piattaforme sociali e sistemi informativi eterogenei generano oggi una quantità crescente di dati digitali, che assumono un ruolo sempre più rilevante sia nella vita quotidiana sia nelle attività professionali, istituzionali e giudiziarie. Tale evoluzione ha ampliato in modo significativo anche la superficie d'attacco dei sistemi informatici, aumentando le opportunità di sfruttamento da parte di soggetti ostili e moltiplicando i possibili punti di compromissione delle evidenze digitali [1, 2].

Parallelamente alle opportunità offerte dall'innovazione tecnologica, si sono affermate minacce sempre più sofisticate, caratterizzate da elevata eterogeneità tecnica e da una crescente capacità di occultamento. Tra queste rientrano l'esfiltrazione e la manipolazione dei dati, l'alterazione di file multimediali, la cancellazione selettiva delle tracce, l'impiego di tecniche di anonimizzazione e, più in generale, tutte quelle pratiche che mirano a ostacolare la ricostruzione attendibile degli eventi. In un simile scenario, la DF assume un ruolo centrale quale disciplina deputata all'identificazione, acquisizione, preservazione, analisi e presentazione dell'evidenza digitale secondo criteri di rigore metodologico, integrità e verificabilità [3, 4, 5, 6].

Secondo la definizione comunemente richiamata in letteratura, la DF costituisce l'applicazione di metodi scientifici e procedure tecniche finalizzate a rendere i dati digitali utilizzabili come elementi di prova in un contesto investigativo o giudiziario [3]. Tale impostazione richiede che ogni fase del processo sia condotta in modo tracciabile, ripetibile e difendibile, affinché il risultato dell'analisi non sia soltanto tecnicamente corretto, ma anche sostenibile sotto il profilo probatorio. In termini operativi, il processo forense viene comunemente ricondotto a una sequenza di fasi che comprende identificazione, acquisizione, conservazione, analisi e presentazione dell'evidenza, tutte accomunate dall'esigenza di garantire integrità, trasparenza e verificabilità [4, 5]. Questa esigenza diventa particolarmente rilevante nei casi in cui le evidenze risultino distribuite su molteplici dispositivi, conservate in ambienti virtualizzati, presenti in forma volatile oppure esposte a manipolazioni intenzionali [5, 6].

La crescente incidenza dei reati informatici e, più in generale, il ruolo ormai pervasivo delle tecnologie digitali nella commissione e nella documentazione dei reati hanno consolidato la funzione della DF come snodo essenziale tra competenza tecnica e accertamento dei fatti. In questo quadro, la qualità delle procedure di analisi e l'affidabilità degli strumenti impiegati incidono direttamente sulla possibilità di ricostruire correttamente gli eventi, individuare i responsabili e preservare il valore dell'evidenza nel procedimento giudiziario [7, 8].

1.2 Automazione dell'analisi forense e ruolo dell'Artificial Intelligence (AI)

L'espansione quantitativa e qualitativa dei dati oggetto di indagine ha reso progressivamente meno sostenibile un approccio esclusivamente manuale all'analisi forense. Le metodologie tradizionali, pur mantenendo un ruolo fondamentale in termini di controllo tecnico e validazione dell'evidenza, risultano spesso difficilmente scalabili quando l'investigatore deve esaminare grandi volumi di immagini, video, log, conversazioni, file di sistema e artefatti eterogenei provenienti da fonti differenti. In tali condizioni, l'automazione rappresenta una necessità operativa prima ancora che una scelta di efficienza [1, 7].

In questo contesto, l'integrazione di tecniche di AI negli strumenti di DF ha introdotto nuove possibilità di supporto all'analisi investigativa. In particolare, i metodi di Machine Learning (ML) e Deep Learning (DL) consentono di automatizzare attività quali la classificazione semantica di immagini e video, il riconoscimento di pattern ricorrenti, il raggruppamento di evidenze simili, l'analisi di log e l'individuazione di contenuti potenzialmente rilevanti ai fini dell'indagine. La letteratura sottolinea come tali strumenti possano contribuire a ridurre il carico cognitivo dell'analista, ad accelerare le attività di triage e, in alcuni contesti, anche a limitare l'esposizione prolungata a contenuti sensibili o traumatici, rendendo più gestibile l'esame di dataset molto ampi [7, 9, 10].

L'applicazione dell'AI alla DF non si limita tuttavia a una mera accelerazione dei processi esistenti. Essa introduce un cambiamento qualitativo nel modo in cui l'informazione investigativa viene filtrata, ordinata e prioritizzata. Sistemi basati su AI integrati in strumenti forensi commerciali possono suggerire categorie semantiche, supportare il clustering automatico di contenuti multimediali, evidenziare anomalie e proporre correlazioni che orientano l'attenzione dell'operatore verso specifici elementi dell'evidenza. Tale tendenza è osservabile anche nei principali strumenti professionali impiegati nel settore, nei quali moduli basati su AI vengono progressivamente integrati per supportare attività di classificazione, ordinamento e selezione preliminare delle evidenze [10, 11]. Esempi significativi in questo senso sono rappresentati da piattaforme forensi professionali quali *Magnet Axiom*, *Cellebrite Universal Forensic Extraction Device (UFED)*, *X-Ways Forensics* e *Oxygen Forensics*.

Tuttavia, il vantaggio offerto dall'automazione non può essere valutato esclusivamente in termini di efficienza. In ambito forense, infatti, ogni riduzione del carico umano ottenuta mediante modelli automatici deve essere bilanciata con esigenze di affidabilità, trasparenza e controllo. Un sistema che classifica automaticamente un contenuto come rilevante o irrilevante non si limita a velocizzare il lavoro dell'analista, ma contribuisce a determinare quali evidenze riceveranno attenzione prioritaria e quali, al contrario, rischieranno di essere trascurate. Ne deriva che l'introduzione dell'AI nei workflow forensi richiede una riflessione critica non solo sulle prestazioni dei modelli, ma anche sulla solidità delle loro decisioni in scenari operativi complessi e sulla possibilità di renderne comprensibili i limiti attraverso approcci di Explainable Artificial Intelligence (XAI) [12, 13].

1.3 Robustezza dei sistemi basati su AI e minacce avversariali e anti-forensi

L'impiego di sistemi basati su AI in contesti ad alta criticità ha evidenziato una questione fondamentale: prestazioni elevate in condizioni standard non implicano necessariamente affidabilità in presenza di input alterati, degradati o ostili. Nel caso della DF, tale aspetto assume particolare rilievo, poiché i modelli di classificazione possono essere esposti a contenuti intenzionalmente manipolati, a trasformazioni introdotte lungo la catena di acquisizione oppure a immagini che si discostano in modo significativo dalla distribuzione dei dati utilizzati in fase di sviluppo o addestramento.

La letteratura sull'Adversarial Machine Learning (AML) ha dimostrato che i modelli di ML

e DL possono essere vulnerabili a perturbazioni appositamente progettate per indurre errori di classificazione, anche quando tali alterazioni risultano minime o poco percepibili per un osservatore umano. Questi input manipolati, comunemente indicati come *adversarial examples*, mettono in discussione l'idea che un classificatore ad alte prestazioni sia necessariamente affidabile in scenari reali. La definizione dei *threat model*, la distinzione tra attacchi a conoscenza completa o limitata e la necessità di una valutazione orientata alla sicurezza costituiscono ormai elementi consolidati di questo ambito di ricerca [14, 15, 16, 17].

Nel dominio forense, tale vulnerabilità assume una valenza ulteriore, poiché la manipolazione dell'input può essere finalizzata non soltanto a compromettere una predizione, ma anche a ostacolare deliberatamente l'attività investigativa. È quindi utile distinguere tra due categorie di alterazioni. Da un lato, gli attacchi avversariali mirano a sfruttare le fragilità del modello, ad esempio mediante perturbazioni ottimizzate rispetto alla funzione di perdita o alla *decision boundary* del classificatore. Dall'altro, le trasformazioni anti-forensi agiscono sull'artefatto digitale con l'obiettivo di degradare, alterare o mascherare le tracce informative utili all'analisi, attraverso operazioni quali ricompressione, ridimensionamento, sfocatura, modifiche cromatiche o manipolazioni statistiche dell'immagine. Sebbene queste due famiglie di tecniche abbiano presupposti differenti, entrambe possono incidere sulla stabilità dei sistemi di classificazione automatica e ridurre l'affidabilità del supporto fornito all'analista forense [18, 19, 20].

La nozione di robustezza deve dunque essere intesa, in questa tesi, come capacità del sistema di mantenere comportamenti affidabili non soltanto in presenza di rumore o degradazioni naturali, ma anche sotto perturbazioni intenzionali e strategicamente progettate. In questa prospettiva, un sistema non robusto può modificare la priorità attribuita ai contenuti, ridurre la stabilità delle classificazioni o rendere meno affidabile il triage automatizzato. Per questa ragione, il tema della robustezza non costituisce un problema marginale di ottimizzazione del modello, ma una questione centrale di affidabilità operativa [16, 21].

1.4 Problema di ricerca e rilevanza in scenari forensi realistici

Nonostante l'ampia letteratura sugli attacchi avversariali e sulla robustezza dei modelli di ML, rimane ancora limitata la valutazione di tali criticità in scenari forensi realistici. Molti studi si concentrano su benchmark standardizzati, dataset costruiti per finalità generiche di *computer vision* o condizioni sperimentali lontane dai workflow investigativi effettivi. Questa distanza riduce la trasferibilità dei risultati e rende difficile stimare l'impatto operativo delle vulnerabilità quando i sistemi automatici sono impiegati per supportare l'analisi di contenuti di interesse investigativo, come nel caso della classificazione di immagini raffiguranti armi individuali realistiche [18, 22, 23].

Nel dominio della DF, il problema non consiste soltanto nello stabilire se un classificatore possa essere ingannato, ma nel comprendere in quale misura tale fragilità incida sulla capacità del sistema di supportare decisioni affidabili durante l'analisi dell'evidenza. Ciò implica considerare dataset realistici, contenuti eterogenei, immagini soggette a trasformazioni plausibili, casi borderline e situazioni in cui la distinzione tra contenuto rilevante, irrilevante o ambiguo non è sempre netta. La stessa evoluzione recente della ricerca sui tool forensi guidati da AI mostra che l'integrazione dell'automazione, pur promettente, solleva interrogativi concreti sulla tenuta dei moduli di classificazione quando essi vengono esposti a contenuti manipolati o sintetici [9, 10].

In questo quadro, la vulnerabilità del sistema non ha soltanto una rilevanza teorica, ma produce conseguenze operative immediate. Errori di classificazione indotti da input manipolati possono alterare la priorità attribuita alle evidenze, generare rumore analitico o ridurre la capacità del sistema di segnalare contenuti potenzialmente rilevanti. La robustezza, pertanto, non riguarda soltanto la stabilità del modello rispetto a perturbazioni controllate, ma la qualità complessiva del supporto che esso è in grado di offrire all'interno del workflow forense [21, 24].

Il problema di ricerca affrontato in questa tesi si colloca precisamente in tale intersezione tra robustezza algoritmica e affidabilità operativa. L'obiettivo non è limitarsi a osservare una generica degradazione prestazionale, ma analizzare in modo sistematico come differenti modelli di classificazione automatica e differenti strumenti basati su AI si comportino quando vengono impiegati in uno scenario forense realistico e sottoposti a perturbazioni avversariali e anti-forensi. Questa prospettiva consente di superare una valutazione puramente astratta della sicurezza dei modelli, orientando l'analisi verso le conseguenze concrete che tali vulnerabilità possono produrre sul triage, sulla selezione delle evidenze e, più in generale, sull'intero workflow investigativo.

La rilevanza della ricerca è dunque duplice. Da un lato, essa è scientifica, poiché contribuisce alla definizione di un quadro sperimentale più aderente alle esigenze del dominio forense e alla comprensione dei limiti dei modelli basati su AI in presenza di input ostili. Dall'altro, essa è operativa, poiché fornisce elementi utili per valutare criticamente l'uso di sistemi automatici nei contesti investigativi, promuovendo un approccio che non privilegi la sola accuratezza nominale, ma anche la robustezza, la tracciabilità e la verificabilità del comportamento del modello. In questo senso, la tesi si inserisce in una linea di ricerca che mira a colmare la carenza di benchmark specifici e di protocolli comparativi condivisi per la valutazione dell'AI in DF [9, 10, 21].

1.5 Obiettivi della ricerca

Alla luce delle criticità evidenziate nei paragrafi precedenti, questa tesi si propone di valutare in modo sistematico la robustezza operativa di strumenti e modelli basati su AI impiegati per la classificazione automatica di immagini in ambito forense. L'obiettivo generale è verificare in quale misura tali sistemi mantengano prestazioni affidabili quando vengono esposti a input manipolati, degradati o comunque non pienamente conformi alle condizioni ideali di addestramento e validazione, con particolare attenzione a scenari in cui le perturbazioni possano essere ricondotte a strategie avversariali o anti-forensi [16, 21].

In questa prospettiva, il lavoro si articola attorno a quattro obiettivi principali. Il primo consiste nella costruzione di un quadro sperimentale rigoroso e riproducibile per l'analisi della robustezza di modelli di classificazione di immagini rilevanti ai fini investigativi. Il secondo consiste nel confrontare modelli eterogenei, sia in termini architetturali sia in termini di paradigma di apprendimento, al fine di osservare eventuali differenze di comportamento rispetto alle diverse tipologie di perturbazione. Il terzo obiettivo riguarda la misurazione dell'impatto delle manipolazioni sulla capacità dei sistemi di riconoscere correttamente contenuti di interesse forense, con attenzione sia al degrado prestazionale complessivo sia alle specifiche modalità di errore introdotte. Il quarto obiettivo consiste nel collegare tali evidenze sperimentali a una riflessione più ampia sull'affidabilità dell'automazione nei workflow forensi, evidenziando limiti, rischi operativi e possibili direttrici di miglioramento [7, 9, 24].

L'impostazione adottata non mira quindi soltanto a misurare l'accuratezza di classificatori in un ambiente controllato, ma a comprendere come l'interazione tra modelli, dati e perturbazioni possa incidere concretamente sul supporto che tali strumenti offrono all'analista. In tal senso, l'obiettivo della ricerca non è esclusivamente prestazionale, ma anche metodologico e applicativo: individuare un protocollo di valutazione che consenta di giudicare la robustezza dei sistemi basati su AI non in astratto, bensì in relazione al loro possibile impiego in scenari investigativi realistici.

1.6 Contributo della tesi

Il contributo principale della presente tesi risiede nella definizione e nell'applicazione di un framework di valutazione orientato alla robustezza operativa di sistemi basati su AI per la classificazione automatica di immagini in ambito forense. A differenza di molti studi focalizzati prevalentemente su benchmark standard di *computer vision* o su valutazioni di robustezza in contesti generici, il presente lavoro adotta una prospettiva specificamente calibrata sulle

esigenze della DF, ponendo al centro non solo la capacità di classificazione, ma anche la tenuta del sistema in presenza di input ostili, ambigui o degradati [18, 22, 23].

Un primo contributo consiste nell'integrazione di una pipeline accademica e di una pipeline operativo-forense all'interno di un unico disegno sperimentale. La prima consente di analizzare modelli, dataset, perturbazioni, metriche ed elementi di interpretabilità secondo una logica controllata e comparabile; la seconda permette di estendere la riflessione a strumenti forensi professionali, valutandone criticamente il comportamento in un contesto più vicino alle condizioni applicative reali. Tale integrazione consente di colmare, almeno in parte, la distanza che spesso separa la letteratura sperimentale dalla pratica investigativa effettiva [7, 10, 11].

Un secondo contributo riguarda la costruzione di un dataset frozen, ossia congelato rispetto alle successive fasi sperimentali, nonché la definizione di un protocollo di selezione coerente con il problema investigativo affrontato. Il dataset finale è organizzato in tre classi semanticamente distinte, denominate **weapon**, **non_weapon** e OOD, per un totale di 1500 immagini bilanciate. La classe **weapon** include esclusivamente armi individuali realistiche e chiaramente visibili; la classe **non_weapon** comprende negativi realistici coerenti con il task; la classe OOD raccoglie casi borderline o fuori distribuzione, quali repliche, coltelli, render sintetici, scene di guerra, immagini degradate o contenuti anomali rispetto al dominio di interesse. A partire da tale dataset viene inoltre definito un subset adversarial binario di 1000 immagini, composto dalle sole classi **weapon** e **non_weapon**, destinato alla generazione e alla valutazione delle perturbazioni. La selezione dei campioni segue un paradigma *human-in-the-loop*, nel quale la componente manuale non viene occultata, ma documentata come parte integrante del protocollo metodologico.

Un terzo contributo riguarda la costruzione di un protocollo sperimentale fondato su dati eterogenei, criteri di classificazione coerenti con il problema investigativo affrontato e un insieme di perturbazioni selezionate per rappresentare sia attacchi adversariali sia trasformazioni compatibili con una logica anti-forense. In questo modo, la tesi non si limita a verificare se un modello possa essere indotto in errore, ma analizza anche la natura di tale errore e le sue possibili implicazioni operative [19, 21, 25].

Un quarto contributo consiste nella comparazione tra modelli differenti per architettura, grado di supervisione e logica decisionale, così da evidenziare eventuali profili di maggiore o minore robustezza in relazione alle perturbazioni considerate. Questa impostazione consente di evitare conclusioni eccessivamente dipendenti da un singolo classificatore e rafforza la validità comparativa del lavoro. Infine, la tesi offre un contributo di natura metodologica più ampia, proponendo una lettura della robustezza non soltanto come proprietà tecnica del modello, ma come requisito funzionale per il suo impiego consapevole in DF.

L'analisi empirica è quindi finalizzata a valutare in che misura tali perturbazioni incidano sulla stabilità delle classificazioni, sulla robustezza dei modelli e sulla qualità del supporto offerto dagli strumenti automatici all'interno del workflow forense.

1.7 Rilevanza tecnico-forense e profili di affidabilità probatoria

In ambito forense, la correttezza tecnica di uno strumento non può essere valutata indipendentemente dal contesto in cui esso viene utilizzato e dalle conseguenze che i suoi risultati possono produrre sull'analisi dell'evidenza. L'introduzione di sistemi basati su AI nei workflow investigativi solleva pertanto una questione che è al tempo stesso tecnica e forense: fino a che punto un output automatizzato può essere considerato sufficientemente affidabile da orientare il lavoro dell'analista, senza compromettere la completezza dell'esame o introdurre errori sistematici difficilmente rilevabili [11, 24].

Il problema assume rilievo particolare quando i sistemi automatici operano in modalità sostanzialmente opaca, ovvero quando l'analista dispone del risultato della classificazione ma non di una piena comprensione del processo decisionale che lo ha generato. In tali casi, la fragilità del modello rispetto a input manipolati o inattesi non rappresenta soltanto un limite algoritmico,

ma può riflettersi sulla qualità dell'intero processo investigativo. Un falso negativo può determinare la mancata selezione di un contenuto rilevante; un falso positivo può generare rumore, deviare risorse e appesantire la verifica manuale. In entrambi i casi, la vulnerabilità del sistema incide sulla fiducia operativa riposta nello strumento e sulla possibilità di giustificare in modo rigoroso il ruolo svolto dall'automazione nell'analisi [12, 13].

Da questo punto di vista, la robustezza operativa si collega direttamente all'esigenza di tracciabilità, verificabilità e controllo critico che caratterizza la DF. Un sistema automatico può certamente costituire un supporto efficace per il triage e la prioritizzazione delle evidenze, ma il suo impiego richiede che i risultati siano interpretati alla luce dei limiti del modello, delle condizioni sperimentali in cui è stato valutato e dei possibili margini di errore. La presente tesi si colloca precisamente in questo spazio problematico: non assume l'automazione come intrinsecamente affidabile, ma ne esamina la tenuta empirica per comprendere in quali condizioni essa possa offrire un supporto utile e in quali, invece, richieda particolare cautela.

Sotto il profilo probatorio, tale impostazione non implica che il modello debba essere considerato fonte autonoma di verità tecnica, bensì che il suo eventuale impiego debba essere accompagnato da un'adeguata consapevolezza metodologica. In altri termini, la rilevanza del presente studio risiede anche nel fornire elementi utili a distinguere tra uso meramente strumentale dell'AI e affidamento acritico su decisioni algoritmiche non sufficientemente robuste. Ciò risulta particolarmente importante in un contesto in cui la prova digitale richiede procedure rigorose e in cui l'adozione di strumenti automatici deve poter essere difesa non solo sul piano dell'efficienza, ma anche su quello della controllabilità tecnica e della loro affidabilità in ambito forense [26, 27, 28].

1.8 Struttura della tesi

La struttura della tesi segue una progressione dal generale al particolare: dal quadro teorico e dallo stato dell'arte si passa alla definizione della metodologia sperimentale, per poi arrivare all'analisi empirica, alla discussione critica dei risultati e alle implicazioni operative del lavoro. La tesi è articolata in sei capitoli principali.

Il Capitolo 1 introduce il contesto generale della ricerca, evidenziando la crescente rilevanza della DF in scenari ad alta digitalizzazione, il ruolo assunto dall'automazione e dall'AI nei workflow investigativi, nonché il problema della robustezza dei sistemi di classificazione automatica di immagini in presenza di perturbazioni avversariali e anti-forensi. Nello stesso capitolo vengono definiti gli obiettivi del lavoro, il contributo specifico della tesi e la sua rilevanza tecnico-forense.

Il Capitolo 2 presenta il quadro teorico di riferimento. In esso vengono richiamati i concetti fondamentali della DF, i principali riferimenti normativi e metodologici relativi alla prova digitale, i fondamenti di ML e DL rilevanti per il problema affrontato, nonché le nozioni principali in materia di attacchi avversariali, tecniche anti-forensi, robustezza e interpretabilità dei modelli.

Il Capitolo ?? sviluppa una rassegna critica dello stato dell'arte, con particolare attenzione alle applicazioni dell'AI in DF, alle vulnerabilità dei sistemi di classificazione automatica rispetto a input manipolati e alle principali linee di ricerca sulla robustezza dei modelli e dei tool forensi guidati da AI. Tale capitolo consente di individuare le principali lacune della letteratura e di motivare il disegno sperimentale adottato nella tesi.

Il Capitolo ?? descrive in dettaglio la metodologia sperimentale. In questa parte vengono presentati il dataset, i criteri di costruzione e selezione delle classi, i modelli di classificazione considerati, le perturbazioni avversariali e anti-forensi selezionate, gli strumenti forensi impiegati e le metriche di valutazione. Il capitolo definisce inoltre la pipeline complessiva dell'esperimento e le scelte adottate per garantire coerenza metodologica e riproducibilità.

Il Capitolo ?? riporta l'applicazione concreta della metodologia, illustrando le procedure di test, i risultati ottenuti e il confronto tra modelli e strumenti rispetto alle diverse condizioni sperimentali. In questa parte vengono analizzati sia gli aspetti quantitativi sia quelli qualitativi

della risposta dei sistemi alle perturbazioni, con l'obiettivo di evidenziare punti di forza, fragilità ricorrenti e implicazioni operative dei risultati.

Infine, il Capitolo ?? raccoglie e discute criticamente le principali evidenze emerse dal lavoro. In esso vengono sintetizzati i contributi della tesi, evidenziati i limiti dello studio e proposte possibili direzioni di ricerca futura, con particolare riguardo al miglioramento della robustezza, dell'interpretabilità e dell'affidabilità dei sistemi basati su AI applicati alla DF.

Chapter 2

Technical Background Concepts

Questo capitolo fornisce una panoramica tecnica dei concetti fondamentali alla base dello studio, con particolare riferimento alle tecniche attualmente impiegate nella *digital forensics*, all'integrazione dell'intelligenza artificiale in tale contesto, alle immagini avversarial e alle tecniche di perturbazione, nonché all'intera pipeline forense.

Viene inoltre presentata una breve introduzione ai principali riferimenti normativi e ai concetti fondamentali di *Computer Law* applicati all'ambito forense digitale, con particolare attenzione agli aspetti giuridici della prova digitale, alla sua acquisizione, conservazione e valutazione nel contesto investigativo e processuale.

2.1 Introduzione alla Computer Law

Il termine **Computer Law** designa quell'insieme di norme giuridiche e principi interpretativi che disciplinano l'utilizzo delle tecnologie informatiche, con particolare attenzione ai profili di responsabilità, sicurezza e protezione dei dati digitali [29]. In ambito forense, tale disciplina si intreccia in modo indissolubile con la **Digital Forensics**, ossia la scienza che si occupa dell'individuazione, acquisizione, conservazione e analisi delle prove digitali ai fini processuali [2].

L'evoluzione tecnologica ha reso la prova digitale un elemento sempre più centrale nel processo penale contemporaneo, tanto che il legislatore e la giurisprudenza hanno progressivamente ampliato i confini della sua utilizzabilità. In particolare, gli articoli **234 c.p.p.** (documenti) e **189 c.p.p.** (prove atipiche) costituiscono le principali basi normative per l'ammissione di evidenze elettroniche in giudizio [30]. La giurisprudenza ha chiarito che i dati informatici possono essere acquisiti e valutati come prova purché siano rispettati i principi di integrità, autenticità e tracciabilità, che garantiscono la loro attendibilità [31].

Un punto di particolare rilievo è rappresentato dal **principio di legalità della prova**, secondo cui solo gli elementi probatori raccolti secondo modalità previste dalla legge possono essere utilizzati dal giudice nella formazione del convincimento. Questo principio, tradizionalmente applicato alle prove tradizionali, ha trovato progressiva estensione anche in relazione alle prove digitali, che richiedono un grado di garanzia aggiuntivo a causa della loro intangibilità e della facilità con cui possono essere alterate [32].

La **Corte di Cassazione** ha più volte sottolineato la necessità di una *motivazione rafforzata* quando la decisione giudiziaria si fonda in modo significativo su dati digitali (cfr. Cass. pen., sez. VI, n. 17677/2025). Tale orientamento contribuisce a delineare un quadro giuridico in cui il valore della prova digitale non è solo tecnico, ma anche strettamente connesso al rispetto delle garanzie costituzionali di difesa e al principio del giusto processo [8].

2.2 La prova digitale e i requisiti di ammissibilità

La **prova digitale** si caratterizza per una serie di peculiarità che la distinguono dalle prove tradizionali: essa è *immateriale*, in quanto rappresentata da bit piuttosto che da oggetti fisici; è *replicabile* all'infinito senza degradazione; è *volatile*, poiché può essere facilmente alterata o cancellata; e presenta una particolare vulnerabilità alle manipolazioni [2, 8]. Tali caratteristiche rendono indispensabile il rispetto di requisiti stringenti per assicurarne l'**ammissibilità processuale**.

Secondo la dottrina e la giurisprudenza, i principali requisiti che la prova digitale deve soddisfare sono i seguenti [31, 32]:

- **Integrità:** la prova deve essere preservata da alterazioni, volontarie o accidentali. A tal fine è fondamentale l'uso di procedure di *catena di custodia*, corredate da registri dettagliati e hash crittografici (MD5, SHA-256), che consentano di dimostrare la corrispondenza tra il dato acquisito e quello analizzato.
- **Autenticità:** l'evidenza deve poter essere attribuita con certezza ad un determinato soggetto, dispositivo o contesto. Ciò implica la tracciabilità delle operazioni e la documentazione delle modalità di acquisizione [30].
- **Affidabilità:** gli strumenti e le metodologie impiegate devono essere validati e scientificamente riconosciuti. La comunità internazionale ha prodotto standard come *ISO/IEC 27037:2012*, che definisce le linee guida per l'identificazione, la raccolta e la conservazione delle prove digitali.
- **Pertinenza e rilevanza:** la prova deve essere pertinente rispetto al fatto da accertare e rilevante ai fini della decisione giudiziaria, in conformità ai principi generali del processo penale.

Sul piano giurisprudenziale, la **Corte di Cassazione** ha ribadito la necessità che l'acquisizione e l'utilizzo della prova digitale rispettino pienamente tali requisiti, pena l'inammissibilità o la perdita di efficacia probatoria. In particolare, è stato affermato che il giudice deve fornire una **motivazione rafforzata** qualora fondi la decisione su evidenze digitali potenzialmente manipolabili (Cass. pen., sez. VI, n. 17677/2025).

Anche sul piano sovranazionale, le **Linee guida Eurojust** e le raccomandazioni dell'**ENFSI Forensic IT Working Group** sottolineano la centralità di integrità, autenticità e tracciabilità per garantire l'uso transfrontaliero delle prove digitali [33]. Tali documenti promuovono inoltre l'armonizzazione delle pratiche tra Stati membri, al fine di rafforzare la cooperazione giudiziaria europea in materia di criminalità informatica.

2.3 Normativa e giurisprudenza di riferimento

Il quadro normativo e giurisprudenziale che disciplina la prova digitale e le decisioni algoritmiche in ambito forense è estremamente articolato, coinvolgendo fonti nazionali, europee e internazionali. In questa sezione vengono analizzati i riferimenti principali, con attenzione agli aspetti maggiormente rilevanti per l'ammissibilità della prova digitale e per la legittimità delle decisioni basate su AI.

2.3.1 Italia

Nel sistema processuale italiano, la disciplina della prova digitale si fonda principalmente sul **Codice di procedura penale**:

- **Art. 234 c.p.p.** – ammette come prova i documenti, categoria oggi estesa anche ai dati informatici.
- **Art. 189 c.p.p.** – consente l'ingresso di *prove atipiche*, purché rispettose dei diritti fondamentali e dei principi generali del processo.

-
- **Artt. 247–254 c.p.p.** – disciplinano le perquisizioni, i sequestri e l’acquisizione di dati informatici, con particolare attenzione alla garanzia dell’integrità e della catena di custodia.

La **Corte di Cassazione** ha elaborato il principio della *motivazione rafforzata* per le decisioni che si basano su dati digitali, sottolineando come la loro vulnerabilità a manipolazioni richieda un vaglio particolarmente attento da parte del giudice (Cass. pen., sez. VI, n. 17677/2025). Questo orientamento si colloca nella più ampia cornice costituzionale di tutela del diritto di difesa (art. 24 Cost.) e del giusto processo (art. 111 Cost.).

2.3.2 Europa

A livello europeo, le principali fonti normative sono:

- **Regolamento (UE) 2016/679 – GDPR**: in particolare, l’art. 22 sancisce il diritto a non essere sottoposti a decisioni unicamente automatizzate, mentre l’art. 35 introduce l’obbligo di valutazioni d’impatto (DPIA) per trattamenti ad alto rischio [31].
- **AI Act (Reg. UE 2024/1689)**: introduce un sistema di classificazione dei sistemi di AI basato sul rischio. I sistemi ad alto rischio, tra cui quelli usati in ambito investigativo e giudiziario, devono rispettare requisiti di robustezza, trasparenza, supervisione umana e tracciabilità.
- **Direttiva 2013/40/UE** sugli attacchi contro i sistemi informatici, che stabilisce misure minime di acquisizione e conservazione delle prove digitali a livello europeo.
- **Linee guida Eurojust e ENFSI Forensic IT Working Group**: raccomandazioni operative per l’acquisizione, la conservazione e lo scambio di prove digitali, volte ad armonizzare le pratiche investigative tra Stati membri [33].

2.3.3 Standard internazionali

Sul piano internazionale, si evidenziano tre principali riferimenti:

- **Convenzione di Budapest sul cybercrime (2001)**: primo trattato internazionale in materia, che disciplina la cooperazione giudiziaria per la raccolta e la trasmissione di prove elettroniche [34].
- **ISO/IEC 27037:2012**: linee guida per l’identificazione, la raccolta e la conservazione delle prove digitali, con enfasi sulla catena di custodia [6].
- **Daubert standard**: criterio di ammissibilità della prova scientifica nei sistemi di common law, richiamato anche dalla dottrina europea come parametro per valutare la solidità scientifica delle metodologie digitali [8].

Questi riferimenti dimostrano come il riconoscimento giuridico della prova digitale e delle decisioni algoritmiche richieda un approccio multilivello, che integri standard tecnici, normative nazionali e linee guida sovranazionali.

2.4 Decisioni algoritmiche e implicazioni giuridiche

L’impiego di **sistemi di intelligenza artificiale (AI)** nelle indagini forensi sta assumendo un ruolo sempre più rilevante, in particolare attraverso strumenti di *pattern recognition*, classificazione automatica di immagini e analisi predittiva di log digitali [7, 35]. Tale evoluzione, se da un lato consente una significativa riduzione dei tempi di analisi e una maggiore capacità di trattare grandi volumi di dati, dall’altro solleva questioni giuridiche di primaria importanza.

Tra i principali rischi identificati in dottrina e giurisprudenza si segnalano:

- **Errore giudiziario:** un modello non robusto, vulnerabile a perturbazioni avversariali o bias di addestramento, può indurre classificazioni errate. Se tali classificazioni costituiscono la base di un'accusa o di una decisione giudiziaria, vi è un rischio concreto di compromettere il giusto processo [nowroozi2024robustness, 36].
- **Opacità algoritmica:** i modelli di deep learning, spesso configurati come *black-box*, rendono difficile comprendere le logiche decisionali interne. Ciò contrasta con il principio del contraddittorio e con il diritto di difesa, poiché le parti devono poter verificare le basi della decisione giudiziaria.
- **Necessità di motivazione rafforzata:** analogamente a quanto affermato dalla Corte di Cassazione per l'utilizzo della prova digitale, anche per le decisioni basate su AI è richiesta una motivazione particolarmente accurata, che dia conto dell'affidabilità e della validità degli strumenti impiegati.
- **Trasparenza e accountability:** le moderne linee guida europee sottolineano l'importanza di implementare approcci di *Explainable AI* (XAI), al fine di rendere tracciabili e interpretabili i processi decisionali automatici [phd'unisi'068552].

Il **Regolamento (UE) 2016/679 – GDPR** affronta esplicitamente il tema delle decisioni automatizzate: l'art. 22 sancisce il diritto a non essere sottoposti a decisioni basate unicamente su trattamenti automatizzati, comprese quelle fondate sulla profilazione, salvo specifiche eccezioni; l'art. 35 prevede l'obbligo di una valutazione d'impatto (DPIA) per trattamenti ad alto rischio [31].

Il recente **AI Act** (Regolamento UE 2024/1689) rappresenta un ulteriore passo avanti, introducendo una classificazione dei sistemi di AI in base al livello di rischio. I sistemi ad alto rischio, tra cui rientrano quelli impiegati in ambito investigativo e giudiziario, sono soggetti a obblighi stringenti in termini di robustezza, tracciabilità e trasparenza. In particolare, l'AI Act impone che tali sistemi siano progettati per ridurre al minimo i rischi di errore e garantire meccanismi di supervisione umana, rendendo così le decisioni algoritmiche compatibili con i principi del giusto processo.

2.5 Introduzione alla Digital Forensics

La **Digital Forensics** è una disciplina scientifica che si occupa dell'identificazione, acquisizione, conservazione, analisi e presentazione di dati digitali utilizzabili come prova in ambito legale. La sua applicazione è cruciale in indagini penali, civili, amministrative e aziendali, ed è regolata da standard tecnici e normativi internazionali, tra cui le linee guida del NIST (National Institute of Standards and Technology), del SANS Institute e dei gruppi di lavoro SWGDE (Scientific Working Group on Digital Evidence) e ACPO (Association of Chief Police Officers).

Secondo la definizione ufficiale del NIST SP 800-86, la digital forensics consiste in:

“The application of science to the identification, collection, examination, and analysis of data while preserving the integrity of the information and maintaining a strict chain of custody for the data.” [kent2006nist]

L'intero processo di indagine digitale può essere modellato attraverso una pipeline metodologica ben definita, generalmente articolata in quattro fasi principali [2, 37]:

1. **Collection** (Raccolta): rappresenta il primo passo operativo e consiste nell'acquisizione dei dati digitali rilevanti da dispositivi, server, archivi cloud, reti, memorie volatili (RAM) o dispositivi mobili. È fondamentale utilizzare strumenti che garantiscano l'integrità della fonte, come write-blocker hardware o software e strumenti di imaging forense come dd, FTK Imager, Guymager o EnCase.
2. **Examination** (Esame): in questa fase si procede all'identificazione di file significativi e alla localizzazione di tracce digitali. Le tecniche includono il file carving, il recupero

di file cancellati, l'analisi dei metadata, la ricostruzione della cronologia e l'estrazione di artefatti. L'obiettivo è isolare informazioni potenzialmente probatorie.

3. **Analysis** (Analisi): consiste nell'interpretazione approfondita dei dati ottenuti nella fase precedente. Comprende la correlazione temporale tra eventi, il confronto tra fonti differenti e la ricostruzione di attività sospette. In contesti moderni, questa fase può essere assistita da strumenti basati su intelligenza artificiale (AI), per il riconoscimento di pattern, la classificazione automatica di contenuti e la rilevazione di anomalie.
4. **Reporting** (Redazione del report): tutte le attività svolte devono essere documentate in modo dettagliato, trasparente e replicabile. Il report forense deve includere una descrizione delle procedure utilizzate, i risultati ottenuti, la giustificazione delle scelte tecniche, ed eventuali limitazioni. Questo documento può essere utilizzato in sede giudiziaria come elemento di prova.




Figure 2.1: Pipeline forense secondo le linee guida NIST SP 800-86 e ACPO: fasi operative principali dalla raccolta dell'evidenza alla presentazione in giudizio.

Modelli e standard di riferimento

Nel campo della digital forensics, l'impiego di modelli strutturati e standard condivisi è essenziale per garantire uniformità, affidabilità e validità giuridica nei processi di acquisizione, analisi e conservazione delle evidenze digitali. Numerosi enti istituzionali e gruppi di lavoro hanno contribuito nel tempo allo sviluppo di linee guida e framework metodologici, alcuni dei quali rappresentano oggi riferimenti fondamentali per la comunità forense a livello internazionale.

Tra i principali modelli di riferimento si annoverano:

-
- **NIST SP 800-86 (Guide to Integrating Forensic Techniques into Incident Response):** sviluppato dal *National Institute of Standards and Technology*, questo documento definisce un framework operativo per l'integrazione delle tecniche forensi all'interno delle attività di risposta agli incidenti informatici. Il modello distingue tra le fasi di raccolta, esame, analisi e reporting, fornendo indicazioni pratiche su strumenti e documentazione necessari [kent2006nist].
 - **SWGDE Recommendations (Scientific Working Group on Digital Evidence):** si tratta di una serie di raccomandazioni tecniche e operative pubblicate da un consorzio di esperti statunitensi. Le SWGDE Guidelines coprono un ampio spettro di ambiti — dall'analisi di dispositivi mobili all'autenticazione di immagini — e definiscono requisiti minimi per garantire l'integrità delle procedure nei laboratori forensi digitali.
 - **DIFC Framework (Digital Investigation Framework for Cloud):** progettato specificamente per ambienti cloud e infrastrutture distribuite, questo modello fornisce un'architettura modulare per la conduzione di indagini digitali in contesti in cui i dati non risiedono in ambienti controllati. Include meccanismi per la gestione delle istanze virtuali, la preservazione dei log e la validazione delle prove attraverso tecniche crittografiche.
 - **ACPO Principles (Association of Chief Police Officers):** rappresentano lo standard adottato nel Regno Unito per le indagini digitali. Il principio guida stabilisce che “nessuna azione intrapresa da chiunque coinvolto nell'investigazione deve modificare i dati contenuti in un dispositivo elettronico o sistema informatico”, a meno che non sia inevitabile. Ogni intervento deve essere giustificabile, tracciato e replicabile. Tali principi hanno influenzato anche le linee guida europee e sono oggi ampiamente riconosciuti in ambito internazionale.

L'adozione di tali modelli non solo assicura la conformità normativa e il rispetto dei diritti processuali, ma costituisce anche un prerequisito per la validazione scientifica delle metodologie forensi adottate.




Figure 2.2: Timeline di adozione dei principali standard e modelli forensi.

2.6 Tecniche di acquisizione e analisi forense

Nell'ambito della digital forensics, la fase di **acquisizione** dell'evidenza digitale costituisce uno dei momenti più delicati e critici dell'intero processo investigativo. Essa rappresenta l'atto

iniziale attraverso cui si effettua la raccolta dei dati da un dispositivo elettronico, con l'obiettivo di garantirne l'integrità, la completezza e la futura ripetibilità dell'analisi.

A seconda dello stato operativo del sistema oggetto di indagine, le tecniche di acquisizione si suddividono in due categorie principali [2]:

- **Live Acquisition** (*acquisizione a caldo*): viene effettuata su dispositivi in esecuzione, ovvero ancora attivi al momento dell'intervento. Questa modalità consente la cattura di informazioni volatili, come:
 - Contenuto della memoria RAM
 - Processi in esecuzione
 - Connessioni di rete attive
 - Tabelle ARP, DNS cache e routing
 - Chiavi crittografiche temporanee o sessioni utente

Tali elementi, essendo transitori, non sono recuperabili una volta che il sistema viene spento, rendendo la live acquisition fondamentale in scenari come analisi di malware attivi, indagini post-compromissione o risposta a incidenti. Tuttavia, l'esecuzione di strumenti sul sistema target introduce il rischio di contaminazione dell'evidenza: ogni operazione può alterare lo stato del dispositivo, violando il principio di non modificabilità.

- **Dead Acquisition** (*acquisizione a freddo*): viene realizzata su dispositivi spenti, previa rimozione fisica del supporto di memorizzazione o utilizzo di ambienti controllati (es. write-blocker hardware). Consiste nella creazione di un'immagine forense completa (bitstream copy), che riproduce byte per byte il contenuto del supporto, compresi settori non allocati, partizioni nascoste e aree di slack space. Questa tecnica è la più diffusa nei laboratori forensi, poiché garantisce un elevato livello di integrità, replicabilità e ammissibilità legale. Tra gli strumenti maggiormente impiegati si annoverano:
 - **FTK Imager**: tool GUI-based per Windows, molto usato per acquisizioni rapide e compatibili.
 - **Guymager**: tool open source per ambienti Linux, noto per la sua affidabilità e leggerezza.
 - **dd** e **dcfldd**: strumenti a linea di comando per copie bitstream, con opzioni avanzate di logging e verifica.
 - **EnCase Forensic**: soluzione commerciale avanzata per imaging e validazione forense certificata.

Oltre all'acquisizione, la fase di **analisi forense** comprende una serie di tecniche e strumenti volti a estrarre, correlare e interpretare le informazioni rilevanti. Essa può includere:

- **Analisi del file system**: ricostruzione della struttura logica dei file (NTFS, EXT4, APFS, HFS+) e recupero di dati cancellati o nascosti.
- **Analisi del registro di sistema** (Windows Registry): utile per determinare attività recenti, utenti attivi, dispositivi connessi.
- **Analisi di artefatti digitali**: cronologia del browser, file temporanei, log di sistema, timestamp, cronologia delle esecuzioni.
- **Mobile forensics**: estrazione di dati da smartphone e tablet mediante strumenti dedicati come UFED, Magnet AXIOM e Oxygen Forensics, in grado di ricostruire comunicazioni, contenuti multimediali, posizione e social network.
- **Timeline reconstruction**: generazione di una sequenza temporale coerente degli eventi digitali basata su timestamp, file system e log.

La correttezza di questa fase è fondamentale: ogni errore metodologico o alterazione accidentale potrebbe compromettere la validità probatoria dell'intera indagine. Per questo motivo, i laboratori forensi adottano protocolli standardizzati, hash crittografici (MD5, SHA256) e sistemi di audit trail per certificare ogni passaggio.

Tecniche di analisi

Una volta completata la fase di acquisizione, l'analisi forense si concentra sull'**estrazione, interpretazione e correlazione** dei dati digitali contenuti nei supporti acquisiti. Questa fase è cruciale per trasformare l'evidenza grezza in informazioni comprensibili e rilevanti per l'indagine, sia in ambito giudiziario che investigativo.

Le tecniche di analisi più rilevanti comprendono:

- **File System Analysis:** consente di ricostruire e interpretare la struttura logica dei file system utilizzati nei dispositivi, come NTFS, FAT32, EXT4, HFS+, APFS. L'analisi permette di recuperare file eliminati, accedere a directory nascoste, esplorare settori non allocati, identificare partizioni nascoste e analizzare i record di journaling (es. USN Journal in NTFS).
- **Registry Analysis:** tecnica specifica per sistemi Windows, che consente di esaminare il registro di sistema, struttura che conserva impostazioni di configurazione, informazioni su software installati, dispositivi USB collegati, cronologie utente, chiavi di esecuzione automatica (**Run/RunOnce**) e molto altro. L'analisi del registry è utile per ricostruire il comportamento dell'utente o la presenza di attività sospette.
- **Artefact Analysis:** si riferisce all'identificazione e interpretazione di artefatti digitali, ovvero tracce lasciate dall'attività dell'utente e dal sistema operativo. Tra gli artefatti più comuni si trovano: cronologie dei browser, file temporanei e recenti, log di sistema, sessioni di login/logout, timestamp alterati, file di swap e hibernation, e metadati dei file (exif, MAC times).
- **Mobile Forensics:** comprende sia l'acquisizione che l'analisi dei dispositivi mobili come smartphone, tablet e SIM card. Le tecniche possono variare in base al sistema operativo (iOS, Android), al tipo di blocco presente e al livello di cifratura del dispositivo. Strumenti professionali come **UFED Cellebrite**, **Magnet AXIOM** e **Oxygen Forensics** permettono di estrarre dati da immagini fisiche o logiche, comprese chat (WhatsApp, Telegram), fotografie, posizionamenti GPS, cronologie di navigazione, contatti e applicazioni installate, anche da dispositivi danneggiati o cifrati.

È fondamentale che ogni operazione sia eseguita nel rispetto di metodologie documentate e replicabili, e che siano impiegati software certificati in grado di generare log e report validi in sede giudiziaria. La tracciabilità delle operazioni e l'integrità dei dati analizzati rappresentano requisiti imprescindibili per garantire l'ammissibilità probatoria delle evidenze digitali.

Le informazioni così ottenute costituiscono la base per la fase successiva di correlazione e reporting, in cui le evidenze digitali vengono strutturate e presentate in forma comprensibile per i soggetti giudicanti.

2.7 Aspetti legali della Digital Forensics

L'attività di digital forensics è strettamente legata alla normativa giuridica, poiché si fonda sulla possibilità di trasformare dati digitali in prove utilizzabili in sede giudiziaria. È pertanto essenziale che tutte le operazioni tecniche vengano svolte nel rispetto dei diritti fondamentali, tra cui la privacy, la tutela della difesa, la proporzionalità e il diritto al giusto processo [29].

Le principali fonti normative a livello europeo e internazionale che regolano l'attività di digital forensics includono:

-
- **Regolamento (UE) 2016/679 – GDPR:** disciplina il trattamento dei dati personali, imponendo principi di liceità, limitazione delle finalità, minimizzazione dei dati e responsabilizzazione. In ambito forense, è fondamentale dimostrare la necessità e proporzionalità del trattamento, nonché adottare misure tecniche adeguate per la protezione dei dati [31].
 - **Direttiva 2013/40/UE:** stabilisce norme minime relative agli attacchi contro i sistemi informatici e impone agli Stati membri l'adozione di misure per la raccolta e conservazione delle prove elettroniche, in un'ottica di armonizzazione della normativa penale europea.
 - **Convenzione di Budapest (2001):** primo trattato internazionale sulla criminalità informatica, promuove la cooperazione tra Stati nella raccolta di prove digitali e nella definizione di standard comuni per la loro conservazione, autenticazione e trasmissione. Fornisce le basi giuridiche per richieste di collaborazione transfrontaliera [34].
 - **Codice di procedura penale italiano:** articoli come il 220-bis e 359 disciplinano l'acquisizione, l'analisi e la perizia tecnica delle fonti informatiche, sottolineando l'importanza della **catena di custodia** e del principio del *contraddittorio tecnico*. Le evidenze devono essere acquisite e analizzate in modo da garantirne autenticità, integrità e ripetibilità, pena l'inammissibilità in giudizio [30].

Implicazioni cross-border e cooperazione internazionale

Con la crescente adozione di servizi cloud e infrastrutture distribuite, la Digital Forensics si confronta sempre più frequentemente con scenari in cui l'evidenza digitale è distribuita su server situati in giurisdizioni differenti. Questo fenomeno solleva complessi problemi di natura giuridica e operativa legati alla **giurisdizione**, alla **cooperazione internazionale** e alla **conservazione dell'integrità probatoria** [8, 32].

In particolare, i principali ostacoli includono:

- **Conflitti normativi:** le normative sulla protezione dei dati e sulla privacy variano sensibilmente da un Paese all'altro, creando potenziali incompatibilità tra l'ordinamento del richiedente e quello dell'hosting provider.
- **Limiti di giurisdizione:** un'autorità giudiziaria nazionale può non avere il potere di imporre la consegna di dati conservati all'estero senza ricorrere a strumenti di mutua assistenza legale.
- **Tempi e modalità di cooperazione:** l'uso di procedure formali come le rogatorie internazionali o i Mutual Legal Assistance Treaties (MLATs) può richiedere tempi incompatibili con le esigenze di indagini urgenti, rischiando la perdita di dati volatili.
- **Integrità e catena di custodia:** il trasferimento di prove digitali attraverso confini giurisdizionali deve garantire l'immutabilità dei dati e la tracciabilità delle operazioni eseguite, rispettando sia gli standard tecnici (es. NIST SP 800-86) sia quelli legali applicabili.

Per affrontare tali problematiche, strumenti come la **Convenzione di Budapest sul cyber-crime** e le iniziative dell'*European Union Agency for Cybersecurity* (ENISA) promuovono linee guida e protocolli comuni per l'acquisizione e lo scambio di evidenze digitali in contesti transfrontalieri. Tuttavia, l'eterogeneità normativa e la mancanza di un quadro giuridico globale unificato rendono ancora oggi la *cross-border digital forensics* un ambito critico che richiede competenze tecniche e giuridiche integrate.

#	Fase
1	Richiesta ufficiale di acquisizione dati (Autorità giudiziaria nazionale → Paese ospitante)
2	Autorizzazione legale (es. MLAT, rogatoria internazionale, convenzioni come Budapest)
3	Trasferimento sicuro dell'evidenza digitale (canali cifrati, protocolli autenticati)
4	Verifica integrità e catena di custodia (hash crittografici, documentazione delle operazioni)
5	Utilizzo in sede processuale (ammissibilità secondo norme del Paese richiedente)

Table 2.1: Flusso tipico di acquisizione e gestione di un'evidenza digitale in scenari cross-border.

È fondamentale che l'intera attività forense sia documentata nel rispetto della catena di custodia, affinché le prove possano essere ammesse in sede processuale.

Normativa	Ambito	Vincoli	Rilevanza in DF
GDPR (Reg. UE 2016/679)	Protezione dei dati personali	Minimizzazione, liceità, accountability	Garantire proporzionalità e tracciabilità nel trattamento dei dati digitali
Direttiva 2013/40/UE	Reati informatici	Standard di raccolta, penalizzazione attacchi ai sistemi	Uniformità giuridica europea nella raccolta e conservazione delle evidenze
Convenzione di Budapest (2001)	Cybercrime internazionale	Integrità, autenticazione, cooperazione transfrontaliera	Supporto legale alla cooperazione tra Stati per l'acquisizione di prove digitali
Codice di procedura penale (Italia)	Processo penale	Catena di custodia, perizia, contraddittorio tecnico	Fondamentale per la validità processuale dell'evidenza digitale in giudizio

Table 2.2: Confronto tra principali normative internazionali rilevanti per la digital forensics.

Catena di custodia e validità probatoria

La **catena di custodia** è l'insieme delle procedure formali e documentate finalizzate a garantire che un'evidenza digitale mantenga la propria integrità, autenticità e tracciabilità dal momento della raccolta fino alla sua eventuale presentazione in sede giudiziaria. Ogni operazione — acquisizione, copia, analisi, trasferimento o conservazione — deve essere tracciata in modo preciso, con registrazione dell'identità dell'operatore, data, scopo dell'attività e strumenti utilizzati.

Secondo i principi definiti dall'*Association of Chief Police Officers* (ACPO) [38] nel Regno Unito e riconosciuti a livello internazionale, nessuna azione dovrebbe alterare i dati originali. Qualora ciò sia necessario, la modifica deve essere giustificata, esplicitamente documentata e tecnicamente riproducibile. In ambito europeo, tali prescrizioni si intrecciano con le disposizioni del **Regolamento (UE) 2016/679 (GDPR)** e delle normative penali nazionali, che impongono ulteriori vincoli sulla liceità, la proporzionalità e la conservazione dei dati digitali.

Un'interruzione o una mancata documentazione della catena di custodia può compromettere la validità dell'intera evidenza, rendendola potenzialmente inammissibile in sede processuale.

Come illustrato nella Figura 2.3, il processo forense prevede una serie di fasi distinte ma collegate, ciascuna delle quali deve essere registrata in modo da assicurare la trasparenza e la responsabilità del trattamento probatorio.



Figure 2.3: Fasi della catena di custodia nell'ambito della digital forensics. Fonte: [39].

oppure Come alternativa visiva compatta, la Figura 2.4 illustra la catena di custodia in formato verticale, adatta a layout stretti o a sezioni di dettaglio.




Figure 2.4: Catena di custodia

Standard operativi e best practices

Per garantire l'integrità, l'affidabilità e l'ammissibilità delle evidenze digitali in sede giudiziaria, è essenziale adottare standard operativi riconosciuti a livello internazionale. Tali standard forniscono linee guida metodologiche e tecniche per ogni fase dell'attività forense, dalla raccolta dei dati all'analisi, dalla conservazione alla documentazione.

Tra i riferimenti più autorevoli si annoverano:

- *SWGDE Guidelines (Scientific Working Group on Digital Evidence)*: una serie di raccomandazioni pubblicate da un consorzio internazionale di esperti, finalizzate a promuovere pratiche forensi solide e riproducibili. Le linee guida coprono ambiti quali l'analisi di dispositivi mobili, l'acquisizione di immagini forensi e la validazione degli strumenti impiegati [28].
- *ISO/IEC 27037:2012 – Guidelines for identification, collection and preservation of digital evidence*: standard ISO che definisce procedure dettagliate per l'identificazione, la raccolta, l'acquisizione e la conservazione delle prove digitali, con particolare attenzione alla catena di custodia, alla documentazione e ai ruoli degli operatori coinvolti [6].
- *ENFSI Forensic IT Working Group Guidelines*: raccomandazioni tecniche elaborate dal *European Network of Forensic Science Institutes*, focalizzate sulla standardizzazione delle

pratiche forensi nei laboratori europei. Le linee guida promuovono interoperabilità, trasparenza e coerenza metodologica tra le diverse giurisdizioni europee [33].

L'adesione a tali standard non costituisce soltanto una buona prassi tecnica, ma è considerata oggi un requisito essenziale per garantire:

- la **validità probatoria** delle evidenze raccolte;
- la **trasparenza** e la replicabilità delle metodologie impiegate;
- la **tutela dei diritti fondamentali** delle persone coinvolte nell'indagine, come sancito dalle normative europee (es. GDPR, Direttiva 2016/680/UE).

L'implementazione rigorosa di questi standard consente di ridurre al minimo il rischio di contestazioni legali e di garantire che i risultati delle analisi forensi siano accettabili e credibili in ambito processuale.

La Tabella 2.3 riassume le principali caratteristiche dei tre standard operativi più rilevanti per la gestione e analisi delle evidenze digitali.

Caratteristica	SWGDE Guidelines	ISO/IEC 27037:2012	ENFSI Forensic IT WG
Origine	USA (gruppo di lavoro scientifico federale)	International Organization for Standardization (ISO)	Unione Europea (rete di istituti forensi)
Ambito	Raccomandazioni pratiche per investigatori digitali e laboratori	Linee guida per identificazione, raccolta e conservazione di evidenze digitali	Manuali tecnici per laboratori forensi europei
Finalità	Promuovere l'affidabilità operativa e la documentazione dei processi	Garantire la tracciabilità e l'integrità dell'evidenza in contesti legali	Uniformare le pratiche nei Paesi membri ENFSI
Applicabilità	Indagini digitali, dispositivi mobili, imaging, validazione strumenti	Qualsiasi contesto di gestione di prove digitali, anche al di fuori della forensics	Laboratori accreditati o affiliati a ENFSI, uso in ambito penale europeo
Aggiornamenti	Aggiornamenti periodici disponibili pubblicamente	Standard fisso (2012), ma compatibile con audit ISO	Revisioni periodiche interne e pubblicazioni sul sito ENFSI

Table 2.3: Confronto tra principali standard e linee guida operative in ambito digital forensics.

2.8 AI nella Digital Forensics

L'introduzione dell'Intelligenza Artificiale (AI) nel campo della digital forensics ha trasformato radicalmente molte operazioni di indagine, aumentando la capacità di elaborazione di grandi volumi di dati e migliorando l'automazione di compiti complessi e ripetitivi. In particolare, le tecniche di *Machine Learning* (ML) e *Deep Learning* (DL) si sono dimostrate estremamente efficaci in diversi ambiti investigativi.

Secondo Rogers e Seigfried-Spellar [35], l'AI consente una significativa riduzione dei tempi di analisi, una maggiore precisione nella classificazione automatica e una migliore capacità di identificare pattern anomali rispetto alle metodologie tradizionali. Queste tecnologie sono oggi utilizzate per:

- **Classificazione automatica di immagini e video:** rilevamento di contenuti illeciti o sensibili tramite CNN (Convolutional Neural Networks) [40];

-
- **Segmentazione semantica:** distinzione automatica tra regioni rilevanti in immagini/video (es. arma vs sfondo);
 - **Riconoscimento facciale:** identificazione di soggetti in database investigativi o feed video [41];
 - **Analisi di log e file di sistema:** individuazione di attività sospette o accessi anomali tramite anomaly detection e clustering [42];
 - **Raggruppamento di evidenze:** tecniche non supervisionate per clusterizzare immagini, conversazioni o file in base a similarità.

2.8.1 Evoluzione e motivazioni dell'uso dell'AI nella Digital Forensics

L'applicazione dell'Intelligenza Artificiale (AI) in ambito forense digitale è il risultato di un'evoluzione metodologica che, negli ultimi due decenni, ha visto un progressivo spostamento dall'analisi manuale a processi automatizzati e scalabili. In origine, le attività di digital forensics si basavano prevalentemente su competenze umane e strumenti a basso livello, richiedendo tempi di elaborazione elevati e limitando la capacità di esaminare grandi volumi di dati in tempi compatibili con le esigenze investigative [2, 35].

La crescente pervasività delle tecnologie digitali, l'aumento esponenziale delle fonti di evidenza (dispositivi mobili, cloud, social media, IoT) e la complessità intrinseca dei dati multimediali hanno reso necessario adottare approcci più rapidi e intelligenti. In questo contesto, il *Machine Learning* (ML) e, più recentemente, il *Deep Learning* (DL) hanno introdotto nuove possibilità, consentendo di automatizzare compiti complessi quali la classificazione di immagini e video, l'estrazione di pattern, l'analisi semantica e la correlazione temporale di eventi [7, 40].

L'integrazione dell'AI nella digital forensics risponde a tre esigenze principali:

1. **Scalabilità:** gestione efficiente di dataset composti da milioni di file multimediali, con capacità di filtrare e indicizzare automaticamente contenuti rilevanti [43].
2. **Accuratezza:** miglioramento delle prestazioni in compiti di riconoscimento e classificazione rispetto agli approcci basati su regole statiche.
3. **Supporto decisionale:** fornitura di risultati strutturati e priorità di analisi, riducendo il carico cognitivo sugli investigatori e permettendo loro di concentrarsi sugli elementi critici [phd'unisi'068552].

Questo passaggio evolutivo non è privo di criticità: la natura opaca dei modelli di DL (*black box*) solleva interrogativi sulla trasparenza e sulla spiegabilità delle decisioni, mentre la vulnerabilità a input manipolati (*adversarial examples*) pone problemi di affidabilità probatoria, che saranno approfonditi nei capitoli successivi [nowroozi2024robustness, 36].

2.8.2 Strumenti AI-based in ambito forense

Come illustrato nella Tabella 2.4, numerosi strumenti forensi commerciali e accademici integrano oggi moduli di Intelligenza Artificiale per automatizzare e velocizzare l'analisi di grandi volumi di dati.

Tali strumenti combinano tecniche di *Computer Vision*, *Natural Language Processing* e *Pattern Recognition* per supportare compiti come:

- filtraggio e categorizzazione di contenuti multimediali;
- rilevamento di manipolazioni e anomalie;
- estrazione di pattern e relazioni tra entità digitali;
- segmentazione temporale e semantica di grandi dataset.

L'efficacia operativa di questi tool dipende non solo dalla qualità dei modelli e dei dataset di addestramento, ma anche dalla loro **robustezza** rispetto ad attacchi mirati o perturbazioni non intenzionali, tema che sarà analizzato nei capitoli successivi.

Strumento	Tipo di AI / Modello	Funzionalità principali	Contesto forense
Magnet.AI	NLP, CNN per immagini	Classificazione automatica di immagini, video, messaggi; categorizzazione per temi (armi, abusi, violenza)	Analisi di grandi volumi di dati multimediali in indagini su reati contro la persona e reati informatici
Cellebrite UFED	Pattern recognition, clustering	Raggruppamento automatico di contatti, chat, immagini; riconoscimento contenuti sensibili	Mobile forensics e recupero dati da dispositivi mobili, anche cifrati
Amped Authenticate	Modelli ML per rilevamento manipolazioni	Analisi autenticità immagini; rilevamento compressioni anomale, manipolazioni e incoerenze nei metadati	Verifica di prove fotografiche e video in indagini giudiziarie
X-Ways Forensics plugin AI	Classificatori esterni + integrabili via API	Analisi di pattern ricorrenti in filesystem; segmentazione timeline; ricerca automatica di contenuti sospetti	Indagini informatiche complesse su dischi e sistemi operativi, con estensioni AI custom

Table 2.4: Confronto tra principali strumenti forensi AI-based: tecnologie impiegate, funzionalità e contesto operativo.




Figure 2.5: Principali tool AI-based in digital forensics e tipologie di task supportati.

2.9 Attacchi avversariali nei sistemi di Machine Learning

Negli ultimi anni i modelli di *Machine Learning* (ML) e *Deep Learning* (DL) hanno raggiunto prestazioni estremamente elevate in numerosi ambiti applicativi, tra cui computer vision, riconoscimento vocale, analisi di rete, cybersecurity e digital forensics. Tuttavia, numerosi studi hanno dimostrato che tali modelli sono vulnerabili a input opportunamente manipolati, progettati per indurre errori di classificazione pur mantenendo modifiche minime e spesso impercettibili per un osservatore umano.

Questi input manipolati sono noti come *adversarial examples*. Essi consistono in campioni di input modificati tramite perturbazioni intenzionali, generalmente di piccola entità, che alterano il comportamento del modello inducendolo a produrre predizioni errate. Il fenomeno ha dato origine a un importante filone di ricerca noto come *Adversarial Machine Learning*, che studia le vulnerabilità dei sistemi di apprendimento automatico in presenza di avversari attivi.

Sebbene il tema abbia acquisito grande visibilità a partire dal 2014 con la dimostrazione della vulnerabilità delle reti neurali profonde alla manipolazione degli input, le radici di questo ambito di ricerca sono precedenti. Già nei primi anni 2000 era stato dimostrato che classificatori utilizzati nel filtraggio dello spam potevano essere aggirati tramite modifiche minime ai messaggi di posta elettronica, evidenziando come gli algoritmi di apprendimento automatico possano essere vulnerabili in ambienti ostili [36]. Tali studi hanno evidenziato la necessità di sviluppare metodologie sistematiche per la valutazione della sicurezza dei sistemi basati su machine learning.

In questo contesto, l'*adversarial machine learning* si propone di analizzare e comprendere il comportamento dei sistemi di apprendimento automatico quando operano in ambienti avversariali, nei quali gli attaccanti cercano deliberatamente di manipolare i dati di input o il processo di apprendimento per compromettere l'affidabilità del sistema.

2.9.1 Modello di minaccia negli attacchi avversariali

L'analisi degli attacchi avversariali si basa generalmente sulla definizione di un *modello di minaccia* (*threat model*), che descrive formalmente le capacità, gli obiettivi e il livello di conoscenza dell'attaccante. La definizione di un threat model consente di valutare in modo sistematico le vulnerabilità di un sistema di machine learning e di simulare scenari di attacco realistici.

Il modello di minaccia viene generalmente descritto attraverso tre dimensioni principali: gli obiettivi dell'attaccante, il livello di conoscenza del modello e le capacità di manipolazione dei dati.

Obiettivi dell'attaccante

Gli attacchi avversariali possono perseguire diversi obiettivi, a seconda del contesto applicativo. In generale si distinguono tre principali categorie:

- **Attacchi di integrità** (*integrity attacks*) l'obiettivo dell'attaccante è indurre il sistema a classificare erroneamente uno specifico input, senza necessariamente compromettere il funzionamento complessivo del modello.
- **Attacchi di disponibilità** (*availability attacks*) l'attaccante mira a degradare le prestazioni complessive del modello, causando un elevato numero di errori di classificazione.
- **Attacchi alla privacy** (*privacy attacks*) l'obiettivo consiste nell'estrarre informazioni sensibili dal modello, come dati di addestramento o parametri interni.

Nel contesto della classificazione di immagini, gli attacchi di integrità rappresentano lo scenario più comune, poiché l'attaccante tenta tipicamente di far classificare un'immagine appartenente a una classe come appartenente a un'altra.

Conoscenza dell'attaccante

L'efficacia di un attacco avversariale dipende fortemente dal livello di conoscenza che l'attaccante possiede rispetto al sistema bersaglio. In letteratura si distinguono tre principali scenari:

- **Attacchi white-box** l'attaccante possiede piena conoscenza del modello, inclusi architettura, parametri, funzione di perdita e dati di addestramento.
- **Attacchi black-box** l'attaccante non ha accesso diretto al modello ma può osservare soltanto gli output generati dal sistema, ad esempio tramite interrogazioni.
- **Attacchi gray-box** l'attaccante dispone di informazioni parziali sul sistema, come l'architettura del modello o il dataset utilizzato per l'addestramento.

Gli attacchi black-box sono particolarmente rilevanti nei contesti reali, dove i modelli sono spesso implementati come servizi proprietari o integrati in strumenti software chiusi.

2.9.2 Tipologie di attacchi avversariali

Gli attacchi avversariali possono essere classificati in base alla fase del ciclo di apprendimento in cui avviene la manipolazione dei dati. In particolare si distinguono due principali categorie: *poisoning attacks* ed *evasion attacks*.

Poisoning attacks

I *poisoning attacks* colpiscono la fase di addestramento del modello. In questo scenario l'attaccante introduce nel dataset di training campioni manipolati con l'obiettivo di influenzare il processo di apprendimento.

Tali attacchi possono indurre il modello a sviluppare vulnerabilità specifiche oppure a degradare significativamente le proprie prestazioni. I poisoning attacks risultano particolarmente rilevanti nei sistemi che apprendono continuamente da nuovi dati o che utilizzano dataset provenienti da fonti esterne non controllate.

Tra le strategie più comuni si possono citare:

- manipolazione delle etichette (*label flipping*)
- inserimento di dati malevoli nel dataset
- tecniche di poisoning basate su ottimizzazione del gradiente

Evasion attacks

Gli *evasion attacks*, detti anche *test-time attacks*, rappresentano la forma più diffusa di attacco avversariale. In questo caso l'attaccante modifica direttamente i dati di input durante la fase di inferenza, senza alterare il modello.

Formalmente, dato un classificatore

$$f(x)$$

l'obiettivo dell'attaccante è trovare un input perturbato x' tale che

$$f(x') \neq f(x)$$

dove

$$x' = x + \delta$$

e la perturbazione δ è limitata da un vincolo sulla sua norma:

$$||\delta|| < \epsilon$$

dove ϵ rappresenta la massima intensità della perturbazione consentita.

2.9.3 Adversarial examples nei sistemi di computer vision

Nel contesto dei sistemi di computer vision, gli adversarial examples vengono generalmente generati applicando piccole perturbazioni ai valori dei pixel dell'immagine. Nonostante tali modifiche siano spesso impercettibili all'occhio umano, esse possono alterare in modo significativo la predizione del modello.

Questo fenomeno evidenzia una proprietà fondamentale delle reti neurali profonde: la loro elevata sensibilità a piccole variazioni nello spazio delle feature. Anche modifiche minime dei dati di input possono produrre variazioni significative nelle rappresentazioni interne apprese dalla rete.

Un ulteriore aspetto rilevante degli adversarial examples è la loro *transferability*. In molti casi, perturbazioni generate per ingannare un modello risultano efficaci anche contro altri modelli addestrati sullo stesso task, anche quando presentano architetture differenti.

2.9.4 Implicazioni di sicurezza

La presenza di attacchi adversariali solleva importanti questioni relative all'affidabilità dei sistemi basati su machine learning, soprattutto quando tali sistemi vengono utilizzati in contesti critici per la sicurezza.

In ambito cybersecurity e digital forensics, i modelli di deep learning sono sempre più utilizzati per analizzare automaticamente grandi volumi di dati, come immagini, traffico di rete e artefatti digitali. Tuttavia, la vulnerabilità di questi sistemi alle perturbazioni adversariali può consentire agli attaccanti di manipolare i risultati delle analisi automatiche o di eludere i sistemi di rilevazione.

Per questo motivo, la valutazione sistematica della robustezza dei modelli di machine learning rappresenta oggi una delle principali sfide di ricerca nel campo della sicurezza dei sistemi intelligenti.

2.10 Immagini adversariali e tecniche di perturbazione

Le immagini *adversariali* sono input visivi manipolati in maniera impercettibile all'occhio umano, ma costruiti con precisione matematica per indurre in errore i modelli di classificazione automatica. Tali perturbazioni, anche se minime, possono compromettere la predizione del modello, alterando l'esito di un'analisi investigativa basata su AI [goodfellow2014explaining].

Nel contesto della **digital forensics**, queste tecniche assumono un duplice ruolo:

- come strumenti di **anti-forensics**, utilizzati per ostacolare l'attribuzione, la rilevazione automatica o la ricostruzione dei contenuti;
- come **minacce alla robustezza** dei sistemi AI-based, che devono dimostrare affidabilità anche in presenza di input alterati in modo intenzionale.

2.10.1 Concetti fondamentali negli attacchi adversariali

Nel contesto della visione artificiale e, più in generale, dell'apprendimento automatico, gli *attacchi adversariali* consistono nella generazione intenzionale di input modificati in modo da indurre un modello a produrre una predizione errata. Tali modifiche sono spesso impercettibili all'osservatore umano, ma risultano efficaci nello sfruttare la sensibilità dei modelli di *deep learning* a variazioni specifiche nello spazio delle feature [goodfellow2014explaining, 44].

White-box vs. Black-box Una prima distinzione tra tipologie di attacco si basa sul livello di conoscenza che l'attaccante possiede del modello bersaglio:

- **White-box:** l'attaccante ha accesso completo all'architettura, ai pesi e alla funzione di perdita del modello. Questo scenario consente l'utilizzo di tecniche basate su gradienti (es. FGSM, SuperDeepFool), capaci di generare perturbazioni ad alta efficacia e bassa entropia visiva.
- **Black-box:** l'attaccante non dispone di informazioni interne sul modello, ma può inviare input e osservare le uscite. Gli attacchi black-box si basano su approcci euristici, di ottimizzazione evolutiva o su *transfer attacks* da modelli surrogate [papernot2017practical].

Targeted vs. Untargeted Gli attacchi adversariali possono essere ulteriormente classificati in base all'obiettivo della manipolazione:

- **Targeted:** la perturbazione è progettata per indurre il modello a classificare l'input in una classe specifica scelta dall'attaccante (es. un'immagine di pistola classificata come "cellulare").
- **Untargeted:** l'obiettivo è semplicemente quello di far produrre al modello una predizione errata, senza controllo diretto sulla classe di uscita (es. pistola classificata come qualsiasi oggetto non-arma).




Figure 2.6: Fasi generali di un attacco adversarial: dal calcolo o stima del gradiente, alla generazione e applicazione della perturbazione, fino all’analisi della predizione.

Rilevanza in ambito forense Nel contesto della *digital forensics*, la distinzione tra white-box e black-box è particolarmente rilevante poiché molti strumenti commerciali basati su AI operano come *black-box proprietarie*, accessibili solo tramite interfacce o moduli interni. Allo stesso modo, la distinzione targeted/untargeted permette di inquadrare meglio scenari reali: dagli attacchi mirati a nascondere specifiche tipologie di contenuto (targeted), fino a perturbazioni generalizzate per degradare l’accuratezza complessiva di un sistema (untargeted) [nowroozi2024robustness, 36].

Questo quadro concettuale consente di interpretare le tecniche adottate in questo lavoro sperimentale, che includono attacchi white-box (FGSM, SuperDeepFool) e black-box (One Pixel Attack, Sigma Zero Attack), nonché trasformazioni anti-forensi a carattere più “naturale” (Color Shifting, JPEG Recompression, ecc.), alcune delle quali possono essere impiegate sia in scenari

targeted che untargeted.

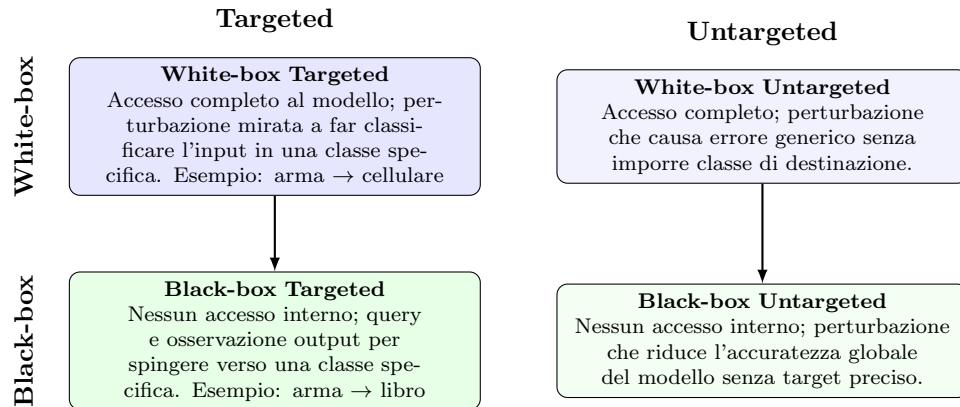


Figure 2.7: Classificazione degli attacchi adversariali in base alla conoscenza del modello (white-box vs black-box) e all'obiettivo (targeted vs untargeted).

In questo lavoro sono state selezionate e sperimentate dieci tecniche di perturbazione, suddivise in due categorie distinte:

- **Adversarial attacks**, ottimizzati per ingannare il classificatore;
- **Anti-forensic transformations**, orientate a degradare o alterare l'input in maniera semantica o strutturale.

La Tabella 2.5 sintetizza le tecniche adottate, descrivendone il meccanismo, l'obiettivo e il livello di visibilità.

Tipo	Tecnica	Meccanismo	Obiettivo	Riferimento	Visibilità
Anti-forense	JPEG Recompression	Ricomprensione lossy	Degradare i coefficienti DCT e ostacolare l'analisi	[45]	Media
Anti-forense	Resample & Resize	Interpolazione / ridimensionamento	Falsare PRNU o scala per ridurre l'attribuibilità	[46]	Media
Anti-forense	Gaussian Blur	Sfocatura spaziale	Offuscare bordi e dettagli utili alla classificazione	[7]	Media
Anti-forense	Histogram Modification	Alterazione istogramma	Cambiare la distribuzione dei colori per ingannare il modello	[phd'unisi'0	Variabile
Anti-forense	Contrast Stretching	Espansione del contrasto	Mascherare o enfatizzare pattern visivi locali	[phd'unisi'0	Media
Adversarial	FGSM	Gradiente singolo	Indurre errore con minima perturbazione	[goodfellow'	Bassa
Adversarial	SuperDeepFool	Ottimizzazione iterativa	Spostare l'input oltre il confine decisionale del modello	[47]	Bassa
Adversarial	One Pixel Attack	Ottimizzazione evolutiva	Forzare errore modificando un solo pixel	[48]	Molto bassa
Adversarial	Sigma Zero Attack	Sparsity-based, black-box	Evasione stealth in scenari realistici con accesso limitato	[phd'unisi'0	Bassa
Adversarial	Color Shifting	Alterazione HSV / RGB	Simulare modifiche cromatiche plausibili	[phd'unisi'0	Media

Table 2.5: Confronto tra tecniche di perturbazione anti-forense e adversarial: meccanismo, obiettivo, visibilità.

2.10.2 Applicazioni forensi

Nel contesto della digital forensics, le immagini adversariali assumono un ruolo controverso, potendo essere impiegate sia per ostacolare le indagini, sia per tutelare diritti fondamentali come la privacy. Le principali applicazioni si possono ricondurre a due scenari contrapposti:

- **Attacchi anti-forensi:** l'obiettivo è eludere o compromettere i sistemi automatizzati di classificazione basati su AI. Ad esempio, un'immagine contenente un'arma da fuoco potrebbe essere intenzionalmente perturbata affinché venga identificata come oggetto neutro, invalidando il riconoscimento automatizzato e compromettendo l'integrità delle prove raccolte [goodfellow2014explaining, 36, 49].
- **Difesa della privacy:** in scenari di sorveglianza diffusa o analisi automatizzata non

autorizzata, le perturbazioni avversariali possono essere utilizzate per impedire la corretta identificazione di volti, oggetti o contesti sensibili. In questo senso, l'adversarial machine learning diventa uno strumento di *resistenza etica* e *privacy by design*, orientato alla protezione dei dati personali contro analisi invasive [36, 48].

Queste due prospettive evidenziano una tensione irrisolta tra esigenze investigative e tutela dei diritti digitali. Inoltre, sollevano interrogativi cruciali sulla **robustezza** e **affidabilità** dei sistemi AI impiegati nei contesti forensi, la cui vulnerabilità a input manipolati può compromettere l'intero processo probatorio. Tali aspetti saranno analizzati in dettaglio nei capitoli successivi.

2.11 Robustezza dei Sistemi AI-based

Nel contesto della digital forensics, la robustezza dei sistemi basati su Intelligenza Artificiale rappresenta un requisito fondamentale, specialmente quando tali sistemi sono impiegati per l'analisi automatica di contenuti sensibili o potenzialmente manipolati. Un modello AI è considerato *robusto* se è in grado di mantenere prestazioni affidabili anche in presenza di perturbazioni non previste, input degradati o veri e propri attacchi avversariali.

Secondo Biggio e Roli [36], la crescente dipendenza da modelli di deep learning in scenari critici ha reso la robustezza una priorità progettuale, sia in ambito di sicurezza informatica che forense. Un sistema robusto dovrebbe idealmente:

- **Mantenere l'accuratezza** predittiva anche in presenza di rumore, distorsioni o attacchi mirati;
- **Garantire trasparenza e tracciabilità** del processo decisionale, a supporto dell'ammissibilità probatoria in sede giudiziaria;
- **Essere verificabile e riproducibile** tramite tecniche di validazione esterna e testing controllato.

2.11.1 Contromisure e difese

Negli ultimi anni sono state sviluppate numerose strategie per aumentare la resilienza dei modelli AI contro manipolazioni intenzionali. Tali difese possono essere classificate in base all'approccio (proattivo, reattivo, formale) e al livello d'integrazione nel sistema.

Tra le principali contromisure si annoverano [16, 36]:

- **Adversarial Training:** consiste nell'arricchire il dataset di addestramento con esempi perturbati in modo controllato, costringendo il modello a riconoscere e ignorare tali deviazioni.
- **Certified Defenses:** approcci formali che garantiscono, tramite bounding geometrico o analisi matematica, che il modello rimane invariato entro determinati limiti di perturbazione (es. norme L_∞ , L_2).
- **Preprocessing degli input:** tecniche come compressione JPEG, denoising e normalizzazione spaziale mirano a "ripulire" l'input prima della classificazione, riducendo l'effetto delle perturbazioni.
- **Rilevatori avversariali:** moduli secondari addestrati per riconoscere input sospetti tramite metodi statistici, inconsistenze semantiche o reti autoencoder.

Nonostante l'efficacia parziale di questi approcci, **nessuna difesa risulta universalmente efficace**. La combinazione di più strategie (approccio ensemble) e la validazione su scenari realistici rimangono essenziali nei contesti ad alta criticità, come quelli forensi.

La Tabella 2.6 riassume e confronta le principali difese disponibili.

Tecnica di difesa	Descrizione	Vantaggi	Limiti
Adversarial Training	Addestramento con esempi perturbati per migliorare la resilienza del modello.	Robustezza diretta contro pattern noti; facile da implementare.	Può ridurre l'accuratezza su dati puliti; non generalizza bene.
Certified Defenses	Tecniche formali che garantiscono la robustezza entro certe perturbazioni.	Offre garanzie teoriche utili in ambito forense.	Alto costo computazionale; limitato a modelli semplici.
Preprocessing degli input	Rimozione delle perturbazioni tramite compressione, denoising, ecc.	Compatibile con modelli esistenti; implementazione leggera.	Poco efficace contro attacchi invisibili sofisticati.
Rilevatori avversariali	Moduli aggiuntivi per identificare input avversari.	Non richiede modifica del modello principale.	Falsi positivi elevati; vulnerabilità ad attacchi adattivi.

Table 2.6: Confronto tra principali tecniche di difesa contro input avversariali.

2.12 Criticità probatorie nell'uso di AI nella Digital Forensics

Nonostante l'enorme potenziale operativo degli strumenti AI-based nella digital forensics, la loro applicazione in ambito giudiziario solleva interrogativi cruciali sul piano della validità probatoria. Modelli di classificazione automatica non robusti, opachi o vulnerabili ad attacchi mirati rappresentano un rischio concreto per l'integrità del processo, specialmente se le loro decisioni influenzano la selezione, l'interpretazione o l'esclusione di evidenze digitali.

L'integrazione di tali strumenti deve confrontarsi con i principi fondamentali del giusto processo, tra cui:

- il diritto alla verifica e alla contestazione tecnica (principio del contraddittorio);
- l'onere della prova e la riproducibilità delle analisi;
- la tutela dalla manipolazione dell'evidenza, anche in forma digitale.

In particolare, l'utilizzo di modelli "black-box" suscita preoccupazioni rispetto alla loro trasparenza, spiegabilità e affidabilità. Le tecniche avversariali e anti-forensi descritte nei capitoli successivi mostrano come sia possibile alterare in modo impercettibile un'immagine o un contenuto, inducendo il sistema AI a classificazioni errate, potenzialmente fuorvianti in ambito giudiziario.

Alla luce di tali considerazioni, questo lavoro sperimentale mira a valutare empiricamente la **robustezza operativa** di alcuni tra i principali strumenti AI per la classificazione automatica di immagini in ambito forense, esponendoli a perturbazioni realistiche e osservandone l'impatto sulle decisioni del sistema.

2.13 Conclusioni critiche

L'analisi condotta mette in evidenza come la validità e l'ammissibilità della **prova digitale** non possano essere considerate esclusivamente una questione tecnica, ma debbano essere inquadrare all'interno di un solido quadro giuridico. La disciplina della *Computer Law*, nelle sue declinazioni nazionali, europee e internazionali, evidenzia come l'integrità, l'autenticità, l'affidabilità e la pertinenza dell'evidenza costituiscano condizioni imprescindibili per il suo utilizzo processuale.

Parallelamente, l'introduzione crescente di **sistemi AI-based** nella digital forensics apre nuove prospettive ma anche rischi significativi. La possibilità che un modello vulnerabile a bias o attacchi avversariali generi classificazioni errate pone il problema della **robustezza tecnica** come condizione di validità giuridica. In tal senso, la Cassazione ha richiesto una *motivazione rafforzata* per l'impiego di prove digitali, mentre il legislatore europeo — attraverso il GDPR e l'AI Act — ha imposto requisiti di trasparenza, spiegabilità e tracciabilità delle decisioni algoritmiche.

Ne deriva la necessità di un **approccio integrato tecnico-legale**, che combini le garanzie probatorie tradizionali (catena di custodia, standard ISO, convenzioni internazionali) con nuovi requisiti derivanti dall'uso dell'intelligenza artificiale (robustezza, accountability, explainability). Così come il diritto processuale impone che il giudice motivi adeguatamente le decisioni fondate su dati digitali, la comunità scientifica e normativa richiede oggi che i sistemi AI siano spiegabili, verificabili e sottoponibili a controllo esterno.

In conclusione, il parallelismo tra **solidità giuridica della prova** e **robustezza tecnica del modello AI** rappresenta la chiave di volta per garantire l'ammissibilità e la credibilità delle evidenze digitali in sede giudiziaria. Questo lavoro di ricerca si colloca esattamente in tale prospettiva, proponendo una valutazione sperimentale della robustezza operativa di strumenti AI-based in ambito forense, al fine di contribuire alla costruzione di un modello probatorio affidabile e conforme ai principi del giusto processo.

Appendix A

Repository and Reproducibility Artifacts

Questa appendice raccoglie gli elementi tecnici necessari a documentare la riproducibilità del lavoro sperimentale. Il codice sorgente completo non viene riportato integralmente nel documento, ma è mantenuto nella repository associata alla tesi. Le sezioni seguenti descrivono la struttura logica del progetto, gli artefatti sperimentali principali, i manifest ufficiali, i meccanismi di tracciabilità, i comandi essenziali di esecuzione e alcuni esempi rappresentativi di output. Tale scelta consente di preservare la leggibilità della tesi, evitando la duplicazione integrale dei file sorgente e mantenendo il codice nella sede più adatta alla sua consultazione, verifica e aggiornamento.

A.1 Struttura della repository

La repository è organizzata in modo modulare, separando i dati grezzi, gli artefatti preparati, i manifest finali, gli split sperimentali, gli script della pipeline, gli output di valutazione e la documentazione della tesi. Tale organizzazione consente di distinguere chiaramente tra dati di input, fasi di trasformazione, artefatti congelati e risultati sperimentali.

```
1 msc-thesis-ai-robustness-in-digital-forensics/  
2   datasets/  
3     raw/  
4     prepared/  
5     final/  
6     splits/  
7     forensic_evaluation_bundle/  
8   datasets/scripts/  
9     prepared/  
10    final/  
11    splits/  
12    bundle/  
13  attacks/  
14    adversarial/  
15    anti_forensic/  
16  evaluation/  
17    clean/  
18    adversarial/  
19    anti_forensic/  
20    forensic_tools/  
21  explainability/  
22    outputs/  
23    manifests/  
24  results/  
25    metrics/  
26    tables/  
27    plots/
```



```

28     figures/
29     reports/
30 docs/
31     LatexThesis_ITA/

```

Listing A.1: Struttura semplificata della repository sperimentale.



Figure A.1: QR code per l'accesso diretto alla repository GitHub della tesi.

A.2 Artefatti sperimentali principali

La Tabella A.1 riassume i principali artefatti sperimentali utilizzati nella pipeline. Tali file costituiscono il riferimento operativo per la ricostruzione del dataset, la generazione degli split, la valutazione dei modelli e la predisposizione del bundle destinato agli strumenti forensi.

Table A.1: Principali artefatti sperimentali della pipeline.

Artefatto	Ruolo nella pipeline
<code>manual_selection_final_1500.csv</code>	Manifest ufficiale del dataset frozen, composto da 1500 immagini bilanciate nelle classi weapon , non_weapon e OOD.
<code>manual_selection_adversarial_subset.csv</code>	Manifest del subset binario utilizzato per gli esperimenti adversariali e anti-forensi, composto dalle sole classi weapon e non_weapon .
<code>manual_selection_protocol_db.csv</code>	Database operativo del protocollo di selezione manuale <i>human-in-the-loop</i> .
<code>manual_selection_removed.csv</code>	Manifest dei campioni esclusi durante la selezione finale.
<code>clean_folds_manifest.csv</code>	Manifest degli split puliti utilizzati per la valutazione baseline dei modelli.
<code>ood_eval_manifest.csv</code>	Manifest del set OOD utilizzato per la valutazione fuori distribuzione.
<code>bundle_manifest.csv</code>	Manifest globale del bundle di valutazione destinato agli strumenti forensi.
<code>bundle_hashes_sha256.csv</code>	File contenente gli hash SHA256 degli artefatti inclusi nel bundle forense.

A.3 Ambiente software e librerie utilizzate

La pipeline sperimentale è stata implementata prevalentemente in Python, utilizzando librerie per la gestione dei dati, l'elaborazione delle immagini, l'esecuzione dei modelli e la produzione degli output sperimentali. La Tabella A.2 riassume i principali strumenti software impiegati.

Table A.2: Principali librerie e strumenti software utilizzati nella pipeline sperimentale.

Libreria / Strumento	Funzione principale
Python	Linguaggio principale per la costruzione della pipeline sperimentale.
pandas	Gestione dei manifest, dei metadati e dei risultati sperimentali.
NumPy	Gestione numerica di array, immagini e matrici di perturbazione.
Pillow	Validazione, apertura e trasformazione delle immagini.
OpenCV	Elaborazione di immagini e applicazione di trasformazioni anti-forensi.
PyTorch	Esecuzione dei modelli neurali e generazione di alcune perturbazioni adversariali.
scikit-learn	Addestramento e valutazione della baseline SVM e calcolo delle metriche.
matplotlib	Produzione di grafici, curve e figure sperimentali.
CLIP	Classificazione zero-shot e confronto semantico immagine-testo.
BLIP	Captioning e analisi multimodale delle immagini.

A.4 Manifest, hash e tracciabilità

La tracciabilità degli artefatti sperimentali è garantita attraverso l'uso sistematico di manifest e hash crittografici. Ogni immagine viene associata a metadati tecnici e semantici che consentono di collegare il campione alla sorgente originaria, alla classe assegnata, allo split sperimentale, all'eventuale versione perturbata e agli output prodotti dai modelli o dagli strumenti forensi.

Il calcolo degli hash SHA256 costituisce un elemento centrale della pipeline, poiché consente di verificare l'identità dei file, individuare duplicati e mantenere un collegamento stabile tra immagini pulite, immagini trasformate e risultati sperimentali. Nel bundle di valutazione forense, gli hash rappresentano inoltre il principale criterio di raccordo tra gli artefatti importati nei tool professionali e gli output esportati dagli stessi strumenti.

A.5 Comandi principali per la riproducibilità

La pipeline sperimentale è organizzata in script separati, ciascuno dedicato a una fase specifica del workflow. Il Listato A.2 riporta la sequenza logica principale per ricostruire gli artefatti del dataset e predisporre il bundle di valutazione forense.

```

1 python datasets/scripts/prepared/08_build_prepared_dataset.py
2 python datasets/scripts/prepared/09_generate_review_manifest_full.py
3 python datasets/scripts/final/10_manual_selection_protocol_reviewer.py
4 python datasets/scripts/splits/11_generate_clean_and_ood_splits.py
5 python datasets/scripts/bundle/12_build_forensic_evaluation_bundle.py

```

Listing A.2: Sequenza principale di esecuzione della pipeline dataset.

A.6 Esempi di log e output

Durante l'esecuzione della pipeline, gli script producono log e report intermedi utili a verificare la correttezza delle operazioni effettuate. Il Listato A.3 mostra un esempio schematico di output relativo alla fase di preparazione tecnica del dataset.

```

1 [INFO] Scanning raw dataset sources...
2 [INFO] Valid images detected: ...
3 [INFO] Invalid images discarded: ...
4 [INFO] SHA256 hashes computed: ...
5 [INFO] Global duplicates removed: ...
6 [INFO] Prepared image pool written to datasets/prepared/final_pool/images/

```

```
7 [INFO] Metadata written to datasets/prepared/final_pool/metadata.csv
```

Listing A.3: Esempio schematico di output della fase di preparazione del dataset.

A.7 Repository e disponibilità del codice

Il codice completo utilizzato per la costruzione del dataset, la generazione degli split, la produzione delle perturbazioni, l'esecuzione delle valutazioni e la raccolta dei risultati è mantenuto nella repository associata alla tesi. La repository contiene inoltre i manifest principali, gli script della pipeline e la documentazione operativa necessaria alla riproduzione del workflow sperimentale.

- **Repository GitHub:** <https://github.com/lmolinario/msc-thesis-ai-robustness-in-digital-forensics>
- **Manifest ufficiale del dataset frozen:** `datasets/final/manifests/manual_selection_final_1500.csv`
- **Manifest del subset adversarial:** `datasets/final/manifests/manual_selection_adversarial_subset.csv`
- **Licenza:** da definire nella repository finale.

References

- [1] Simson L Garfinkel. ‘Digital forensics research: The next 10 years’. In: *Digital Investigation* 7 (2010), S64–S73.
- [2] Eoghan Casey. *Digital Evidence and Computer Crime: Forensic Science, Computers, and the Internet*. Academic Press, 2011.
- [3] Gary Palmer. *A Road Map for Digital Forensic Research*. Tech. rep. Digital Forensic Research Workshop (DFRWS), 2001.
- [4] Matthew Reith, Clint Carr and Gregory Gunsch. ‘Examining the computer forensic process model’. In: *International Journal of Digital Evidence* 1.3 (2002), pp. 1–9.
- [5] K. Kent et al. *Guide to Integrating Forensic Techniques into Incident Response*. Tech. rep. SP 800-86. NIST, 2006. URL: <https://nvlpubs.nist.gov/nistpubs/Legacy/SP/nistspecialpublication800-86.pdf>.
- [6] International Organization for Standardization. *ISO/IEC 27037:2012 – Guidelines for identification, collection and preservation of digital evidence*. <https://www.iso.org/standard/44381.html>. Accessed: 2025-06-13. 2012.
- [7] Stefania Costantini, Giovanni De Gasperis and Raffaele Olivieri. ‘Digital Forensics and Investigations Meet Artificial Intelligence’. In: *Annals of Mathematics and Artificial Intelligence* 86.1 (2019), pp. 193–229. DOI: 10.1007/s10472-019-09632-y.
- [8] Jonathan Clough. *Principles of Cybercrime*. Cambridge University Press, 2015.
- [9] Silvia Lucia Sanna et al. *Exploring the Robustness of AI-Driven Tools in Digital Forensics: A Preliminary Study*. Preprint submitted to Digital Forensics Research Conference Europe 2025. 2024. DOI: 10.48550/arXiv.2412.01363. arXiv: 2412.01363 [cs.CV].
- [10] Silvia Lucia Sanna et al. ‘Pixel Perfect or Perfectly Fake? Exploring the Robustness of Digital Forensic Tools Against Facial Deepfakes and Morphed Images’. In: *Proceedings of the 33rd European Signal Processing Conference (EUSIPCO 2025)*. Preprint / conference paper. Cagliari, Italy, 2025.
- [11] Silvia Lucia Sanna et al. ‘Improving Cybercrime Detection and Digital Forensics Investigations with Artificial Intelligence’. In: *APWG-EU 2025: Tech Summit and Researchers Forum*. Conference paper. Cagliari, Italy, 2025.
- [12] A. Adadi and M. Berrada. ‘Peeking inside the black-box: A survey on Explainable Artificial Intelligence (XAI)’. In: *IEEE Access* 6 (2018), pp. 52138–52160.
- [13] F. Doshi-Velez and B. Kim. ‘Towards a rigorous science of interpretable machine learning’. In: *arXiv preprint arXiv:1702.08608* (2017).
- [14] Ian J Goodfellow, Jonathon Shlens and Christian Szegedy. ‘Explaining and harnessing adversarial examples’. In: *arXiv preprint arXiv:1412.6572* (2015).
- [15] Nicolas Papernot et al. ‘The limitations of deep learning in adversarial settings’. In: *2016 IEEE European Symposium on Security and Privacy (EuroS&P)* (2016), pp. 372–387.
- [16] Nicholas Carlini and David Wagner. ‘Towards evaluating the robustness of neural networks’. In: *IEEE Symposium on Security and Privacy (SP)*. IEEE. 2017, pp. 39–57. DOI: 10.1109/SP.2017.49.

-
- [17] Xiaoyong Yuan et al. ‘Adversarial Examples: Attacks and Defenses for Deep Learning’. In: *IEEE Transactions on Neural Networks and Learning Systems* 30.9 (2019), pp. 2805–2824. DOI: 10.1109/TNNLS.2018.2886017.
 - [18] Ehsan Nowroozi. ‘Machine Learning Techniques for Image Forensics in Adversarial Setting’. PhD thesis. University of Siena, 2020.
 - [19] Mauro Barni, Ehsan Nowroozi and Benedetta Tondi. ‘Adversarial attacks against deep neural network-based image forensics’. In: *2018 25th IEEE International Conference on Image Processing (ICIP)* (2018), pp. 3758–3762.
 - [20] Matthew C. Stamm, Min Wu and K. J. Ray Liu. ‘Information Forensics: An Overview of the First Decade’. In: *IEEE Access* 1 (2013), pp. 167–200. DOI: 10.1109/ACCESS.2013.2260814.
 - [21] Ehsan Nowroozi et al. ‘Verifying the Robustness of Machine Learning based Intrusion Detection Against Adversarial Perturbation’. In: *TechRxiv Preprint* (2024). DOI: 10.36227/techrxiv.172297438.84425389/v1.
 - [22] Dan Hendrycks and Thomas G. Dietterich. ‘Benchmarking neural network robustness to common corruptions and perturbations’. In: *International Conference on Learning Representations (ICLR)*. 2019. URL: <https://openreview.net/forum?id=HJz6tiCqYm>.
 - [23] Francesco Croce and Matthias Hein. ‘RobustBench: A standardized adversarial robustness benchmark’. In: *arXiv preprint arXiv:2010.09670* (2020). URL: <https://arxiv.org/abs/2010.09670>.
 - [24] Raed S. A. Faqir. ‘Digital Criminal Investigations in the Era of Artificial Intelligence: A Comprehensive Overview’. In: *International Journal of Cyber Criminology* 17.2 (2023), pp. 77–94.
 - [25] Jean-Paul A. Yaacoub et al. ‘Digital forensics vs. anti-digital forensics: Techniques, limitations and recommendations’. In: *arXiv preprint arXiv:2103.17028* (2021).
 - [26] *Codice di procedura penale*. D.P.R. 22 settembre 1988, n. 447. Repubblica Italiana, 1988.
 - [27] *Regulation (EU) 2024/1689 laying down harmonised rules on Artificial Intelligence (AI Act)*. European Union, 2024.
 - [28] Scientific Working Group on Digital Evidence. *SWGDE Best Practices and Guidelines*. <https://www.swgde.org/documents>. Accessed: 2025-06-13. 2023.
 - [29] Michael Hewling. ‘Towards a Legal and Forensic Framework for Cloud Computing’. In: *Digital Investigation* 10.4 (2013), pp. 295–305. DOI: 10.1016/j.diin.2013.09.003.
 - [30] Daniele Gambini. *Informatica Giuridica e Informatica Forense*. Maggioli Editore, 2019. ISBN: 9788891639082.
 - [31] Paul Voigt and Axel Von dem Bussche. *The EU General Data Protection Regulation (GDPR): A Practical Guide*. Springer, 2017.
 - [32] Mariangela Biasiotti and Federica Turchi. ‘Handling and Exchanging Electronic Evidence Across Different Jurisdictions’. In: *Handling and Exchanging Electronic Evidence Across Different Jurisdictions*. IGI Global, 2018.
 - [33] European Network of Forensic Science Institutes. *ENFSI Forensic IT Working Group - Best Practice Manual*. <https://enfsi.eu/documents/>. Accessed: 2025-06-13. 2022.
 - [34] *Convention on Cybercrime (Budapest Convention)*. <https://www.coe.int/en/web/conventions/full-list/-/conventions/treaty/185>. Council of Europe, ETS No.185. 2001.
 - [35] M.K. Rogers and K.C. Seigfried-Spellar. ‘AI and Digital Forensics: Emerging Challenges’. In: *Digital Investigation* 32 (2020), p. 200905. DOI: 10.1016/j.diin.2020.200905.
 - [36] Battista Biggio and Fabio Roli. ‘Wild Patterns: Ten Years After the Rise of Adversarial Machine Learning’. In: *Pattern Recognition* 84 (2018), pp. 317–331. DOI: 10.1016/j.patcog.2018.07.023.
 - [37] Brian Carrier. *File System Forensic Analysis*. Addison-Wesley, 2005. ISBN: 9780321268174.
-

-
- [38] *Good Practice Guide for Digital Evidence*. <https://www.digital-detective.net/digital-evidence-good-practice-guide/>.
- [39] FYND Academy. *Chain of Custody in Cyber Security*. <https://www.fynd.academy/blog/chain-of-custody-in-cyber-security>. Accessed June 14, 2025. 2024.
- [40] Thanh T. Le and Hien V. Nguyen. ‘A Survey on Deep Learning Applications for Cyber Forensics’. In: *Forensic Science International: Reports* 2 (2020), p. 100114. DOI: 10.1016/j.fsir.2020.100114.
- [41] Jennifer Lawrence and Z. Tang. ‘Facial Recognition in Forensic Investigations’. In: *IEEE Access* 8 (2020), pp. 140196–140210. DOI: 10.1109/ACCESS.2020.3011417.
- [42] E. Brown and S. Choi. ‘AI-based Anomaly Detection for System Log Analysis’. In: *Journal of Digital Forensics, Security and Law* 18.1 (2023), pp. 44–56.
- [43] *Magnet Axiom*. <https://www.magnetforensics.com/products/axiom/>. Accessed 2025.
- [44] Christian Szegedy et al. ‘Intriguing Properties of Neural Networks’. In: *arXiv preprint arXiv:1312.6199* (2013). <https://arxiv.org/abs/1312.6199>.
- [45] Shawn Shan et al. ‘Fawkes: Protecting privacy against unauthorized deep learning models’. In: *USENIX Security Symposium*. 2020.
- [46] Bastian Hewling and Jörg Schwenk. ‘Anti-Forensics: Furthering Digital Investigation’. In: *Proceedings of the ADFSL Conference on Digital Forensics, Security and Law*. 2018.
- [47] Alireza Abdolapourrostam, Mahed Abroshan and Seyed-Mohsen Moosavi-Dezfooli. ‘SuperDeepFool: A New Fast and Accurate Minimal Adversarial Attack’. In: *Advances in Neural Information Processing Systems 37 (NeurIPS 2024)*. Poster presentation. 2024. URL: <https://openreview.net/forum?id=pqD7ckR8AF>.
- [48] Jiawei Su, Danilo Vargas and Kouichi Sakurai. ‘One pixel attack for fooling deep neural networks’. In: *IEEE Transactions on Evolutionary Computation* 23.5 (2019), pp. 828–841.
- [49] Seyed-Mohsen Moosavi-Dezfooli, Alhussein Fawzi and Pascal Frossard. ‘DeepFool: a simple and accurate method to fool deep neural networks’. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition* (2016), pp. 2574–2582.