



UNIVERSITY OF CAGLIARI

Department of Engineering

MASTER'S DEGREE IN "COMPUTER ENGINEERING,
CYBERSECURITY AND ARTIFICIAL INTELLIGENCE"

**Experimental Evaluation of the Robustness of
AI-Based Forensic Tools for Automated Image
Classification Under Adversarial and
Anti-Forensic Attacks**

Advisor:

Prof. Davide Maiorca

Co-Advisor:

PhD Silvia Lucia Sanna

Author:

Lello Molinaro

Academic Year 2025/2026
Cagliari

Table of Contents

List of Figures	iii
List of Tables	v
1 Introduzione	1
1.1 Digitalizzazione, minacce e centralità della Digital Forensics	1
1.2 Automazione dell'analisi forense e ruolo dell'AI	2
1.3 Robustezza dei sistemi basati su AI e minacce avversariali e anti-forensi	2
1.4 Problema di ricerca e rilevanza in scenari forensi realistici	3
1.5 Obiettivi della ricerca	4
1.6 Contributo della tesi	4
1.7 Rilevanza tecnico-forense e profili di affidabilità probatoria	5
1.8 Struttura della tesi	6
2 Technical Background Concepts	8
2.1 Digital Forensics e prova digitale	8
2.2 Artificial Intelligence nella Digital Forensics	9
2.3 Image Forensics e classificazione automatica	10
2.4 Machine Learning e Deep Learning per la Computer Vision	12
2.5 Adversarial Machine Learning	13
2.5.1 Threat model e assunzioni dell'attaccante	15
2.6 Tecniche anti-forensi su immagini digitali	16
2.7 Explainability, robustezza e affidabilità dei modelli	18
2.8 Profili giuridici e normativi dell'AI in ambito forense	20
3 State of the Art	23
3.1 Digital Forensics: tecniche e pratiche attuali	23
3.2 AI nella Digital Forensics: strumenti e applicazioni	27
3.3 Perturbazioni e attacchi avversariali su immagini	29
3.4 Robustezza e contromisure	33
3.4.1 Explainable Artificial Intelligence (XAI)	34
3.5 Limiti della letteratura esistente e contributo della presente tesi	37
3.6 Sintesi comparativa dei contributi scientifici	38
A Repository and Reproducibility Artifacts	40
A.1 Struttura della repository	40
A.2 Artefatti sperimentali principali	41
A.3 Ambiente software e librerie utilizzate	41
A.4 Manifest, hash e tracciabilità	42
A.5 Comandi principali per la riproducibilità	42
A.6 Esempi di log e output	42
A.7 Repository e disponibilità del codice	43
References	44

List of Figures

2.1	Simplified digital forensic workflow.	9
2.2	AML and conceptual representation of an evasion attack	14
3.1	Principali applicazioni dell'Intelligenza Artificiale nella Digital Forensics	27
3.2	Schema semplificato di generazione di un input avversario. A partire da un'immagine pulita x , viene calcolata una perturbazione δ tale che l'input risultante $x^* = x + \delta$ induca il classificatore $f(\cdot)$ a produrre una predizione errata, mantenendo la distanza percettiva tra x e x^* minima.	32
3.3	Principali categorie di difesa contro attacchi avversariali: vantaggi e limiti in contesto forense.	37
A.1	QR code per l'accesso diretto alla repository GitHub della tesi.	41

List of Tables

2.1	Threat model dimensions considered in the experimental robustness evaluation. .	17
2.2	Comparison between adversarial attacks and anti-forensic transformations in the context of automated image classification.	19
3.1	Principi fondamentali della Digital Forensics secondo gli standard internazionali .	24
3.2	Fasi operative del processo di Digital Forensics	25
3.3	Sintesi dei principali contributi in letteratura sulla robustezza del Machine Learning in ambito forense	39
A.1	Principali artefatti sperimentali della pipeline.	41
A.2	Principali librerie e strumenti software utilizzati nella pipeline sperimentale. . . .	42

Chapter 1

Introduzione

1.1 Digitalizzazione, minacce e centralità della Digital Forensics (DF)

La progressiva digitalizzazione della società contemporanea ha trasformato in profondità le modalità con cui le informazioni vengono prodotte, archiviate, trasmesse e analizzate. Infrastrutture cloud, servizi distribuiti, dispositivi mobili interconnessi, piattaforme sociali e sistemi informativi eterogenei generano oggi una quantità crescente di dati digitali, che assumono un ruolo sempre più rilevante sia nella vita quotidiana sia nelle attività professionali, istituzionali e giudiziarie. Tale evoluzione ha ampliato in modo significativo anche la superficie d'attacco dei sistemi informatici, aumentando le opportunità di sfruttamento da parte di soggetti ostili e moltiplicando i possibili punti di compromissione delle evidenze digitali [1, 2].

Parallelamente alle opportunità offerte dall'innovazione tecnologica, si sono affermate minacce sempre più sofisticate, caratterizzate da elevata eterogeneità tecnica e da una crescente capacità di occultamento. Tra queste rientrano l'esfiltrazione e la manipolazione dei dati, l'alterazione di file multimediali, la cancellazione selettiva delle tracce, l'impiego di tecniche di anonimizzazione e, più in generale, tutte quelle pratiche che mirano a ostacolare la ricostruzione attendibile degli eventi. In un simile scenario, la DF assume un ruolo centrale quale disciplina deputata all'identificazione, acquisizione, preservazione, analisi e presentazione dell'evidenza digitale secondo criteri di rigore metodologico, integrità e verificabilità [3, 4, 5, 6].

Secondo la definizione comunemente richiamata in letteratura, la DF costituisce l'applicazione di metodi scientifici e procedure tecniche finalizzate a rendere i dati digitali utilizzabili come elementi di prova in un contesto investigativo o giudiziario [3]. Tale impostazione richiede che ogni fase del processo sia condotta in modo tracciabile, ripetibile e difendibile, affinché il risultato dell'analisi non sia soltanto tecnicamente corretto, ma anche sostenibile sotto il profilo probatorio. In termini operativi, il processo forense viene comunemente ricondotto a una sequenza di fasi che comprende identificazione, acquisizione, conservazione, analisi e presentazione dell'evidenza, tutte accomunate dall'esigenza di garantire integrità, trasparenza e verificabilità [4, 5]. Questa esigenza diventa particolarmente rilevante nei casi in cui le evidenze risultino distribuite su molteplici dispositivi, conservate in ambienti virtualizzati, presenti in forma volatile oppure esposte a manipolazioni intenzionali [5, 6].

La crescente incidenza dei reati informatici e, più in generale, il ruolo ormai pervasivo delle tecnologie digitali nella commissione e nella documentazione dei reati hanno consolidato la funzione della DF come snodo essenziale tra competenza tecnica e accertamento dei fatti. In questo quadro, la qualità delle procedure di analisi e l'affidabilità degli strumenti impiegati incidono direttamente sulla possibilità di ricostruire correttamente gli eventi, individuare i responsabili e preservare il valore dell'evidenza nel procedimento giudiziario [7, 8].

1.2 Automazione dell'analisi forense e ruolo dell'Artificial Intelligence (AI)

L'espansione quantitativa e qualitativa dei dati oggetto di indagine ha reso progressivamente meno sostenibile un approccio esclusivamente manuale all'analisi forense. Le metodologie tradizionali, pur mantenendo un ruolo fondamentale in termini di controllo tecnico e validazione dell'evidenza, risultano spesso difficilmente scalabili quando l'investigatore deve esaminare grandi volumi di immagini, video, log, conversazioni, file di sistema e artefatti eterogenei provenienti da fonti differenti. In tali condizioni, l'automazione rappresenta una necessità operativa prima ancora che una scelta di efficienza [1, 7].

In questo contesto, l'integrazione di tecniche di AI negli strumenti di DF ha introdotto nuove possibilità di supporto all'analisi investigativa. In particolare, i metodi di Machine Learning (ML) e Deep Learning (DL) consentono di automatizzare attività quali la classificazione semantica di immagini e video, il riconoscimento di pattern ricorrenti, il raggruppamento di evidenze simili, l'analisi di log e l'individuazione di contenuti potenzialmente rilevanti ai fini dell'indagine. La letteratura sottolinea come tali strumenti possano contribuire a ridurre il carico cognitivo dell'analista, ad accelerare le attività di triage e, in alcuni contesti, anche a limitare l'esposizione prolungata a contenuti sensibili o traumatici, rendendo più gestibile l'esame di dataset molto ampi [7, 9, 10].

L'applicazione dell'AI alla DF non si limita tuttavia a una mera accelerazione dei processi esistenti. Essa introduce un cambiamento qualitativo nel modo in cui l'informazione investigativa viene filtrata, ordinata e prioritizzata. Sistemi basati su AI integrati in strumenti forensi commerciali possono suggerire categorie semantiche, supportare il clustering automatico di contenuti multimediali, evidenziare anomalie e proporre correlazioni che orientano l'attenzione dell'operatore verso specifici elementi dell'evidenza. Tale tendenza è osservabile anche nei principali strumenti professionali impiegati nel settore, nei quali moduli basati su AI vengono progressivamente integrati per supportare attività di classificazione, ordinamento e selezione preliminare delle evidenze [10, 11]. Esempi significativi in questo senso sono rappresentati da piattaforme forensi professionali quali *Magnet Axiom*, *Cellebrite Universal Forensic Extraction Device (UFED)*, *X-Ways Forensics* e *Oxygen Forensics*.

Tuttavia, il vantaggio offerto dall'automazione non può essere valutato esclusivamente in termini di efficienza. In ambito forense, infatti, ogni riduzione del carico umano ottenuta mediante modelli automatici deve essere bilanciata con esigenze di affidabilità, trasparenza e controllo. Un sistema che classifica automaticamente un contenuto come rilevante o irrilevante non si limita a velocizzare il lavoro dell'analista, ma contribuisce a determinare quali evidenze riceveranno attenzione prioritaria e quali, al contrario, rischieranno di essere trascurate. Ne deriva che l'introduzione dell'AI nei workflow forensi richiede una riflessione critica non solo sulle prestazioni dei modelli, ma anche sulla solidità delle loro decisioni in scenari operativi complessi e sulla possibilità di renderne comprensibili i limiti attraverso approcci di Explainable Artificial Intelligence (XAI) [12, 13].

1.3 Robustezza dei sistemi basati su AI e minacce avversariali e anti-forensi

L'impiego di sistemi basati su AI in contesti ad alta criticità ha evidenziato una questione fondamentale: prestazioni elevate in condizioni standard non implicano necessariamente affidabilità in presenza di input alterati, degradati o ostili. Nel caso della DF, tale aspetto assume particolare rilievo, poiché i modelli di classificazione possono essere esposti a contenuti intenzionalmente manipolati, a trasformazioni introdotte lungo la catena di acquisizione oppure a immagini che si discostano in modo significativo dalla distribuzione dei dati utilizzati in fase di sviluppo o addestramento.

La letteratura sull'Adversarial Machine Learning (AML) ha dimostrato che i modelli di ML

e DL possono essere vulnerabili a perturbazioni appositamente progettate per indurre errori di classificazione, anche quando tali alterazioni risultano minime o poco percepibili per un osservatore umano. Questi input manipolati, comunemente indicati come *adversarial examples*, mettono in discussione l'idea che un classificatore ad alte prestazioni sia necessariamente affidabile in scenari reali. La definizione dei *threat model*, la distinzione tra attacchi a conoscenza completa o limitata e la necessità di una valutazione orientata alla sicurezza costituiscono ormai elementi consolidati di questo ambito di ricerca [14, 15, 16, 17].

Nel dominio forense, tale vulnerabilità assume una valenza ulteriore, poiché la manipolazione dell'input può essere finalizzata non soltanto a compromettere una predizione, ma anche a ostacolare deliberatamente l'attività investigativa. È quindi utile distinguere tra due categorie di alterazioni. Da un lato, gli attacchi avversariali mirano a sfruttare le fragilità del modello, ad esempio mediante perturbazioni ottimizzate rispetto alla funzione di perdita o alla *decision boundary* del classificatore. Dall'altro, le trasformazioni anti-forensi agiscono sull'artefatto digitale con l'obiettivo di degradare, alterare o mascherare le tracce informative utili all'analisi, attraverso operazioni quali ricompressione, ridimensionamento, sfocatura, modifiche cromatiche o manipolazioni statistiche dell'immagine. Sebbene queste due famiglie di tecniche abbiano presupposti differenti, entrambe possono incidere sulla stabilità dei sistemi di classificazione automatica e ridurre l'affidabilità del supporto fornito all'analista forense [18, 19, 20].

La nozione di robustezza deve dunque essere intesa, in questa tesi, come capacità del sistema di mantenere comportamenti affidabili non soltanto in presenza di rumore o degradazioni naturali, ma anche sotto perturbazioni intenzionali e strategicamente progettate. In questa prospettiva, un sistema non robusto può modificare la priorità attribuita ai contenuti, ridurre la stabilità delle classificazioni o rendere meno affidabile il triage automatizzato. Per questa ragione, il tema della robustezza non costituisce un problema marginale di ottimizzazione del modello, ma una questione centrale di affidabilità operativa [16, 21].

1.4 Problema di ricerca e rilevanza in scenari forensi realistici

Nonostante l'ampia letteratura sugli attacchi avversariali e sulla robustezza dei modelli di ML, rimane ancora limitata la valutazione di tali criticità in scenari forensi realistici. Molti studi si concentrano su benchmark standardizzati, dataset costruiti per finalità generiche di *computer vision* o condizioni sperimentali lontane dai workflow investigativi effettivi. Questa distanza riduce la trasferibilità dei risultati e rende difficile stimare l'impatto operativo delle vulnerabilità quando i sistemi automatici sono impiegati per supportare l'analisi di contenuti di interesse investigativo, come nel caso della classificazione di immagini raffiguranti armi individuali realistiche [18, 22, 23].

Nel dominio della DF, il problema non consiste soltanto nello stabilire se un classificatore possa essere ingannato, ma nel comprendere in quale misura tale fragilità incida sulla capacità del sistema di supportare decisioni affidabili durante l'analisi dell'evidenza. Ciò implica considerare dataset realistici, contenuti eterogenei, immagini soggette a trasformazioni plausibili, casi borderline e situazioni in cui la distinzione tra contenuto rilevante, irrilevante o ambiguo non è sempre netta. La stessa evoluzione recente della ricerca sui tool forensi guidati da AI mostra che l'integrazione dell'automazione, pur promettente, solleva interrogativi concreti sulla tenuta dei moduli di classificazione quando essi vengono esposti a contenuti manipolati o sintetici [9, 10].

In questo quadro, la vulnerabilità del sistema non ha soltanto una rilevanza teorica, ma produce conseguenze operative immediate. Errori di classificazione indotti da input manipolati possono alterare la priorità attribuita alle evidenze, generare rumore analitico o ridurre la capacità del sistema di segnalare contenuti potenzialmente rilevanti. La robustezza, pertanto, non riguarda soltanto la stabilità del modello rispetto a perturbazioni controllate, ma la qualità complessiva del supporto che esso è in grado di offrire all'interno del workflow forense [21, 24].

Il problema di ricerca affrontato in questa tesi si colloca precisamente in tale intersezione tra robustezza algoritmica e affidabilità operativa. L'obiettivo non è limitarsi a osservare una generica degradazione prestazionale, ma analizzare in modo sistematico come differenti modelli di classificazione automatica e differenti strumenti basati su AI si comportino quando vengono impiegati in uno scenario forense realistico e sottoposti a perturbazioni avversariali e anti-forensi. Questa prospettiva consente di superare una valutazione puramente astratta della sicurezza dei modelli, orientando l'analisi verso le conseguenze concrete che tali vulnerabilità possono produrre sul triage, sulla selezione delle evidenze e, più in generale, sull'intero workflow investigativo.

La rilevanza della ricerca è dunque duplice. Da un lato, essa è scientifica, poiché contribuisce alla definizione di un quadro sperimentale più aderente alle esigenze del dominio forense e alla comprensione dei limiti dei modelli basati su AI in presenza di input ostili. Dall'altro, essa è operativa, poiché fornisce elementi utili per valutare criticamente l'uso di sistemi automatici nei contesti investigativi, promuovendo un approccio che non privilegi la sola accuratezza nominale, ma anche la robustezza, la tracciabilità e la verificabilità del comportamento del modello. In questo senso, la tesi si inserisce in una linea di ricerca che mira a colmare la carenza di benchmark specifici e di protocolli comparativi condivisi per la valutazione dell'AI in DF [9, 10, 21].

1.5 Obiettivi della ricerca

Alla luce delle criticità evidenziate nei paragrafi precedenti, questa tesi si propone di valutare in modo sistematico la robustezza operativa di strumenti e modelli basati su AI impiegati per la classificazione automatica di immagini in ambito forense. L'obiettivo generale è verificare in quale misura tali sistemi mantengano prestazioni affidabili quando vengono esposti a input manipolati, degradati o comunque non pienamente conformi alle condizioni ideali di addestramento e validazione, con particolare attenzione a scenari in cui le perturbazioni possano essere ricondotte a strategie avversariali o anti-forensi [16, 21].

In questa prospettiva, il lavoro si articola attorno a quattro obiettivi principali. Il primo consiste nella costruzione di un quadro sperimentale rigoroso e riproducibile per l'analisi della robustezza di modelli di classificazione di immagini rilevanti ai fini investigativi. Il secondo consiste nel confrontare modelli eterogenei, sia in termini architetturali sia in termini di paradigma di apprendimento, al fine di osservare eventuali differenze di comportamento rispetto alle diverse tipologie di perturbazione. Il terzo obiettivo riguarda la misurazione dell'impatto delle manipolazioni sulla capacità dei sistemi di riconoscere correttamente contenuti di interesse forense, con attenzione sia al degrado prestazionale complessivo sia alle specifiche modalità di errore introdotte. Il quarto obiettivo consiste nel collegare tali evidenze sperimentali a una riflessione più ampia sull'affidabilità dell'automazione nei workflow forensi, evidenziando limiti, rischi operativi e possibili direttrici di miglioramento [7, 9, 24].

L'impostazione adottata non mira quindi soltanto a misurare l'accuratezza di classificatori in un ambiente controllato, ma a comprendere come l'interazione tra modelli, dati e perturbazioni possa incidere concretamente sul supporto che tali strumenti offrono all'analista. In tal senso, l'obiettivo della ricerca non è esclusivamente prestazionale, ma anche metodologico e applicativo: individuare un protocollo di valutazione che consenta di giudicare la robustezza dei sistemi basati su AI non in astratto, bensì in relazione al loro possibile impiego in scenari investigativi realistici.

1.6 Contributo della tesi

Il contributo principale della presente tesi risiede nella definizione e nell'applicazione di un framework di valutazione orientato alla robustezza operativa di sistemi basati su AI per la classificazione automatica di immagini in ambito forense. A differenza di molti studi focalizzati prevalentemente su benchmark standard di *computer vision* o su valutazioni di robustezza in contesti generici, il presente lavoro adotta una prospettiva specificamente calibrata sulle

esigenze della DF, ponendo al centro non solo la capacità di classificazione, ma anche la tenuta del sistema in presenza di input ostili, ambigui o degradati [18, 22, 23].

Un primo contributo consiste nell'integrazione di una pipeline accademica e di una pipeline operativo-forense all'interno di un unico disegno sperimentale. La prima consente di analizzare modelli, dataset, perturbazioni, metriche ed elementi di interpretabilità secondo una logica controllata e comparabile; la seconda permette di estendere la riflessione a strumenti forensi professionali, valutandone criticamente il comportamento in un contesto più vicino alle condizioni applicative reali. Tale integrazione consente di colmare, almeno in parte, la distanza che spesso separa la letteratura sperimentale dalla pratica investigativa effettiva [7, 10, 11].

Un secondo contributo riguarda la costruzione di un dataset frozen, ossia congelato rispetto alle successive fasi sperimentali, nonché la definizione di un protocollo di selezione coerente con il problema investigativo affrontato. Il dataset finale è organizzato in tre classi semanticamente distinte, denominate **weapon**, **non_weapon** e OOD, per un totale di 1500 immagini bilanciate. La classe **weapon** include esclusivamente armi individuali realistiche e chiaramente visibili; la classe **non_weapon** comprende negativi realistici coerenti con il task; la classe OOD raccoglie casi borderline o fuori distribuzione, quali repliche, coltelli, render sintetici, scene di guerra, immagini degradate o contenuti anomali rispetto al dominio di interesse. A partire da tale dataset viene inoltre definito un subset adversarial binario di 1000 immagini, composto dalle sole classi **weapon** e **non_weapon**, destinato alla generazione e alla valutazione delle perturbazioni. La selezione dei campioni segue un paradigma *human-in-the-loop*, nel quale la componente manuale non viene occultata, ma documentata come parte integrante del protocollo metodologico.

Un terzo contributo riguarda la costruzione di un protocollo sperimentale fondato su dati eterogenei, criteri di classificazione coerenti con il problema investigativo affrontato e un insieme di perturbazioni selezionate per rappresentare sia attacchi adversariali sia trasformazioni compatibili con una logica anti-forense. In questo modo, la tesi non si limita a verificare se un modello possa essere indotto in errore, ma analizza anche la natura di tale errore e le sue possibili implicazioni operative [19, 21, 25].

Un quarto contributo consiste nella comparazione tra modelli differenti per architettura, grado di supervisione e logica decisionale, così da evidenziare eventuali profili di maggiore o minore robustezza in relazione alle perturbazioni considerate. Questa impostazione consente di evitare conclusioni eccessivamente dipendenti da un singolo classificatore e rafforza la validità comparativa del lavoro. Infine, la tesi offre un contributo di natura metodologica più ampia, proponendo una lettura della robustezza non soltanto come proprietà tecnica del modello, ma come requisito funzionale per il suo impiego consapevole in DF.

L'analisi empirica è quindi finalizzata a valutare in che misura tali perturbazioni incidano sulla stabilità delle classificazioni, sulla robustezza dei modelli e sulla qualità del supporto offerto dagli strumenti automatici all'interno del workflow forense.

1.7 Rilevanza tecnico-forense e profili di affidabilità probatoria

In ambito forense, la correttezza tecnica di uno strumento non può essere valutata indipendentemente dal contesto in cui esso viene utilizzato e dalle conseguenze che i suoi risultati possono produrre sull'analisi dell'evidenza. L'introduzione di sistemi basati su AI nei workflow investigativi solleva pertanto una questione che è al tempo stesso tecnica e forense: fino a che punto un output automatizzato può essere considerato sufficientemente affidabile da orientare il lavoro dell'analista, senza compromettere la completezza dell'esame o introdurre errori sistematici difficilmente rilevabili [11, 24].

Il problema assume rilievo particolare quando i sistemi automatici operano in modalità sostanzialmente opaca, ovvero quando l'analista dispone del risultato della classificazione ma non di una piena comprensione del processo decisionale che lo ha generato. In tali casi, la fragilità del modello rispetto a input manipolati o inattesi non rappresenta soltanto un limite algoritmico,

ma può riflettersi sulla qualità dell'intero processo investigativo. Un falso negativo può determinare la mancata selezione di un contenuto rilevante; un falso positivo può generare rumore, deviare risorse e appesantire la verifica manuale. In entrambi i casi, la vulnerabilità del sistema incide sulla fiducia operativa riposta nello strumento e sulla possibilità di giustificare in modo rigoroso il ruolo svolto dall'automazione nell'analisi [12, 13].

Da questo punto di vista, la robustezza operativa si collega direttamente all'esigenza di tracciabilità, verificabilità e controllo critico che caratterizza la DF. Un sistema automatico può certamente costituire un supporto efficace per il triage e la prioritizzazione delle evidenze, ma il suo impiego richiede che i risultati siano interpretati alla luce dei limiti del modello, delle condizioni sperimentali in cui è stato valutato e dei possibili margini di errore. La presente tesi si colloca precisamente in questo spazio problematico: non assume l'automazione come intrinsecamente affidabile, ma ne esamina la tenuta empirica per comprendere in quali condizioni essa possa offrire un supporto utile e in quali, invece, richieda particolare cautela.

Sotto il profilo probatorio, tale impostazione non implica che il modello debba essere considerato fonte autonoma di verità tecnica, bensì che il suo eventuale impiego debba essere accompagnato da un'adeguata consapevolezza metodologica. In altri termini, la rilevanza del presente studio risiede anche nel fornire elementi utili a distinguere tra uso meramente strumentale dell'AI e affidamento acritico su decisioni algoritmiche non sufficientemente robuste. Ciò risulta particolarmente importante in un contesto in cui la prova digitale richiede procedure rigorose e in cui l'adozione di strumenti automatici deve poter essere difesa non solo sul piano dell'efficienza, ma anche su quello della controllabilità tecnica e della loro affidabilità in ambito forense [26, 27, 28].

1.8 Struttura della tesi

La struttura della tesi segue una progressione dal generale al particolare: dal quadro teorico e dallo stato dell'arte si passa alla definizione della metodologia sperimentale, per poi arrivare all'analisi empirica, alla discussione critica dei risultati e alle implicazioni operative del lavoro. La tesi è articolata in sei capitoli principali.

Il Capitolo 1 introduce il contesto generale della ricerca, evidenziando la crescente rilevanza della DF in scenari ad alta digitalizzazione, il ruolo assunto dall'automazione e dall'AI nei workflow investigativi, nonché il problema della robustezza dei sistemi di classificazione automatica di immagini in presenza di perturbazioni avversariali e anti-forensi. Nello stesso capitolo vengono definiti gli obiettivi del lavoro, il contributo specifico della tesi e la sua rilevanza tecnico-forense.

Il Capitolo 2 presenta il quadro teorico di riferimento. In esso vengono richiamati i concetti fondamentali della DF, i principali riferimenti normativi e metodologici relativi alla prova digitale, i fondamenti di ML e DL rilevanti per il problema affrontato, nonché le nozioni principali in materia di attacchi avversariali, tecniche anti-forensi, robustezza e interpretabilità dei modelli.

Il Capitolo 3 sviluppa una rassegna critica dello stato dell'arte, con particolare attenzione alle applicazioni dell'AI in DF, alle vulnerabilità dei sistemi di classificazione automatica rispetto a input manipolati e alle principali linee di ricerca sulla robustezza dei modelli e dei tool forensi guidati da AI. Tale capitolo consente di individuare le principali lacune della letteratura e di motivare il disegno sperimentale adottato nella tesi.

Il Capitolo ?? descrive in dettaglio la metodologia sperimentale. In questa parte vengono presentati il dataset, i criteri di costruzione e selezione delle classi, i modelli di classificazione considerati, le perturbazioni avversariali e anti-forensi selezionate, gli strumenti forensi impiegati e le metriche di valutazione. Il capitolo definisce inoltre la pipeline complessiva dell'esperimento e le scelte adottate per garantire coerenza metodologica e riproducibilità.

Il Capitolo ?? riporta l'applicazione concreta della metodologia, illustrando le procedure di test, i risultati ottenuti e il confronto tra modelli e strumenti rispetto alle diverse condizioni sperimentali. In questa parte vengono analizzati sia gli aspetti quantitativi sia quelli qualitativi

della risposta dei sistemi alle perturbazioni, con l'obiettivo di evidenziare punti di forza, fragilità ricorrenti e implicazioni operative dei risultati.

Infine, il Capitolo ?? raccoglie e discute criticamente le principali evidenze emerse dal lavoro. In esso vengono sintetizzati i contributi della tesi, evidenziati i limiti dello studio e proposte possibili direzioni di ricerca futura, con particolare riguardo al miglioramento della robustezza, dell'interpretabilità e dell'affidabilità dei sistemi basati su AI applicati alla DF.

Chapter 2

Technical Background Concepts

Questo capitolo introduce i concetti teorici necessari per comprendere la valutazione della robustezza operativa di strumenti AI-based impiegati nella classificazione automatizzata di immagini in ambito forense. Il quadro teorico è costruito a partire dai fondamenti della DF e della prova digitale, per poi esaminare il ruolo dell'AI nei workflow forensi, la rilevanza delle immagini come evidenze digitali, i principi di ML e DL applicati alla computer vision, l'AML, le tecniche anti-forensi applicate a contenuti visivi e il ruolo dell'XAI nella valutazione dell'affidabilità dei modelli. La trattazione mantiene un livello concettuale e definitorio: la descrizione della pipeline sperimentale, dei dataset, dei modelli e degli strumenti utilizzati è demandata ai capitoli metodologici successivi.

2.1 Digital Forensics e prova digitale

La DF è la disciplina tecnico-scientifica che si occupa dell'identificazione, acquisizione, conservazione, esame, analisi e presentazione di dati digitali potenzialmente rilevanti in un contesto investigativo o giudiziario. Essa nasce dall'esigenza di trattare informazioni memorizzate o trasmesse mediante dispositivi elettronici secondo procedure idonee a preservarne il valore probatorio. In tale prospettiva, il dato digitale non assume automaticamente il ruolo di prova: esso deve essere raccolto, documentato e interpretato mediante procedure controllabili, ripetibili e compatibili con i requisiti di integrità, autenticità e tracciabilità richiesti dall'indagine forense [1, 2, 5].

La prova digitale presenta caratteristiche peculiari rispetto alle evidenze fisiche tradizionali. Essa è immateriale, facilmente replicabile, spesso distribuita tra dispositivi, servizi cloud, supporti rimovibili e sistemi di comunicazione, e può essere alterata anche da operazioni apparentemente ordinarie, come l'accensione di un dispositivo, l'apertura di un file o l'esecuzione di un'applicazione. Questa fragilità rende necessario distinguere tra semplice disponibilità tecnica del dato e sua utilizzabilità forense. Un'immagine, un log, un messaggio o un file multimediale possono contribuire alla ricostruzione di un fatto solo se il loro ciclo di vita investigativo è documentato in modo da consentire la verifica delle operazioni compiute e delle eventuali trasformazioni subite.

I requisiti di integrità, autenticità e tracciabilità costituiscono quindi il fondamento metodologico della DF. L'integrità riguarda la capacità di dimostrare che il dato analizzato non sia stato modificato in modo non controllato rispetto alla fonte acquisita. L'autenticità attiene alla possibilità di collegare l'evidenza a un determinato dispositivo, soggetto, sistema o contesto operativo. La tracciabilità, infine, richiede che ogni fase dell'attività forense sia documentata mediante registri, log, annotazioni tecniche, valori hash e procedure di catena di custodia. Tali elementi non hanno soltanto una funzione amministrativa, ma permettono di rendere verificabile il percorso che conduce dal reperto digitale originario all'informazione presentata in sede investigativa o processuale [6, 28, 29].

Dal punto di vista operativo, la letteratura e le linee guida tecniche descrivono il processo forense digitale attraverso una sequenza di fasi logicamente distinte: raccolta, esame, analisi e reporting. La fase di raccolta riguarda l'individuazione e l'acquisizione delle fonti digitali rilevanti, con particolare attenzione alla preservazione dello stato dell'evidenza. La fase di esame comprende l'estrazione e l'organizzazione dei dati potenzialmente pertinenti, ad esempio mediante analisi del file system, recupero di artefatti, indicizzazione e filtraggio. La fase di analisi consiste nell'interpretazione tecnica dei dati estratti, nella correlazione tra fonti differenti e nella ricostruzione di eventi o comportamenti rilevanti. La fase di reporting, infine, richiede la documentazione chiara, verificabile e comprensibile delle attività svolte, degli strumenti impiegati, dei risultati ottenuti e delle limitazioni riscontrate [2, 4, 5].

La Figura 2.1 sintetizza questo workflow generale e colloca la presente tesi principalmente nelle fasi di *examination* e *analysis*.




Figure 2.1: Simplified digital forensic workflow.

In questo quadro, l'automazione assume un ruolo sempre più rilevante. La crescita del volume dei dati sequestrati o acquisiti nelle indagini digitali rende spesso impraticabile un'analisi esclusivamente manuale. Strumenti forensi commerciali e open source integrano quindi funzionalità di indicizzazione, ricerca, classificazione, correlazione temporale e, più recentemente, moduli basati su AI per supportare l'analista nell'individuazione di contenuti rilevanti. Tuttavia, l'automazione non elimina la responsabilità interpretativa dell'operatore forense. Al contrario, introduce la necessità di valutare in modo esplicito l'affidabilità degli strumenti, la robustezza dei modelli e il rischio che errori, bias o manipolazioni intenzionali influenzino la selezione delle evidenze.

Questa esigenza diventa particolarmente critica quando l'automazione riguarda contenuti visivi. Nei casi in cui immagini o video vengano classificati automaticamente come rilevanti per l'indagine, l'errore di un modello può determinare falsi negativi, con conseguente mancata individuazione di materiale probatorio, oppure falsi positivi, con possibile sovraccarico analitico e rischio di interpretazioni improprie. Per tale ragione, la classificazione automatizzata di immagini in ambito forense deve essere studiata non solo in termini di accuratezza nominale, ma anche rispetto alla sua robustezza in presenza di degradazioni, manipolazioni anti-forensi e perturbazioni avversariali. Questo collegamento tra prova digitale, automazione e affidabilità dei modelli costituisce il punto di partenza per le sezioni successive del capitolo.

2.2 Artificial Intelligence nella Digital Forensics

L'integrazione dell'AI nella DF risponde alla crescente complessità quantitativa e qualitativa delle indagini digitali. L'aumento del volume dei dati acquisiti da dispositivi personali, infrastrutture cloud, sistemi mobili, applicazioni di messaggistica e archivi multimediali rende progressivamente meno sostenibile un'analisi esclusivamente manuale. In questo scenario, tecniche di automazione, indicizzazione intelligente e classificazione assistita possono supportare l'analista nella selezione preliminare delle informazioni potenzialmente rilevanti, riducendo il carico operativo e accelerando le fasi di esame e analisi dell'evidenza digitale [1, 7].

Nel contesto forense, l'AI può essere impiegata per compiti eterogenei, tra cui il riconoscimento di pattern, il raggruppamento di contenuti simili, la ricerca semantica, la classificazione automatica di immagini e documenti, l'identificazione di anomalie e la prioritizzazione degli artefatti da sottoporre a revisione umana. Tali funzionalità non sostituiscono l'attività valutativa dell'operatore, ma possono costituire un supporto alla navigazione di grandi insiemi di dati, specialmente quando l'evidenza contiene quantità elevate di contenuti multimediali o informazioni scarsamente strutturate. La rilevanza dell'AI nella DF deve quindi essere intesa in termini di assistenza investigativa e non come delega automatica della decisione probatoria [7, 24].

L'utilizzo di modelli ML e DL introduce tuttavia una discontinuità rispetto agli strumenti forensi tradizionali. Molte procedure classiche di analisi digitale si basano su regole deterministiche, firme note, hash, metadati, keyword search o strutture del file system. I modelli di apprendimento automatico, invece, producono output probabilistici fondati su rappresentazioni apprese dai dati. Questa caratteristica consente di trattare contenuti complessi, come immagini, video e testo naturale, ma rende necessario valutare con maggiore attenzione la qualità dei dati di addestramento, la distribuzione degli input, la generalizzazione del modello e la stabilità delle predizioni in condizioni non ideali.

In ambito forense, tale distinzione è particolarmente rilevante perché l'output di un sistema AI-based può influenzare il modo in cui l'analista esplora l'evidenza. Una classificazione errata non determina necessariamente una conclusione probatoria autonoma, ma può incidere sulla priorità assegnata a determinati contenuti, sulla visibilità di artefatti rilevanti o sull'efficienza complessiva del workflow investigativo. Di conseguenza, l'affidabilità di un modulo automatico non può essere valutata soltanto attraverso metriche aggregate di accuratezza, ma deve essere considerata anche rispetto alla presenza di falsi positivi, falsi negativi, bias di distribuzione e scenari di manipolazione intenzionale.

La letteratura recente ha evidenziato come l'impiego di funzionalità AI-based negli strumenti forensi sollevi un problema specifico di validazione: non è sufficiente verificare che il sistema funzioni correttamente su dati ordinari, ma occorre comprenderne il comportamento anche in presenza di dati degradati, manipolati o fuori distribuzione [9, 10]. Questo aspetto assume particolare importanza quando l'analisi riguarda contenuti visivi, poiché immagini e video possono essere alterati mediante tecniche di compressione, ridimensionamento, sfocatura, modifica del contrasto o perturbazioni avversariali. In tali condizioni, un sistema apparentemente accurato su dati puliti può mostrare una riduzione significativa della propria capacità di classificazione.

Per queste ragioni, l'adozione dell'AI nella DF deve essere accompagnata da un paradigma di supervisione umana, documentazione tecnica e valutazione sperimentale della robustezza. L'analista deve poter comprendere il ruolo svolto dal sistema automatico, i limiti della classificazione prodotta e le condizioni nelle quali il modello può generare errori. In questa prospettiva, l'AI non rappresenta un sostituto della competenza forense, ma uno strumento di supporto la cui utilità dipende dalla possibilità di verificarne prestazioni, stabilità e affidabilità nel contesto operativo in cui viene impiegato.

Il caso della classificazione automatica di immagini costituisce un dominio particolarmente significativo per analizzare tali problematiche. Le immagini possono contenere informazioni direttamente rilevanti per l'indagine, ma sono anche soggette a trasformazioni tecniche e manipolazioni che possono modificarne l'aspetto, i metadati o le caratteristiche statistiche. Per questo motivo, prima di introdurre i principi di ML e DL applicati alla computer vision, è necessario chiarire il ruolo delle immagini come evidenze digitali e il significato della loro classificazione automatica nel contesto dell'image forensics.

2.3 Image Forensics e classificazione automatica

Le immagini digitali rappresentano una categoria di evidenza particolarmente rilevante nelle indagini forensi contemporanee. Esse possono documentare luoghi, oggetti, persone, condotte, strumenti o circostanze potenzialmente significative per la ricostruzione di un fatto. A differenza di altri artefatti digitali, tuttavia, l'immagine combina una dimensione visiva immediatamente

interpretabile dall'osservatore umano con una struttura tecnica complessa, costituita da valori di pixel, metadati, parametri di compressione, informazioni sul dispositivo di acquisizione e possibili tracce di elaborazione successiva. Per questo motivo, l'analisi forense delle immagini richiede di considerare sia il contenuto raffigurato sia le proprietà digitali del file che lo rappresenta [20, 30].

L'immagine forensics si occupa dello studio delle immagini digitali con l'obiettivo di valutarne origine, integrità, autenticità e possibili manipolazioni. Le tecniche classiche di questo dominio includono, tra le altre, l'analisi dei metadati, lo studio degli artefatti di compressione, la ricerca di incoerenze statistiche, l'identificazione di tracce di ricampionamento e l'esame di caratteristiche legate al sensore o al processo di acquisizione. Tali analisi non mirano soltanto a stabilire se un'immagine sia visivamente plausibile, ma a verificare se il file presenti elementi tecnici compatibili con una determinata origine o con una determinata storia di elaborazione [30, 31].

Nel contesto della presente tesi, l'immagine forensics viene considerata soprattutto come quadro concettuale per comprendere la complessità delle immagini come evidenze digitali. Il focus non è la rilevazione diretta di falsificazioni o manipolazioni mediante tecniche specializzate di forgery detection, ma la valutazione della classificazione automatica di contenuti visivi in un contesto forense. Tale distinzione è importante: stabilire se un'immagine sia stata manipolata e classificare ciò che essa rappresenta sono due compiti differenti, sebbene possano interagire. Una manipolazione o una degradazione dell'immagine può infatti non essere l'oggetto primario dell'analisi, ma può comunque influenzare la capacità di uno strumento automatico di riconoscere correttamente il contenuto raffigurato.

La classificazione automatica di immagini consiste nell'assegnazione di un'immagine a una o più categorie semantiche sulla base del contenuto visivo. In ambito forense, tali categorie possono corrispondere a oggetti, scene, persone, documenti, contenuti sensibili o elementi ritenuti rilevanti per l'indagine. Questa forma di automazione può supportare l'analista nella gestione di grandi collezioni multimediali, consentendo di filtrare, ordinare o prioritizzare immagini potenzialmente pertinenti. Tuttavia, la classificazione automatica non deve essere interpretata come una determinazione probatoria autonoma: essa produce un'indicazione tecnica che richiede contestualizzazione, verifica e supervisione umana.

L'affidabilità della classificazione automatica dipende anche dalle caratteristiche tecniche dell'immagine. Risoluzione, qualità visiva, illuminazione, occlusioni, prospettiva, compressione Joint Photographic Experts Group (JPEG), ricampionamento, sfocatura e modifiche cromatiche possono alterare la rappresentazione digitale del contenuto e ridurre la stabilità delle predizioni. Alcune trasformazioni sono comuni nei normali flussi di produzione e condivisione delle immagini, ad esempio quando un contenuto viene caricato su piattaforme social, inoltrato tramite applicazioni di messaggistica o salvato più volte in formati compressi. Altre trasformazioni possono invece essere introdotte deliberatamente per degradare l'immagine, mascherare dettagli o rendere più difficile l'analisi automatica.

Questa sensibilità è particolarmente critica in ambito forense, perché un errore di classificazione può incidere sul processo di selezione preliminare delle evidenze. Un falso negativo può impedire che un'immagine rilevante venga portata all'attenzione dell'analista, mentre un falso positivo può aumentare il carico di revisione e generare percorsi investigativi non pertinenti. In entrambi i casi, il problema non riguarda soltanto la prestazione tecnica del classificatore, ma anche il rapporto tra automazione, priorità investigativa e affidabilità del workflow forense.

Pertanto, la classificazione automatica di immagini in ambito forense deve essere valutata considerando non solo la correttezza della predizione su dati puliti, ma anche la sua stabilità rispetto a condizioni realistiche di acquisizione, compressione, degradazione e manipolazione. Questo aspetto collega direttamente l'immagine forensics alla valutazione della robustezza dei modelli AI-based. Prima di discutere attacchi adversariali e tecniche anti-forensi, è necessario introdurre i principi di ML e DL che consentono ai sistemi di computer vision di apprendere rappresentazioni visive e produrre classificazioni automatiche.

2.4 Machine Learning e Deep Learning per la Computer Vision

La computer vision comprende l'insieme di metodi computazionali finalizzati all'analisi automatica di immagini e video, con l'obiettivo di estrarre informazioni strutturate da contenuti visivi. In questo ambito, le tecniche di ML e DL hanno progressivamente sostituito o affiancato approcci basati su feature progettate manualmente, consentendo ai modelli di apprendere rappresentazioni visive direttamente dai dati. Nel caso della classificazione di immagini, il problema consiste nell'associare a un'immagine una o più etichette semantiche sulla base delle caratteristiche osservabili nel contenuto visivo [32, 33].

Nel paradigma supervisionato, un modello viene addestrato su un insieme di esempi annotati, ciascuno costituito da un input e da una corrispondente etichetta di classe. Durante l'addestramento, il modello apprende una funzione decisionale capace di associare nuovi input a una delle classi previste dal task. L'obiettivo non è memorizzare gli esempi osservati, ma generalizzare correttamente su dati non visti. Questa distinzione è centrale in ambito forense, poiché un classificatore utilizzato su evidenze reali può incontrare immagini diverse da quelle presenti nei dati di addestramento, per qualità, provenienza, risoluzione, compressione, contesto visivo o distribuzione semantica.

La qualità della generalizzazione dipende da diversi fattori, tra cui la rappresentatività del dataset, la coerenza delle annotazioni, la separabilità delle classi, il bilanciamento dei dati e la capacità del modello di apprendere caratteristiche realmente rilevanti per il compito. In assenza di tali condizioni, un sistema può ottenere buone prestazioni su un insieme di test controllato ma risultare meno affidabile in scenari realistici. Questo problema è particolarmente rilevante nei task forensi, nei quali le immagini possono provenire da fonti eterogenee, essere degradate da processi di compressione o condivisione, oppure contenere casi ambigui e fuori distribuzione.

Gli approcci tradizionali di ML applicati alla classificazione di immagini si basano spesso su una separazione tra estrazione delle feature e classificazione. Le caratteristiche visive vengono calcolate mediante descrittori progettati o selezionati in funzione del problema, mentre un classificatore apprende una regola decisionale nello spazio delle feature. Modelli come le Support Vector Machine (SVM) hanno rappresentato per lungo tempo una soluzione efficace per problemi di classificazione supervisionata, grazie alla capacità di costruire superfici di decisione robuste in spazi ad alta dimensionalità [32, 34]. Tuttavia, la qualità del risultato dipende fortemente dalla scelta delle feature e dalla loro capacità di rappresentare in modo discriminativo il contenuto dell'immagine.

Il DL ha modificato profondamente questo paradigma, introducendo modelli capaci di apprendere automaticamente rappresentazioni gerarchiche dei dati. Nelle reti neurali convoluzionali, comunemente indicate come Convolutional Neural Network (CNN), i primi livelli tendono a catturare strutture visive semplici, come bordi, texture e contrasti locali, mentre i livelli più profondi combinano tali informazioni in rappresentazioni più astratte e semanticamente significative. Architetture come ResNet hanno mostrato l'efficacia di connessioni residue per addestrare reti profonde, riducendo problemi di degradazione dell'ottimizzazione e migliorando la capacità di apprendimento di rappresentazioni visive complesse [35]. Modelli successivi, come EfficientNet, hanno invece introdotto strategie di scaling più bilanciate tra profondità, larghezza e risoluzione dell'immagine, con l'obiettivo di migliorare il rapporto tra prestazioni e costo computazionale [36].

Accanto alle architetture convoluzionali, negli ultimi anni si sono affermati modelli vision-language capaci di apprendere rappresentazioni congiunte di immagini e testo. In tali sistemi, l'immagine non viene analizzata soltanto rispetto a classi predefinite durante l'addestramento, ma può essere associata a descrizioni testuali o concetti semantici più generali. Modelli come Contrastive Language-Image Pre-training (CLIP) hanno mostrato la possibilità di apprendere rappresentazioni visuali trasferibili a partire da supervisione linguistica su larga scala, aprendo la strada a classificazioni zero-shot o text-guided [37]. Questa impostazione è particolarmente interessante nei contesti in cui le categorie operative non coincidono perfettamente con le classi

disponibili nei dataset tradizionali, ma introduce anche nuove criticità legate alla formulazione dei prompt, alla copertura semantica delle classi e alla stabilità delle predizioni.

Accanto a CLIP, anche modelli vision-language generativi come Bootstrapping Language-Image Pre-training (BLIP) consentono di associare immagini a descrizioni testuali, introducendo una prospettiva complementare rispetto alla classificazione chiusa basata su etichette predefinite [38]. Nel contesto forense, tali modelli possono supportare forme di descrizione automatica del contenuto visivo e contribuire alla prioritizzazione preliminare degli artefatti multimediali. Tuttavia, il loro impiego richiede particolare cautela, poiché la descrizione generata può essere sensibile alla qualità dell'immagine, alla distribuzione dei dati, alla formulazione del prompt e alla presenza di contenuti ambigui o fuori distribuzione.

Dal punto di vista forense, la scelta del modello non può essere valutata esclusivamente in funzione dell'accuratezza media. Un sistema di classificazione automatica deve essere considerato rispetto alla sua capacità di mantenere prestazioni stabili su dati eterogenei, degradati o non perfettamente allineati alla distribuzione di addestramento. La presenza di immagini fuori distribuzione, casi borderline o contenuti visivamente ambigui può infatti compromettere la confidenza del modello o produrre classificazioni non affidabili. In questo senso, il concetto di Out-of-Distribution (OOD) detection è strettamente collegato alla robustezza operativa, poiché consente di distinguere tra errori su classi note e input che non dovrebbero essere ricondotti con eccessiva sicurezza alle categorie previste dal classificatore [39, 40].

Questa impostazione giustifica, sul piano metodologico, l'introduzione di una classe OOD distinta dalle classi operative principali. Nel contesto della presente tesi, tale classe consente di rappresentare contenuti borderline, anomali o non pienamente riconducibili alla distribuzione semantica attesa dal classificatore, evitando che immagini estranee al task vengano forzatamente ricondotte alle categorie *weapon* o *non-weapon*.

Un ulteriore aspetto riguarda l'interpretazione probabilistica degli output. Molti modelli di classificazione producono score o probabilità associate alle classi, ma tali valori non corrispondono necessariamente a una misura diretta di affidabilità probatoria. Un'elevata confidenza può essere il risultato di correlazioni spurie, bias del dataset o sovra-adattamento alla distribuzione di addestramento. Per questo motivo, l'uso di modelli ML e DL in un workflow forense richiede una valutazione prudente, nella quale le predizioni automatiche siano considerate come supporto analitico e non come determinazioni autonome.

La computer vision forense deve quindi confrontarsi con una tensione metodologica: da un lato, i modelli DL consentono di analizzare grandi quantità di immagini con prestazioni spesso superiori agli approcci tradizionali; dall'altro, la loro affidabilità può ridursi in presenza di variazioni visive, trasformazioni anti-forensi, perturbazioni adversariali o input fuori distribuzione. Questa tensione giustifica la necessità di studiare la robustezza dei classificatori non soltanto in condizioni pulite e controllate, ma anche in scenari realistici nei quali il contenuto visivo può essere degradato, manipolato o deliberatamente alterato.

2.5 Adversarial Machine Learning

L'AML studia il comportamento dei sistemi di apprendimento automatico in presenza di input costruiti o modificati con l'obiettivo di alterarne il funzionamento. A differenza degli errori dovuti a rumore casuale, scarsa qualità dei dati o limiti di generalizzazione, gli attacchi adversariali presuppongono la presenza di un attore che modifica deliberatamente l'input per indurre il modello a produrre una predizione errata. Nel dominio della computer vision, questo problema assume particolare rilevanza perché piccole variazioni del contenuto digitale possono essere sufficienti a modificare la classificazione prodotta da un modello, anche quando l'immagine resta apparentemente simile per un osservatore umano [14, 41].

Un adversarial example può essere descritto, in termini generali, come un input modificato rispetto a un campione originario, ma costruito in modo tale da indurre il classificatore a produrre un'etichetta non corretta. Indicando con x l'immagine originale, con y la sua classe

corretta e con $f(\cdot)$ il classificatore, l'obiettivo dell'attaccante è generare una versione perturbata x' , tale che x' rimanga sufficientemente vicina a x secondo un vincolo di distanza o percettibilità, ma venga classificata in modo diverso dal modello. In forma semplificata, il problema può essere espresso come la ricerca di una perturbazione δ tale che:

$$x' = x + \delta \quad \text{e} \quad f(x') \neq y.$$

La perturbazione δ è spesso vincolata mediante metriche di distanza o vincoli di tipo ℓ_p , espressi nella forma $\|\delta\|_p \leq \epsilon$, dove ϵ rappresenta il budget massimo di perturbazione ammesso e, nei casi più comuni, $p \in \{0, 2, \infty\}$. Tali vincoli permettono di formalizzare rispettivamente attacchi sparsi, perturbazioni di energia limitata o modifiche limitate uniformemente sui pixel, pur non esauendo il problema della percettibilità visiva in scenari reali [16, 42].

Questa formulazione evidenzia la natura duale dell'attacco: da un lato la perturbazione deve essere limitata, dall'altro deve essere abbastanza efficace da modificare la decisione del sistema.

La Figura 2.2 rappresenta in forma concettuale questo meccanismo nel contesto di un attacco di evasion.




Figure 2.2: AML and conceptual representation of an evasion attack. A bounded perturbation δ is added to the original input x to obtain an adversarial image x' , which induces a wrong classifier prediction while preserving visual coherence for a human analyst.

Gli attacchi avversariali possono essere classificati secondo diversi criteri. Una prima distinzione riguarda la fase del ciclo di vita del modello in cui l'attacco viene condotto. Gli attacchi di poisoning intervengono durante la fase di addestramento, alterando i dati o le etichette con l'obiettivo di compromettere il modello risultante. Gli attacchi di evasion, invece, avvengono in fase di inferenza e consistono nella manipolazione degli input sottoposti a un modello già addestrato [15, 43]. Nel contesto della classificazione automatica di immagini in ambito forense, il focus principale è sugli attacchi di evasion, poiché lo scenario più rilevante è quello in cui

immagini già presenti in un dispositivo, archivio o evidenza digitale vengano alterate per ridurre la probabilità di essere correttamente individuate da uno strumento automatico.

Una seconda distinzione riguarda il livello di conoscenza disponibile all'attaccante. Negli scenari white-box, l'attaccante dispone di informazioni complete o estese sul modello, inclusi architettura, parametri, funzione di perdita e gradienti. In questi casi, la perturbazione può essere ottimizzata direttamente rispetto al comportamento interno del classificatore. Negli scenari black-box, invece, l'attaccante non conosce i dettagli del modello e può basarsi soltanto sugli output osservabili, su query ripetute, su modelli surrogati o sulla trasferibilità degli esempi adversariali tra classificatori differenti [15, 16, 17]. Questa distinzione è particolarmente importante nei contesti forensi, nei quali gli strumenti commerciali sono spesso sistemi chiusi e non consentono l'accesso diretto ai parametri del modello.

Un'ulteriore distinzione riguarda l'obiettivo dell'attacco. Negli attacchi *untargeted*, l'intento è semplicemente indurre il modello a produrre una classe diversa da quella corretta. Negli attacchi *targeted*, invece, l'obiettivo è spingere il classificatore verso una specifica classe scelta dall'attaccante. Nel caso di immagini forensi, un attacco *untargeted* può essere sufficiente a ridurre la capacità dello strumento di recuperare contenuti rilevanti, mentre un attacco *targeted* potrebbe mirare a far apparire un contenuto sensibile come appartenente a una categoria innocua. Tuttavia, in un contesto probatorio, anche forme meno controllate di errore possono avere conseguenze operative significative, poiché incidono sulla selezione, prioritizzazione e revisione delle evidenze digitali.

La letteratura ha proposto numerose tecniche per generare esempi adversariali, differenziate per vincolo di perturbazione, costo computazionale, conoscenza richiesta e trasferibilità. Metodi basati sul gradiente, come il Fast Gradient Sign Method (FGSM), sfruttano l'informazione fornita dalla funzione di perdita per individuare una direzione di perturbazione efficace [14]. Altri approcci mirano a produrre perturbazioni più ottimizzate, più sparse o localizzate, riducendo il numero di pixel modificati o approssimando perturbazioni minime capaci di attraversare il confine decisionale del classificatore [16, 44, 45, 46]. Nel presente capitolo tali tecniche sono richiamate soltanto come fondamento teorico; la selezione e l'applicazione degli attacchi nella pipeline sperimentale vengono discusse nel capitolo metodologico.

In ambito forense, il problema adversarial non riguarda soltanto la vulnerabilità astratta dei modelli, ma la loro affidabilità operativa all'interno di un processo investigativo. Se un sistema AI-based viene utilizzato per filtrare o classificare grandi quantità di immagini, una perturbazione capace di alterarne la predizione può ridurre la probabilità che un contenuto rilevante venga sottoposto tempestivamente all'attenzione dell'analista. Il rischio non consiste necessariamente nella produzione automatica di una decisione giudiziaria errata, ma nella possibilità che l'automazione modifichi il percorso di scoperta, prioritizzazione e interpretazione dell'evidenza. Per questo motivo, la robustezza adversarial deve essere considerata come una componente della più ampia affidabilità tecnico-forense del sistema.

2.5.1 Threat model e assunzioni dell'attaccante

Il threat model definisce le assunzioni relative alle capacità, agli obiettivi e ai vincoli dell'attaccante. In AML, esso è necessario per delimitare in modo rigoroso lo scenario di attacco e per evitare valutazioni di robustezza prive di un contesto operativo. Senza un threat model esplicito, il risultato di un test adversarial rischia di essere difficilmente interpretabile, poiché non è chiaro quale tipo di avversario il sistema sia in grado di tollerare e quali condizioni siano invece escluse dall'analisi [16, 17].

Nel contesto della classificazione automatica di immagini in ambito forense, l'attaccante può essere modellato come un soggetto interessato a ridurre la probabilità che determinati contenuti vengano correttamente identificati da uno strumento automatico. L'obiettivo principale non è necessariamente compromettere l'intero workflow forense, ma alterare la risposta del classificatore su specifici input visivi. In termini operativi, ciò può tradursi nella volontà di trasformare un'immagine rilevante in un'immagine classificata come non rilevante, ambigua o appartenente a una categoria diversa da quella attesa. Questo scenario è coerente con un attacco di evasion,

poiché la manipolazione avviene sull'input analizzato e non sulla fase di addestramento del modello.

Le capacità dell'attaccante possono variare in funzione dell'accesso al sistema bersaglio. In uno scenario white-box, l'attaccante conosce il modello e può calcolare perturbazioni ottimizzate rispetto ai suoi gradienti. In uno scenario black-box, più realistico per molti strumenti forensi commerciali, l'attaccante non dispone dei parametri interni del classificatore e deve basarsi su informazioni indirette, su modelli sostitutivi o sulla possibilità che esempi avversariali generati contro un modello siano trasferibili ad altri modelli. La distinzione tra questi scenari è essenziale perché incide sul tipo di attacco applicabile, sul costo computazionale richiesto e sulla plausibilità operativa della minaccia.

Il threat model deve inoltre specificare i vincoli imposti alla perturbazione. Nel dominio delle immagini, la modifica può essere limitata in termini di ampiezza numerica, distanza percettiva, numero di pixel alterati, area dell'immagine interessata o trasformazioni ammesse. In ambito forense, tali vincoli assumono un significato specifico: una manipolazione troppo evidente potrebbe essere rilevata dall'analista umano o da procedure di controllo dell'integrità, mentre una modifica più sottile potrebbe non compromettere la plausibilità visiva dell'immagine ma alterare comunque la predizione del modello. La nozione di impercettibilità deve quindi essere trattata con cautela, perché la percezione umana, la qualità del file e la rilevanza investigativa dei dettagli visivi non coincidono necessariamente con una semplice metrica matematica di distanza.

Un aspetto ulteriore riguarda la conoscenza del dominio forense da parte dell'attaccante. In scenari realistici, l'attaccante potrebbe non conoscere lo specifico strumento utilizzato dall'analista, ma potrebbe sapere che immagini e contenuti multimediali vengono spesso sottoposti a classificazione automatica. Questa conoscenza parziale può essere sufficiente a motivare trasformazioni orientate a ridurre la riconoscibilità automatica del contenuto, soprattutto quando tali trasformazioni non compromettono in modo evidente la leggibilità generale dell'immagine. Pertanto, il threat model deve considerare non soltanto l'attaccante altamente informato, ma anche scenari nei quali l'avversario opera con conoscenza limitata del modello e sfrutta trasformazioni generiche o trasferibili.

La definizione del threat model consente infine di collegare gli attacchi avversariali alle trasformazioni anti-forensi discusse nella sezione successiva. Sebbene entrambe le categorie possano alterare il comportamento di un sistema di classificazione, esse rispondono a logiche differenti. L'attacco avversarial è progettato rispetto al comportamento del modello, mentre la manipolazione anti-forense può mirare più in generale a degradare, mascherare o rendere meno informativa l'evidenza digitale. Questa distinzione è metodologicamente rilevante perché permette di valutare separatamente la robustezza del classificatore contro perturbazioni ottimizzate e contro trasformazioni realistiche che possono emergere nei normali flussi di acquisizione, condivisione o occultamento dei contenuti visivi.

La Tabella 2.1 sintetizza le principali dimensioni del threat model adottato nella valutazione sperimentale, distinguendo tra la formulazione teorica degli attacchi e il focus operativo-forense della presente tesi.

2.6 Tecniche anti-forensi su immagini digitali

Le tecniche anti-forensi comprendono l'insieme di strategie finalizzate a ostacolare, degradare o rendere meno affidabile l'analisi forense di un contenuto digitale. Nel dominio delle immagini, tali tecniche possono intervenire sia sulle proprietà visive del contenuto sia sulle caratteristiche statistiche e strutturali del file, con l'obiettivo di ridurre la possibilità di ricostruire la storia dell'immagine, rilevare manipolazioni, identificare tracce di acquisizione o classificare correttamente il contenuto raffigurato. In termini generali, l'anti-forensics non coincide necessariamente con la falsificazione esplicita dell'immagine, ma include anche trasformazioni capaci di alterare o mascherare informazioni rilevanti per l'analisi tecnica [25, 47].

Dimension	Theoretical scenarios	Thesis operational focus
Attack phase	Poisoning vs evasion	Evasion , since the manipulation affects already acquired or analysed images at inference time.
Adversary knowledge	White-box vs black-box	Primarily black-box at the forensic-tool level , consistently with closed commercial forensic tools and limited knowledge of their internal classification logic.
Attack objective	Targeted vs untargeted	Untargeted , with emphasis on performance degradation, missed detection, and reduced classification reliability.

Table 2.1: Threat model dimensions considered in the experimental robustness evaluation.

Nel contesto dell’image forensics, molte analisi si basano sulla presenza di tracce statistiche, artefatti di compressione, pattern di ricampionamento, caratteristiche del sensore o incoerenze tra regioni dell’immagine. Le trasformazioni anti-forensi mirano spesso a ridurre la visibilità di tali tracce o a introdurre modifiche che rendano più difficile distinguere tra contenuti originali, degradati o manipolati. Ad esempio, la ricompressione JPEG può modificare gli artefatti prodotti da precedenti operazioni di salvataggio, il ricampionamento può alterare le correlazioni spaziali introdotte da operazioni di ridimensionamento, mentre modifiche dell’istogramma o del contrasto possono cambiare la distribuzione dei valori di intensità dell’immagine [30, 31].

Una prima famiglia di trasformazioni riguarda la compressione e la ricompressione. Il formato JPEG, ampiamente utilizzato nei dispositivi digitali e nelle piattaforme di condivisione, applica una compressione con perdita che modifica le componenti frequenziali dell’immagine e introduce artefatti dipendenti dal livello di qualità scelto. Dal punto di vista forense, tali artefatti possono essere informativi, ma possono anche interferire con analisi successive. La ricompressione intenzionale può attenuare o sovrascrivere tracce precedenti, ridurre la qualità percettiva o modificare caratteristiche statistiche sfruttate da strumenti automatici. Per questa ragione, la compressione non è soltanto un normale passaggio tecnico nella gestione delle immagini, ma può diventare anche una trasformazione rilevante in chiave anti-forense [20, 47].

Una seconda categoria comprende operazioni geometriche e di ricampionamento, come resizing, cropping, rotazione e resampling. Tali trasformazioni possono essere comuni nei flussi ordinari di produzione e condivisione delle immagini, ma possono anche essere impiegate per modificare la scala degli oggetti, rimuovere regioni rilevanti, alterare la composizione della scena o introdurre pattern statistici differenti da quelli originari. Il ricampionamento, in particolare, può lasciare tracce rilevabili mediante analisi forense, ma può anche essere combinato con ulteriori trasformazioni per renderne più difficile l’identificazione [30, 31].

Ulteriori trasformazioni anti-forensi riguardano la degradazione visiva controllata. Sfocatura, rumore, riduzione della risoluzione, alterazione della nitidezza e modifiche cromatiche possono diminuire la leggibilità di dettagli rilevanti senza necessariamente rendere l’immagine inutilizzabile per un osservatore umano. In un workflow forense assistito da AI, queste trasformazioni sono particolarmente importanti perché possono modificare le feature visive utilizzate dai classificatori. Un oggetto ancora riconoscibile per l’analista potrebbe diventare meno discriminativo per il modello, soprattutto se la trasformazione altera bordi, texture, contrasti locali o relazioni spaziali tra le componenti della scena.

Accanto alle trasformazioni visibili o statisticamente rilevabili, un’ulteriore categoria di tecniche riconducibili al dominio anti-forense riguarda la steganografia, ossia l’occultamento di informazione all’interno di un contenuto digitale. Nel caso delle immagini, dati aggiuntivi possono essere inseriti alterando porzioni poco percettibili della rappresentazione, ad esempio i bit meno significativi dei valori di pixel. Sebbene la steganografia abbia finalità diverse rispetto alla de-

gradazione visiva o alla ricompressione, essa è rilevante nel quadro dell'immagine forensics perché può introdurre contenuti nascosti, modificare proprietà statistiche del file e rendere necessarie analisi specializzate per distinguere tra immagine apparentemente ordinaria e immagine usata come vettore di occultamento [20, 25].

Nel presente lavoro, la steganografia viene richiamata come componente panoramica del dominio anti-forense, mentre la valutazione sperimentale si concentra su trasformazioni visive e statistiche direttamente rilevanti per la robustezza della classificazione automatica.

È importante distinguere le tecniche anti-forensi dagli attacchi avversariali discussi nella sezione precedente. Gli attacchi avversariali sono generalmente progettati rispetto al comportamento di un modello e mirano a indurre una predizione errata attraverso perturbazioni ottimizzate. Le trasformazioni anti-forensi, invece, possono essere indipendenti dal modello e orientate più genericamente a degradare, mascherare o alterare l'evidenza digitale. Questa distinzione non implica una separazione assoluta: una trasformazione anti-forense può produrre effetti avversariali su un classificatore, così come una perturbazione avversariale può avere conseguenze anti-forensi nel momento in cui riduce l'utilità investigativa dell'immagine. Tuttavia, dal punto di vista metodologico, le due categorie devono essere mantenute distinte perché presuppongono capacità, obiettivi e assunzioni differenti sull'attaccante.

Nel caso della classificazione automatica di immagini, le tecniche anti-forensi assumono rilievo perché possono incidere sulla robustezza operativa dei sistemi AI-based anche in assenza di un attacco ottimizzato contro il modello. Un'immagine ricompressa, ridimensionata, sfocata o alterata nel contrasto può rappresentare un input realistico, compatibile con normali processi di acquisizione, archiviazione o condivisione. Tuttavia, le stesse trasformazioni possono essere sfruttate intenzionalmente per ridurre la probabilità che un contenuto venga correttamente classificato. La difficoltà consiste quindi nel distinguere tra degradazioni fisiologiche del ciclo di vita digitale dell'immagine e trasformazioni applicate con finalità di occultamento o riduzione dell'efficacia analitica.

Dal punto di vista forense, questa ambiguità richiede una valutazione prudente. Non ogni immagine compressa, ridimensionata o degradata può essere considerata il risultato di una condotta anti-forense; al contrario, molte trasformazioni sono conseguenze ordinarie dell'uso di dispositivi mobili, social network, applicazioni di messaggistica e sistemi di archiviazione. Tuttavia, quando l'obiettivo è valutare l'affidabilità di strumenti automatici, è necessario includere tali trasformazioni nello spazio degli scenari realistici. La robustezza di un classificatore forense non dipende soltanto dalla sua accuratezza su immagini pulite, ma anche dalla capacità di mantenere un comportamento stabile in presenza di degradazioni plausibili, intenzionali o accidentali.

In questa prospettiva, le tecniche anti-forensi su immagini digitali costituiscono un ponte tra l'immagine forensics tradizionale e la valutazione della robustezza dei modelli di computer vision. Esse evidenziano che l'immagine non è un input statico e neutro, ma un artefatto digitale soggetto a trasformazioni tecniche che possono incidere sia sulla sua interpretabilità umana sia sulla sua elaborazione automatica. Per tale ragione, la valutazione di strumenti AI-based in ambito forense deve considerare non solo attacchi avversariali formalmente definiti, ma anche manipolazioni e degradazioni compatibili con scenari operativi realistici.

La Tabella 2.2 sintetizza la distinzione concettuale tra *adversarial attacks* e *anti-forensic transformations* nel contesto della classificazione automatizzata di immagini.

2.7 Explainability, robustezza e affidabilità dei modelli

La valutazione di un modello AI-based non può essere ricondotta esclusivamente alla misurazione della sua accuratezza media. In un contesto forense, infatti, l'utilità di un sistema automatico dipende anche dalla stabilità delle sue predizioni, dalla capacità di gestire input degradati o fuori distribuzione, dalla trasparenza delle informazioni fornite all'analista e dalla possibilità di documentare in modo verificabile il ruolo svolto dal modello nel workflow invest-

Dimension	Adversarial attacks	Anti-forensic transformations
Primary target	Decision function of the AI-based model.	Visual, statistical, or structural properties of the digital image file.
Nature	Perturbations designed to alter the model prediction.	Manipulations or degradations such as JPEG recompression, resizing, blur, or contrast modification.
Model dependency	Usually direct or surrogate-based, especially in white-box or transfer-based settings.	Usually low or indirect, since the transformation can often be applied without knowing the classifier.
Visibility	Often designed to be imperceptible, sparse, or localized.	Often compatible with visible degradations or ordinary image processing operations.
Forensic relevance	May affect automated evidence selection by inducing false positives or false negatives.	May alter the evidentiary quality of the image and reduce the reliability of automated analysis.

Table 2.2: Comparison between adversarial attacks and anti-forensic transformations in the context of automated image classification.

igativo. Accuratezza, robustezza, interpretabilità e affidabilità sono quindi dimensioni complementari, che devono essere considerate congiuntamente quando un sistema di classificazione automatica viene impiegato a supporto dell’analisi di evidenze digitali [12, 13].

La robustezza può essere definita, in termini generali, come la capacità di un modello di mantenere un comportamento stabile e coerente in presenza di variazioni dell’input. Tali variazioni possono essere accidentali, come rumore, compressione, bassa risoluzione o condizioni di acquisizione non ideali, oppure intenzionali, come perturbazioni avversariali e trasformazioni anti-forensi. Nel dominio della computer vision, la robustezza non riguarda soltanto la resistenza a piccole perturbazioni numeriche, ma anche la capacità del classificatore di gestire cambiamenti realistici nelle proprietà visive dell’immagine, nella distribuzione dei dati e nella qualità del contenuto analizzato [22, 48].

L’affidabilità rappresenta un concetto più ampio della robustezza. Un modello può essere robusto rispetto a una determinata famiglia di perturbazioni, ma non necessariamente affidabile in senso forense. L’affidabilità richiede che il sistema produca risultati sufficientemente stabili, documentabili e interpretabili rispetto al contesto d’uso. In particolare, un classificatore impiegato in un workflow di DF deve essere valutato rispetto alla sua capacità di supportare l’analista senza sostituirne il giudizio, di segnalare incertezze o casi ambigui, di non sovrastimare la propria confidenza e di mantenere prestazioni coerenti anche su dati diversi da quelli osservati durante l’addestramento. Questa distinzione è essenziale perché un output formalmente corretto in media può comunque risultare poco affidabile se non è stabile, verificabile o adeguatamente contestualizzato.

In questo quadro si colloca il ruolo dell’XAI. Le tecniche di explainability mirano a fornire strumenti per rendere più comprensibile il comportamento dei modelli, soprattutto quando essi operano come sistemi complessi o parzialmente opachi. In computer vision, tali tecniche possono includere mappe di salienza, metodi di attribuzione, visualizzazioni delle regioni dell’immagine maggiormente influenti sulla predizione e spiegazioni locali del comportamento del classificatore. Esempi noti includono approcci model-agnostic, come LIME e SHAP, e tecniche di attribuzione o localizzazione visiva, come Integrated Gradients e class activation mapping [49, 50, 51, 52].

L’impiego dell’XAI in ambito forense deve tuttavia essere interpretato con cautela. Una spiegazione visuale non costituisce una prova autonoma della correttezza del modello, né garantisce che il classificatore abbia appreso concetti semanticamente coerenti con il ragionamento umano.

Le mappe di salienza, ad esempio, possono indicare regioni dell'immagine rilevanti per la predizione, ma non dimostrano necessariamente che il modello abbia riconosciuto l'oggetto di interesse nel modo atteso. Inoltre, spiegazioni generate da metodi differenti possono divergere tra loro, e la loro stabilità può essere influenzata da perturbazioni dell'input o da variazioni del modello [12, 53].

Nonostante tali limiti, l'XAI può fornire un supporto utile nella valutazione della robustezza operativa. Confrontare le spiegazioni prodotte su immagini pulite e manipolate può aiutare a individuare variazioni nel comportamento del modello, spostamenti dell'attenzione verso regioni non pertinenti o dipendenza da artefatti visivi non rilevanti. In questo senso, l'explainability non deve essere intesa come uno strumento conclusivo di validazione, ma come una componente ausiliaria dell'analisi, utile a formulare ipotesi sul comportamento del classificatore e a documentare eventuali anomalie nella risposta del sistema.

La relazione tra robustezza ed explainability è particolarmente importante nei casi in cui un modello mantiene la stessa etichetta ma modifica il razionale apparente della predizione, oppure produce una classificazione errata concentrandosi su regioni visive non pertinenti. Tali situazioni evidenziano che la sola accuratezza non è sufficiente per comprendere il comportamento del sistema. In un contesto forense, la possibilità di osservare come il modello reagisce a degradazioni, trasformazioni anti-forensi o perturbazioni avversariali può contribuire a una valutazione più completa della sua affidabilità, soprattutto quando l'output automatico viene utilizzato per filtrare o prioritizzare grandi quantità di immagini.

Un ulteriore elemento riguarda la calibrazione della confidenza. I modelli DL possono produrre predizioni con score elevati anche in presenza di input ambigui, degradati o fuori distribuzione. Questo fenomeno è problematico nei workflow assistiti da AI, perché un'elevata confidenza apparente può indurre l'utente a sovrastimare l'affidabilità dell'output. La robustezza operativa richiede quindi non solo che il modello mantenga buone prestazioni su dati manipolati, ma anche che l'incertezza venga trattata in modo coerente e non fuorviante, soprattutto nei casi in cui l'immagine non appartenga chiaramente alle classi previste dal sistema [39, 40].

Nel quadro della presente tesi, explainability, robustezza e affidabilità sono considerate come dimensioni complementari della valutazione di strumenti AI-based in ambito forense. La robustezza permette di misurare la stabilità delle predizioni rispetto a perturbazioni avversariali e trasformazioni anti-forensi; l'XAI consente di osservare, con le dovute cautele, alcune dinamiche interne o locali del processo decisionale; l'affidabilità integra questi elementi nel contesto operativo, considerando il ruolo dell'analista, la documentabilità del processo e le possibili conseguenze di errori automatici nella selezione delle evidenze. Questa impostazione consente di superare una valutazione puramente prestazionale e di collocare il comportamento dei modelli all'interno delle esigenze di verificabilità proprie della DF.

2.8 Profili giuridici e normativi dell'AI in ambito forense

L'impiego dell'AI in ambito forense non solleva soltanto questioni tecniche, ma incide anche sui presupposti di affidabilità, verificabilità e controllo che caratterizzano la prova digitale. Nei procedimenti investigativi e giudiziari, un sistema automatico può contribuire alla selezione, classificazione o prioritizzazione di contenuti rilevanti, ma non può sostituire la valutazione dell'operatore forense né quella dell'autorità giudiziaria. La dimensione giuridica dell'AI nella DF deve quindi essere ricondotta al principio secondo cui ogni risultato tecnico utilizzato a fini probatori deve poter essere documentato, contestualizzato e, per quanto possibile, verificato mediante procedure trasparenti e ripetibili [2, 6, 54].

La prova digitale è caratterizzata da una particolare vulnerabilità alla modifica, alla perdita di contesto e alla difficoltà di attribuzione. Per tale ragione, gli standard e le linee guida internazionali insistono sulla necessità di preservare integrità, autenticità, tracciabilità e catena di custodia lungo l'intero ciclo di gestione dell'evidenza [6, 29]. Quando l'analisi è supportata da moduli AI-based, questi requisiti non vengono meno, ma si estendono anche al funzionamento dello strumento automatico. Diventa quindi necessario documentare non soltanto l'origine e il

trattamento del dato, ma anche il ruolo svolto dal modello, le condizioni di utilizzo, le metriche disponibili, i limiti noti e l'eventuale intervento umano nella valutazione del risultato.

Nel quadro europeo, il General Data Protection Regulation (GDPR) rappresenta un riferimento rilevante per il trattamento automatizzato dei dati personali. In particolare, l'art. 22 disciplina il diritto dell'interessato a non essere sottoposto a decisioni basate esclusivamente su trattamenti automatizzati, inclusa la profilazione, quando tali decisioni producano effetti giuridici o incidano in modo analogo e significativo sulla persona. Sebbene l'attività forense presenti specificità proprie, questo principio evidenzia la necessità di evitare che output algoritmici siano trattati come decisioni autonome e non contestabili. L'art. 35, inoltre, prevede la valutazione d'impatto sulla protezione dei dati, indicata come Data Protection Impact Assessment (DPIA), nei casi di trattamenti suscettibili di presentare rischi elevati, rafforzando l'esigenza di analizzare preventivamente rischi, finalità, proporzionalità e misure di mitigazione nei sistemi automatizzati [55, 56].

Un ulteriore riferimento è costituito dall'AI Act, che introduce un modello regolatorio fondato sul rischio e attribuisce particolare attenzione ai sistemi impiegati in contesti sensibili, tra cui attività di law enforcement e amministrazione della giustizia. In tali ambiti, l'uso dell'AI può incidere su diritti fondamentali, garanzie procedurali e capacità delle parti di comprendere o contestare l'esito di un processo decisionale assistito. Per questo motivo, i sistemi classificati come ad alto rischio sono soggetti a requisiti di governance dei dati, documentazione tecnica, registrazione dei log, trasparenza, supervisione umana, accuratezza, robustezza e cybersecurity [27]. Tali requisiti sono particolarmente coerenti con le esigenze della DF, nella quale ogni passaggio rilevante deve poter essere ricostruito e giustificato.

Nel contesto specifico della classificazione automatica di immagini, il problema giuridico non consiste necessariamente nel fatto che il modello produca una decisione finale sul valore probatorio dell'immagine. Più realisticamente, il rischio riguarda l'influenza indiretta dell'automazione sul percorso investigativo: un falso negativo può ridurre la probabilità che un'immagine rilevante venga esaminata tempestivamente, mentre un falso positivo può orientare l'attenzione dell'analista verso contenuti non pertinenti. In entrambi i casi, l'output del sistema automatico può incidere sulla selezione e sulla priorità delle evidenze, pur non costituendo formalmente una decisione giudiziaria. Questo rende necessario adottare un approccio prudente, nel quale la classificazione automatica sia considerata uno strumento di supporto e non una fonte autonoma di accertamento.

La supervisione umana rappresenta quindi un requisito centrale. Essa non deve essere intesa come un controllo meramente formale, ma come la possibilità effettiva per l'operatore di comprendere il ruolo del sistema, valutarne l'output, riconoscere condizioni di incertezza e intervenire quando il risultato automatico appaia incoerente o non sufficientemente affidabile. In ambito forense, la supervisione assume anche una funzione documentale: l'analista deve poter spiegare se e come l'output del modello abbia contribuito alla selezione dell'evidenza, quali verifiche siano state svolte e quali limiti siano stati considerati nella valutazione complessiva.

L'opacità dei modelli DL introduce ulteriori criticità. Se un sistema produce una classificazione senza rendere comprensibili le ragioni tecniche della predizione, la possibilità di contestare, replicare o valutare criticamente il risultato può risultare ridotta. Le tecniche di XAI possono mitigare parzialmente tale problema, fornendo indicazioni sulle regioni dell'immagine o sulle caratteristiche che hanno maggiormente influenzato la predizione. Tuttavia, come discusso nella sezione precedente, tali spiegazioni non devono essere confuse con una prova della correttezza del modello. Esse costituiscono strumenti di supporto interpretativo, utili alla documentazione e alla revisione, ma non sostituiscono la validazione tecnica né il giudizio umano [12, 13].

Alla luce di questi profili, la robustezza dei sistemi AI-based assume anche una rilevanza giuridica e non soltanto tecnica. Un modello vulnerabile a perturbazioni avversariali, degradazioni realistiche o trasformazioni anti-forensi può compromettere la qualità del supporto fornito all'analista e ridurre l'affidabilità del workflow investigativo. La valutazione sperimentale della robustezza, pertanto, contribuisce a chiarire entro quali limiti un sistema automatico possa essere utilizzato in modo responsabile, quali condizioni possano generare errori e quali cautele

debbano accompagnarne l'impiego in scenari forensi.

In conclusione, l'uso dell'AI nella DF richiede un equilibrio tra efficienza operativa e garanzie procedurali. L'automazione può migliorare la capacità di analizzare grandi quantità di dati, ma deve essere integrata in un processo controllato, documentato e supervisionato. Nel caso della classificazione automatica di immagini, tale equilibrio richiede che il modello sia valutato non solo rispetto alla sua accuratezza su dati puliti, ma anche rispetto alla sua robustezza, spiegabilità, tracciabilità e capacità di operare in condizioni realistiche. Questi elementi costituiscono il presupposto teorico per la metodologia sperimentale sviluppata nei capitoli successivi.

Chapter 3

State of the Art

In questo capitolo viene analizzata la letteratura scientifica e tecnica esistente riguardante i principali ambiti della tesi: le tecniche tradizionali e moderne della Digital Forensics, l'impiego dell'Intelligenza Artificiale in questo contesto, gli attacchi avversariali orientati alle immagini, le principali tecniche di perturbazione e le metodologie di valutazione della robustezza. L'obiettivo è delineare lo stato dell'arte, individuare le principali criticità ancora aperte e motivare il contributo innovativo del presente lavoro.

3.1 Digital Forensics: tecniche e pratiche attuali

La **Digital Forensics** (DF) rappresenta oggi una disciplina chiave nelle indagini penali e civili che coinvolgono dispositivi digitali, ambienti informatici distribuiti e piattaforme online. Essa si occupa dell'intero ciclo di vita dell'evidenza digitale — dall'identificazione iniziale fino alla sua presentazione in sede giudiziaria — con l'obiettivo di garantirne l'ammissibilità processuale secondo criteri tecnico-scientifici consolidati [costantini2019digitaldigital, 25].

Affinché un procedimento forense possa essere considerato valido, è necessario che vengano rispettati una serie di principi fondamentali, definiti dagli standard internazionali come quelli dell'ENFSI (European Network of Forensic Science Institutes), del NIST (National Institute of Standards and Technology) e del protocollo ACPO (Association of Chief Police Officers). Tali principi sono sintetizzati nella Tabella 3.1.

Linee guida e tendenze recenti nella Digital Forensics

Negli ultimi anni, la disciplina della **Digital Forensics** ha dovuto adattarsi a scenari tecnologici sempre più complessi, caratterizzati dalla crescente diffusione di servizi *cloud*, dispositivi *Internet of Things* (IoT) e sistemi basati su *Intelligenza Artificiale* (AI). Le metodologie tradizionali, incentrate sull'acquisizione e analisi di dispositivi fisici, sono oggi integrate da procedure e standard aggiornati per garantire la validità probatoria in contesti distribuiti e ad alta dinamicità [57, 58, 59].

Un contributo rilevante in tal senso è fornito dal documento **ENFSI Guidelines for Forensic Digital Imaging and Video Analysis** (2020) [enfsi2020guidelines], che definisce criteri operativi per l'acquisizione, il trattamento e l'analisi di immagini e video digitali, includendo raccomandazioni specifiche per preservare l'integrità del materiale probatorio in ambienti eterogenei. Le linee guida pongono particolare enfasi sulla *catena di custodia*, la documentazione meticolosa dei processi e l'uso di strumenti forensi convalidati, ribadendo la necessità di standardizzazione per garantire la riproducibilità delle analisi.

Digital Forensics in ambienti *cloud*. La **cloud forensics** rappresenta una delle aree più sfidanti per l'investigazione digitale contemporanea. In ambienti multi-tenant, dove le risorse

fisiche sono condivise da più utenti, diventa complesso garantire l'isolamento delle evidenze e la non contaminazione dei dati [57]. Inoltre, l'assenza di un accesso fisico diretto all'hardware complica le operazioni di acquisizione bit-a-bit tipiche delle metodologie tradizionali [58]. Le indagini in cloud richiedono quindi procedure cooperative con i fornitori di servizi, l'utilizzo di API forensi e l'adozione di protocolli di autenticazione e verifica che preservino l'integrità e l'autenticità delle evidenze [57, 58]. Sfide ulteriori includono:

- la distribuzione geografica dei dati su più giurisdizioni, con implicazioni legali e di sovranità;
- la volatilità delle informazioni, legata a processi di allocazione dinamica delle risorse e politiche di retention limitate;
- la necessità di logging e monitoraggio continuo per garantire la tracciabilità delle operazioni.

IoT Forensics. L'espansione dell'ecosistema **Internet of Things** ha introdotto nuove superfici di acquisizione probatoria, comprendenti sensori, wearable devices, sistemi di video-sorveglianza smart e veicoli connessi [59]. La peculiarità dell'IoT forensics risiede nella natura distribuita e resource-constrained dei dispositivi, che impone strategie di acquisizione spesso *live* e con capacità di memorizzazione limitata. I framework recenti suggeriscono approcci ibridi, basati su acquisizioni dirette dai dispositivi quando possibile e, in alternativa, su raccolta centralizzata dei dati dai gateway o dalle piattaforme cloud a cui essi si connettono. La preservazione della *chain of custody* in contesti IoT è particolarmente complessa a causa della varietà di protocolli e standard di comunicazione impiegati [59].

Integrazione dell'AI nelle pratiche forensi. L'applicazione dell'**Intelligenza Artificiale** nella Digital Forensics sta progressivamente migrando dalle sperimentazioni accademiche a soluzioni operative, specialmente per il *triage* rapido di grandi moli di dati multimediali e la classificazione automatica di contenuti [25]. Tuttavia, documenti recenti sottolineano la necessità di sviluppare linee guida specifiche per l'impiego di sistemi AI in ambito forense, considerando la loro vulnerabilità ad attacchi adversariali e la natura opaca dei processi decisionali [nowroozi2024robustnessrobustness]. Le buone pratiche emergenti suggeriscono:

- validazione preventiva dei modelli AI su dataset rappresentativi del contesto operativo;
- tracciabilità e auditabilità delle decisioni algoritmiche;
- integrazione di moduli di rilevamento di input anomali o potenzialmente manipolati.

In sintesi, l'evoluzione recente delle linee guida forensi riflette un passaggio da un approccio prevalentemente tecnico a uno multidimensionale, che integra aspetti tecnologici, procedurali e legali per rispondere alle sfide poste dai moderni scenari digitali [nowroozi2024robustnessrobustness].

Principio	Descrizione
Integrità	I dati digitali originali non devono essere alterati durante le fasi di acquisizione e analisi. Devono essere applicati metodi di verifica (es. hash crittografici) per garantirne l'autenticità.
Tracciabilità	Ogni operazione compiuta sull'evidenza deve essere documentata accuratamente, garantendo la ricostruzione completa della <i>catena di custodia</i> .
Riproducibilità	Le analisi forensi devono essere replicabili da altri esperti indipendenti, a parità di dati e strumenti, così da assicurare l'obiettività del risultato.
Validità scientifica	Le tecniche e gli strumenti utilizzati devono essere fondati su basi teoriche e sperimentali solide, preferibilmente convalidati dalla comunità scientifica [costantini2019digitaldigital, 60].

Table 3.1: Principi fondamentali della Digital Forensics secondo gli standard internazionali

Modello operativo della Digital Forensics

Il processo di Digital Forensics si fonda su una sequenza metodologica ben definita, la cui applicazione rigorosa è essenziale per garantire l'affidabilità dell'intero procedimento investigativo. Le fasi operative tradizionali riflettono una standardizzazione internazionale (es. ISO/IEC 27037, NIST SP 800-86), la cui adozione consente una gestione strutturata delle evidenze digitali.

La Tabella 3.2 sintetizza le quattro fasi principali comunemente adottate nei flussi di lavoro forense.

Fase	Descrizione
Identificazione	Riconoscimento delle possibili fonti di evidenza digitale, incluse memorie di massa, dispositivi mobili, ambienti cloud, reti e servizi online. Questa fase è cruciale per delimitare correttamente il perimetro dell'indagine.
Acquisizione	Creazione di una copia forense dei dati mediante tecniche come l'imaging bit-a-bit e l'uso di hash (MD5, SHA-256) per garantire l'integrità. È fondamentale l'impiego di dispositivi write-blocker per evitare modifiche accidentali.
Analisi	Estrazione, correlazione e interpretazione delle informazioni digitali attraverso strumenti automatizzati e competenze esperte. Include tecniche come file carving, analisi dei log, metadata extraction, memory forensics e timeline reconstruction.
Reporting	Documentazione tecnica e legale dei risultati dell'analisi. Il report deve essere chiaro, replicabile e comprensibile anche a figure non tecniche (es. giudici, avvocati), rispettando i requisiti di validità probatoria.

Table 3.2: Fasi operative del processo di Digital Forensics

Strumenti utilizzati

L'analisi forense digitale si fonda sull'utilizzo di strumenti software specializzati che supportano le diverse fasi dell'investigazione: dall'acquisizione dei dati alla loro analisi e successiva presentazione in sede giudiziaria. Tali strumenti si distinguono principalmente in due categorie: soluzioni commerciali (*Commercial Off-The-Shelf*, COTS) e soluzioni open-source, ciascuna con vantaggi e limitazioni che ne influenzano l'adozione in contesti operativi.

Tra le soluzioni commerciali più consolidate vi è **X-Ways Forensics**, noto per le sue prestazioni elevate in termini di efficienza e capacità di lavorare con immagini forensi di grandi dimensioni. Il software offre funzionalità avanzate come l'analisi di file system, la ricostruzione di timeline e il carving di file cancellati. Un'altra piattaforma largamente utilizzata è **Magnet AXIOM**, particolarmente apprezzata per la sua interfaccia intuitiva e per l'integrazione di moduli basati su Intelligenza Artificiale, in grado di automatizzare la classificazione di immagini e contenuti multimediali sospetti.

Cellebrite UFED rappresenta lo standard di riferimento per l'estrazione di dati da dispositivi mobili, utilizzato in ambito investigativo e forense da numerose forze dell'ordine a livello internazionale. La sua efficacia nel decifrare e analizzare contenuti protetti, come quelli provenienti da app di messaggistica cifrata, lo rende uno strumento fondamentale nelle indagini su smartphone. Complementare è **Oxygen Forensic Detective**, anch'esso dedicato all'analisi di dispositivi mobili e ambienti cloud, con funzionalità specifiche per il tracciamento di comunicazioni, geolocalizzazioni e profili utente.

Sul versante open-source, uno degli strumenti più diffusi è **Autopsy**, un'interfaccia grafica che facilita l'utilizzo del toolkit **The Sleuth Kit**. Quest'ultimo fornisce una suite di strumenti a riga di comando per l'analisi di dischi e file system, ed è alla base di molte distribuzioni forensi. Autopsy è ampiamente utilizzato in ambito accademico e investigativo, grazie alla sua capacità

di gestire evidenze provenienti da diverse fonti e alla modularità che consente l'integrazione di plugin personalizzati.

Per l'analisi della memoria volatile, fondamentale in scenari di analisi post-compromissione o di malware forensics, viene frequentemente impiegato **Volatility**. Si tratta di un framework flessibile in grado di estrarre strutture complesse dalla RAM, come processi attivi, connessioni di rete, credenziali, e persino code di esecuzione. Infine, **Plaso (log2timeline)** consente la creazione automatizzata di timeline forensi a partire da una molteplicità di log di sistema, browser, dispositivi USB, e altre fonti temporali, facilitando l'identificazione di eventi critici in sequenze temporali complesse.

L'utilizzo combinato di strumenti commerciali e open-source è spesso strategico: i primi garantiscono affidabilità certificata e aggiornamenti costanti, mentre i secondi offrono maggiore trasparenza, personalizzazione e possibilità di integrazione in pipeline di analisi più flessibili. In contesti ad alta sensibilità, come la digital forensics applicata alla sicurezza nazionale o alle indagini su reati informatici gravi, questa sinergia diventa fondamentale per garantire l'efficacia investigativa e la robustezza delle conclusioni prodotte [phd'unisi'068552].

Limiti delle tecniche attuali e sfide emergenti

L'integrazione di tecniche di *Machine Learning* (ML) nella Digital Forensics ha portato vantaggi in termini di automazione e scalabilità, ma ha anche introdotto nuove vulnerabilità. In particolare, i modelli basati su reti neurali profonde (Deep Learning) risultano altamente sensibili a perturbazioni artificiali anche minime, note come *adversarial examples* [phd'unisi'068552].

Queste perturbazioni, spesso invisibili all'occhio umano, sono in grado di eludere i sistemi di classificazione automatica, compromettendo così la validità probatoria dell'evidenza. Secondo Nowroozi, la facilità con cui tali attacchi possono essere generati rende problematica l'adozione di strumenti AI-based in scenari forensi reali [phd'unisi'068552].

“The easiness with which it is possible to disable ML tools and in particular DL tools makes it very hard to exploit these tools in a multimedia forensic scenario and more in general for security-oriented applications.” [phd'unisi'068552]

L'autore sottolinea inoltre come la maggior parte dei tool attuali non sia progettata per operare in ambienti ostili. Di conseguenza, diventa cruciale lo sviluppo di strumenti **robusti e consapevoli dell'avversario** (*adversary-aware*), in grado di resistere a manipolazioni mirate dei dati in ingresso.

Verso l'intelligenza artificiale nella DF

In risposta alle sfide emergenti — come l'aumento dei volumi di dati, la diffusione di tecniche anti-forensi, la crittografia avanzata e la distribuzione delle evidenze su più dispositivi — la comunità scientifica ha iniziato a introdurre approcci basati su AI all'interno del workflow forense.

L'Intelligenza Artificiale può essere utilizzata per:

- Automatizzare il **triage** di grandi moli di dati multimediali;
- Eseguire **classificazione semantica** di contenuti (armi, volti, testo);
- Abilitare tecniche di **profilazione comportamentale** e correlazione temporale;
- Supportare il **decision making** investigativo attraverso modelli predittivi [costantini2019digitaldigital, phd'unisi'068552].

Tuttavia, come sarà analizzato nei prossimi paragrafi, l'affidabilità di tali sistemi resta un punto critico, specialmente in presenza di input manipolati con finalità anti-forense [nowroozi2024robustnessrobustness].

Come illustrato in Figura 3.1, l'AI può intervenire in diverse fasi del processo forense: dal triage iniziale dei contenuti digitali, fino alla classificazione semantica, clustering di immagini sospette

e correlazione di eventi. L'efficacia di queste attività dipende dalla robustezza dei modelli e dalla qualità del dataset.




Figure 3.1: Principali applicazioni dell'Intelligenza Artificiale nella Digital Forensics

3.2 AI nella Digital Forensics: strumenti e applicazioni

Negli ultimi anni, l'Intelligenza Artificiale (AI) ha assunto un ruolo sempre più rilevante nel panorama della Digital Forensics, contribuendo in maniera sostanziale alla modernizzazione dei processi investigativi. La sua introduzione risponde all'esigenza crescente di gestire volumi sempre maggiori di dati digitali, spesso non strutturati, provenienti da dispositivi eterogenei e in tempi estremamente ridotti. L'AI, e in particolare il *Machine Learning* (ML), consente di automatizzare fasi critiche dell'analisi forense e di identificare correlazioni complesse e pattern nascosti difficilmente rilevabili con metodi tradizionali [costantini2019digitaldigital].

Tra le principali applicazioni AI-driven in ambito forense si possono identificare:

- **Classificazione automatica di immagini e video**, finalizzata all'identificazione di contenuti rilevanti per l'indagine (es. armi da fuoco, contenuti violenti o illeciti, presenza di minori). Le reti neurali convoluzionali (CNN), in particolare architetture come ResNet, VGG o EfficientNet, sono state ampiamente utilizzate per addestrare classificatori capaci di analizzare grandi corpus multimediali con elevata accuratezza [61].
- **Riconoscimento facciale e di oggetti**, spesso utilizzato in contesti investigativi e di intelligence per identificare soggetti coinvolti, tracciare interazioni o rintracciare volti già presenti in banche dati. Tecnologie come *YOLOv5*, *FaceNet* e *OpenFace* sono comunemente impiegate nei sistemi di sorveglianza intelligenti e nei software forensi di nuova generazione.
- **Analisi forense su dispositivi mobili**, ambito in cui l'AI è integrata all'interno di strumenti commerciali come **Magnet AXIOM** e **Cellebrite UFED**, con funzionalità di categorizzazione automatica di immagini e messaggi, rilevamento di contenuti sospetti e suggerimenti basati su similarità semantica tra elementi multimediali.
- **Triage multimediale e content-based filtering**, utile per l'analisi preliminare di grandi dataset, ad esempio in operazioni di digital triage su sistemi compromessi o dispositivi sequestrati. Algoritmi AI-based permettono di scartare in modo automatico contenuti irrilevanti e concentrare l'attenzione su quelli di interesse investigativo.

Oltre alle CNN, altre classi di modelli come le *Recurrent Neural Networks* (RNN) o gli *Transformer*-based (es. Vision Transformer, BERT applicato a metadati testuali) stanno progressiva-

mente emergendo nella digital forensics, specialmente in task come la ricostruzione automatica di eventi o l'analisi di log complessi.

Esperienze sperimentali e benchmark disponibili

Nonostante il crescente interesse accademico e industriale per l'integrazione dell'Intelligenza Artificiale nei flussi di lavoro forensi, la letteratura scientifica che documenta **pipeline AI-based operative e valutate in scenari realistici** rimane sorprendentemente limitata. Alcuni contributi recenti rappresentano però tentativi significativi in questa direzione.

Costantini et al. [costantini2019digitaldigital] hanno proposto un framework per la *multimedia forensics* basato su reti neurali profonde, integrando moduli di classificazione delle immagini e rilevamento di manipolazioni in un contesto simulato di indagine. L'architettura è stata progettata per combinare tecniche tradizionali di analisi forense con modelli di *deep learning* in grado di automatizzare la fase di triage, riducendo i tempi di identificazione di contenuti sospetti.

Più recentemente, Nowroozi et al. [nowroozi2024robustnessrobustness] hanno analizzato la robustezza di modelli di *intrusion detection* e classificazione forense basati su AI quando esposti a perturbazioni intenzionali, inclusi attacchi *adversarial*. Il lavoro evidenzia come, anche in pipeline costruite con attenzione alla validazione tecnica, perturbazioni minime possano degradare drasticamente le prestazioni dei classificatori, compromettendo l'affidabilità dell'analisi in contesti investigativi.

Questi studi sottolineano una criticità importante: **la carenza di benchmark pubblici e specifici per la valutazione dell'AI in Digital Forensics** [22]. A differenza di altri domini del machine learning, dove dataset di riferimento come ImageNet, COCO o CIFAR-10 hanno permesso un'evoluzione rapida e comparabile delle tecniche, in ambito forense i dataset disponibili sono spesso:

- di dimensioni ridotte e non rappresentativi della varietà di scenari reali;
- vincolati da restrizioni legali e di privacy che ne impediscono la condivisione;
- eterogenei per formato, qualità e tipologia di contenuti.

Questa mancanza di standardizzazione rende difficile confrontare le prestazioni di diversi modelli e metodologie, ostacolando l'avanzamento coordinato della ricerca. La definizione di benchmark realistici e condivisibili rappresenta pertanto una priorità strategica per il futuro della disciplina.

Strumenti AI-oriented e contesto operativo

Nel contesto applicativo reale, l'integrazione di modelli AI avviene tramite componenti embedded all'interno di strumenti già in uso nelle attività investigative. Cellebrite, ad esempio, utilizza il motore di riconoscimento delle immagini per suggerire automaticamente categorie come "nudo", "arma", "droga", riducendo il carico cognitivo sull'analista umano. Allo stesso modo, Magnet AXIOM consente di eseguire clustering automatici di conversazioni e immagini per agevolare l'analisi contestuale.

Queste funzioni, pur essendo estremamente utili in termini di efficienza, sollevano anche importanti questioni di affidabilità e trasparenza, specie se i modelli vengono utilizzati come base per decisioni probatorie. Infatti, la natura opaca (*black-box*) dei modelli deep learning, unita alla loro vulnerabilità a perturbazioni ad-hoc, rappresenta un potenziale rischio per la validità delle evidenze forensi.

Vulnerabilità e rischi associati

Uno degli aspetti più critici dell'introduzione dell'AI in ambito forense riguarda la sua esposizione ad attacchi adversariali: input manipolati in modo impercettibile possono ingannare il modello, generando classificazioni errate senza che l'analista se ne accorga. Questo rischio è stato

ampiamente dimostrato nella letteratura recente [phd'unisi'068552, nowroozi2024robustnessrobustness], e risulta particolarmente grave nel contesto forense, dove l'accuratezza e la riproducibilità delle analisi sono fondamentali.

Tali vulnerabilità non si limitano agli attacchi esterni, ma possono manifestarsi anche in condizioni operative normali: immagini degradate, compressioni JPEG, sfocature, cropping o interferenze dovute a pre-elaborazioni automatiche possono anch'esse alterare il comportamento del modello, con conseguenze potenzialmente gravi sul piano legale.

Per questi motivi, il presente lavoro si propone di analizzare criticamente l'efficacia e la robustezza degli strumenti AI-based adottati in ambito forense, ponendo particolare attenzione alla loro resistenza a manipolazioni intenzionali — un tema ancora largamente sottovalutato nella pratica operativa e nella letteratura tecnica esistente.

Modelli CNN vs Transformer nella digital forensics

Nel presente lavoro sono stati valutati sia modelli basati su **Convolutional Neural Networks (CNN)** che modelli **Transformer-based** per la classificazione automatica di immagini a contenuto potenzialmente sospetto.

Le **CNN** (es. ResNet18, EfficientNetB0) si basano su convoluzioni locali e sono ottimizzate per estrarre feature gerarchiche da immagini statiche. Sono più leggere, facilmente interpretabili, e si prestano bene ad ambienti operativi con risorse computazionali limitate.

I **modelli Transformer** (es. CLIP, BLIP) si fondano su meccanismi di attenzione e sono pre-addestrati su task multimodali (immagine-testo). Presentano un'elevata capacità di generalizzazione e resistenza ad alcune perturbazioni semantiche, ma richiedono risorse computazionali più elevate e mostrano comportamenti meno prevedibili in presenza di perturbazioni low-level o steganografiche.

La combinazione dei due approcci ha permesso di confrontare la robustezza tra modelli leggeri e altamente specializzati, valutandone l'efficacia in condizioni realistiche.

3.3 Perturbazioni e attacchi adversarial su immagini

Gli attacchi adversariali rappresentano una delle minacce più insidiose per i modelli di classificazione basati su apprendimento automatico, in particolare per quelli applicati all'analisi delle immagini. Si tratta di tecniche che introducono perturbazioni mirate, spesso impercettibili all'occhio umano, in input legittimi al fine di indurre il modello a produrre predizioni errate [48, 62]. L'impatto di tali manipolazioni è amplificato nel contesto della **Digital Forensics**, dove un errore nella classificazione può compromettere l'integrità probatoria di un'evidenza digitale, con potenziali ripercussioni legali significative.

Queste perturbazioni vengono generate sfruttando la sensibilità locale dei modelli deep learning rispetto a variazioni dello spazio delle caratteristiche, e si basano su gradienti, euristiche di ottimizzazione o modifiche pixel-level. La loro efficacia è stata dimostrata su una vasta gamma di architetture, incluse CNN standard (come ResNet, VGG, DenseNet) e più recentemente anche modelli basati su transformer visivi (ViT).

Tecniche di attacco più comuni

Le principali tecniche di attacco adversarial su immagini possono essere classificate in due macro-categorie: *attacchi ottimizzati numericamente* e *attacchi naturali o di tipo low-level*. Ciascuna tipologia sfrutta meccanismi differenti per compromettere il comportamento del modello di classificazione.

Attacchi ottimizzati numericamente. Questi attacchi si basano su tecniche di ottimizzazione, spesso fondate sul calcolo del gradiente della funzione di perdita rispetto all'input o

sull'uso di algoritmi evolutivi. Sono tipicamente impiegati in contesti white-box, dove l'attaccante ha accesso all'architettura e ai parametri del modello. Tra i principali si annoverano:

- **Fast Gradient Sign Method (FGSM)** [goodfellow2014explaining]: calcola il gradiente della funzione di perdita rispetto all'input e genera una perturbazione diretta lungo il segno del gradiente, scalata da un parametro ϵ , con l'obiettivo di massimizzare l'errore del classificatore in una singola iterazione.
- **One Pixel Attack** [44]: modifica un solo pixel dell'immagine, selezionato tramite un processo di ottimizzazione evolutiva (differential evolution), in modo da generare un errore di classificazione, anche in scenari black-box.
- **DeepFool** [45]: attacco iterativo che calcola la minima perturbazione necessaria per spostare l'input oltre il confine decisionale del classificatore, risultando spesso più impercettibile di FGSM.
- **SuperDeepFool** [46]: evoluzione di DeepFool che incorpora strategie multi-classe e multi-layer, migliorando la capacità di elusione su modelli complessi e ottenendo un equilibrio tra efficacia e invisibilità.

Classificazione delle perturbazioni e contesto scientifico

La letteratura recente distingue due macro-categorie di perturbazioni che possono compromettere le prestazioni di un modello di classificazione di immagini: le **perturbazioni intenzionali**, generate deliberatamente per indurre errori di predizione, e le **perturbazioni naturali**, dovute a degradazioni accidentali o condizioni operative non ottimali.

Le **perturbazioni intenzionali** comprendono gli attacchi *adversariali* in senso stretto, progettati per massimizzare la probabilità di classificazione errata pur mantenendo l'alterazione visivamente impercettibile [goodfellow2014explaining, 62]. Questi attacchi sfruttano la sensibilità locale dei modelli deep learning rispetto a variazioni nello spazio delle feature, applicando tecniche di ottimizzazione basate su gradienti, strategie evolutive o modifiche strutturate a livello pixel. In contesti forensi, tali perturbazioni vengono considerate una forma di **anti-forensics attivo**, in quanto mirano a eludere il rilevamento o a mascherare contenuti di interesse probatorio.

Le **perturbazioni naturali**, al contrario, derivano da fattori non intenzionali ma comunque potenzialmente critici per la robustezza del modello: compressioni lossy (es. JPEG a bassa qualità), variazioni di illuminazione, sfocature dovute a movimento o messa a fuoco imperfetta, rumore di sensore, occlusioni parziali dell'oggetto. Sebbene non siano generate con finalità malevole, esse condividono con le perturbazioni intenzionali la capacità di alterare significativamente le predizioni, specie in modelli non addestrati a gestire condizioni *out-of-distribution* (OOD).

In questo contesto, studi come quello di Hendrycks e Dietterich [22, 63] hanno evidenziato come la robustezza ai dati OOD sia strettamente connessa alla capacità di resistere anche a perturbazioni naturali. Gli autori propongono benchmark specifici per testare la *corruption robustness*, dimostrando che degradazioni comunemente riscontrabili in scenari reali possono produrre effetti paragonabili, in termini di errore di classificazione, a quelli degli attacchi adversariali più noti. Questi risultati sottolineano l'importanza di trattare la problematica della robustezza in maniera unificata, considerando sia le perturbazioni naturali sia quelle intenzionali come parte di uno spettro continuo di possibili degradazioni dell'input.

L'analisi combinata di perturbazioni intenzionali e naturali risulta particolarmente rilevante nella **Digital Forensics**, dove le evidenze digitali possono essere soggette a entrambe le tipologie di degrado: da un lato, manipolazioni volontarie operate da un attore ostile; dall'altro, artefatti dovuti alla catena di acquisizione, trasmissione e memorizzazione dell'immagine. Comprendere e classificare correttamente queste perturbazioni è un passo preliminare essenziale per sviluppare sistemi di rilevamento e classificazione robusti e affidabili in scenari operativi complessi.

Attacchi naturali o low-level. A differenza dei precedenti, questi attacchi non richiedono accesso interno al modello e si basano su trasformazioni visive realistiche, spesso indistinguibili da alterazioni legittime. Sono particolarmente rilevanti in ambito forense, dove possono simulare degradazioni introdotte volontariamente da soggetti ostili:

- **Color Shifting:** alterazione intenzionale del bilanciamento dei colori, che può compromettere il riconoscimento degli oggetti.
- **Gaussian Blur:** sfocatura dell'immagine che riduce la nitidezza dei dettagli rilevanti per la classificazione.
- **Occlusion Patch:** inserimento di blocchi visivi (es. neri o mimetici) su aree salienti, simile a forme di censura o mascheramento.
- **JPEG Compression (ad alta perdita):** ri-compressione dell'immagine a qualità ridotta, che distrugge pattern strutturali sfruttati dai modelli AI per riconoscere i contenuti.

Queste tecniche, pur non richiedendo sofisticati algoritmi di ottimizzazione, si dimostrano altamente efficaci in contesti pratici e rappresentano una sfida concreta per la robustezza dei modelli AI impiegati in scenari forensi reali.

Attacchi steganografici. Una terza categoria di perturbazioni, meno esplorata ma di particolare interesse in ambito forense, comprende le tecniche steganografiche. Questi attacchi non mirano tanto a generare una predizione errata quanto a nascondere informazioni all'interno delle immagini in modo invisibile, eludendo il rilevamento da parte di classificatori automatici o strumenti di ispezione visiva.

In contesto avversariale, la steganografia può essere impiegata con due finalità principali:

- **Ocultamento semantico:** l'immagine viene modificata in modo da mantenere un aspetto innocuo, mentre al suo interno viene codificato un contenuto sensibile o illegale (es. mediante tecniche LSB, DCT o metodi neural-based), aggirando i sistemi di content moderation o analisi automatica.
- **Evasione forense:** sfruttando la steganografia, un attore malevolo può mascherare la presenza di contenuti proibiti o eludere sistemi AI addestrati su immagini "esplicite", evitando che il contenuto nascosto venga analizzato o rilevato.

Tecniche comuni includono:

- **LSB (Least Significant Bit):** i bit meno significativi di alcuni pixel vengono modificati per codificare un messaggio, senza alterare visibilmente l'immagine originale.
- **Steganografia differenziale neurale:** sfrutta reti neurali addestrate per incorporare messaggi in modo impercettibile, mantenendo elevata qualità visiva e resistenza a compressione o ridimensionamento.
- **Payload mimetico:** impiega pattern visivi ad hoc (es. QR degradati, texture a bassa frequenza) per inserire segnali difficili da identificare ma riconoscibili da sistemi pre-accordati.

Nel contesto della presente tesi, le tecniche steganografiche vengono considerate come possibili vettori di attacco anti-forense, poiché alterano in modo mirato le proprietà semantiche dell'immagine, senza innescare alert nei sistemi di classificazione automatica. La loro inclusione nelle perturbazioni testate consente di valutare la robustezza dei modelli AI anche rispetto a forme più sofisticate e subdole di manipolazione.




Figure 3.2: Schema semplificato di generazione di un input avversario. A partire da un'immagine pulita x , viene calcolata una perturbazione δ tale che l'input risultante $x^* = x + \delta$ induca il classificatore $f(\cdot)$ a produrre una predizione errata, mantenendo la distanza percettiva tra x e x^* minima.

Classificazione: White-box vs. Black-box

Gli attacchi avversariali si distinguono in due grandi classi, a seconda del livello di conoscenza che l'attaccante ha sul modello:

- **White-box:** l'attaccante ha accesso completo all'architettura, ai pesi e alla funzione di perdita del modello. Questo consente l'uso di tecniche basate su gradienti, come FGSM, DeepFool o Projected Gradient Descent (PGD), ottenendo perturbazioni altamente efficaci ma meno realistiche dal punto di vista operativo.
- **Black-box:** l'attaccante non ha visibilità interna sul modello, ma può inviare input e osservare le uscite. In questo caso si utilizzano approcci di ottimizzazione evolutiva, surrogate models o tecniche transfer-based. Gli attacchi black-box sono di maggiore interesse in ambito forense, dove il sistema di classificazione (es. Magnet, Cellebrite) è spesso una black-box proprietaria non accessibile direttamente.

Implicazioni in ambito forense

Nel contesto della Digital Forensics, la presenza di attacchi avversariali può compromettere la fiducia nei sistemi di classificazione automatica, con effetti potenzialmente disastrosi. Ad esempio, un'immagine contenente un'arma potrebbe essere classificata erroneamente come innocua, oppure viceversa, generando falsi positivi. L'utilizzo di tali tecniche come strumenti anti-forensi rappresenta un vettore emergente di manipolazione digitale intenzionale, che si colloca a metà tra l'offuscamento e l'elusione.

Inoltre, la difficoltà nel rilevare e mitigare questi attacchi — specialmente quelli più “naturali” come il blur o il cropping intenzionale — rende la valutazione della robustezza dei sistemi AI un elemento imprescindibile per garantirne l'affidabilità operativa. La presente tesi si colloca in questo contesto, con l'obiettivo di valutare sistematicamente la capacità degli strumenti AI-based adottati in ambito forense di resistere a perturbazioni intenzionali e realistiche.

3.4 Robustezza e contromisure

Valutazione della robustezza: metriche e protocolli

La valutazione della **robustezza** di un modello di apprendimento automatico in presenza di perturbazioni intenzionali o naturali richiede un insieme di metriche e protocolli di test che siano allo stesso tempo riproducibili e rappresentativi del contesto applicativo. In letteratura, le metriche più comunemente utilizzate includono:

- **Accuracy under attack (AUA)**: misura la percentuale di campioni classificati correttamente in presenza di un attacco specifico, mantenendo le stesse condizioni di test dei dati “puliti”.
- **Robust Accuracy (RA)**: variante dell'accuratezza che considera l'insieme combinato di campioni originali e perturbati, fornendo una visione complessiva della resilienza del modello [64].
- **Mean Corruption Error (mCE)**: introdotta da Hendrycks e Dietterich [22], misura l'errore medio normalizzato su un insieme di corruzioni naturali standardizzate, consentendo un confronto cross-dataset e cross-modello.
- **Perturbation Norms (L_p norms)**: quantificano l'entità della perturbazione in termini di distanza nello spazio dell'input, con L_2 , L_∞ e L_0 come misure più comuni. Queste norme sono particolarmente utili per confrontare attacchi ottimizzati numericamente.
- **Attack Success Rate (ASR)**: percentuale di campioni per i quali l'attacco ha prodotto una modifica dell'output del classificatore rispetto al dato originale, indipendentemente dalla classe di destinazione.

Nonostante l'ampio uso di tali metriche, **manca una standardizzazione dei protocolli di valutazione** nel contesto specifico della *Digital Forensics*. La maggior parte degli studi si basa su benchmark di dominio generale (es. CIFAR-10, ImageNet) o su dataset sintetici, spesso in condizioni controllate e non rappresentative della complessità dei dati forensi reali.

Alcune problematiche ricorrenti includono:

- l'uso di scenari di test poco realistici rispetto alle condizioni operative sul campo;
- la limitata disponibilità di dataset pubblici bilanciati e diversificati per il dominio forense;
- la difficoltà di replicare esperimenti a causa di vincoli legali e di privacy sulle evidenze digitali.

Come sottolineato anche da Nowroozi et al. [nowroozi2024robustnessrobustness], la mancanza di protocolli comuni ostacola il confronto diretto tra metodologie, impedendo una valutazione chiara dei progressi nel tempo. Questo rende urgente la definizione di **framework di testing condivisi e aperti** per la valutazione della robustezza dei sistemi AI-based in scenari forensi,

che includano sia perturbazioni intenzionali (*adversarial*) sia naturali (*corruption robustness*), in linea con le raccomandazioni di benchmarking OOD proposte in letteratura [23].

Il concetto di **robustezza** di un modello di apprendimento automatico si riferisce alla sua capacità di mantenere prestazioni affidabili anche in presenza di perturbazioni sugli input, intenzionali o accidentali. Nel contesto della Digital Forensics, tale robustezza è fondamentale, poiché l'analisi di immagini o contenuti multimediali manipolati può determinare l'ammissione o il rigetto di una prova in sede giudiziaria.

3.4.1 Explainable Artificial Intelligence (XAI)

Un aspetto cruciale nell'utilizzo di strumenti di intelligenza artificiale in ambito forense è la capacità non solo di ottenere prestazioni elevate, ma anche di **spiegare e giustificare** le decisioni dei modelli. Tale esigenza nasce dalla natura stessa del contesto forense, in cui la prova digitale deve essere non soltanto accurata, ma anche trasparente, ripetibile e interpretabile da parte di investigatori, consulenti tecnici e magistrati. La cosiddetta **Explainable Artificial Intelligence (XAI)** si propone di affrontare il problema della "scatola nera" dei modelli complessi, rendendo interpretabili i risultati dei classificatori e permettendo di comprendere quali caratteristiche di input abbiano influenzato maggiormente una decisione [Guidotti2019, 12].

Negli ultimi anni sono state proposte numerose tecniche di XAI, sia *model-agnostic*, cioè indipendenti dall'architettura sottostante, sia *model-specific*, cioè concepite per particolari famiglie di modelli come le reti neurali profonde [53]. Tra i metodi più rilevanti, utilizzati anche in ambito di computer vision e sicurezza, si ricordano:

- **SHAP (SHapley Additive Explanations)**: basato sulla teoria dei giochi, assegna un contributo positivo o negativo a ciascun attributo, sia a livello globale (importanza media di una feature) sia locale (spiegazione della singola predizione). È considerato uno dei metodi più solidi in termini teorici [50].
- **LIME (Local Interpretable Model-agnostic Explanations)**: approssima localmente il comportamento di un modello complesso con un classificatore interpretabile (es. regressione lineare o alberi decisionali), evidenziando quali feature abbiano influenzato la decisione in uno specifico caso [49].
- **Class Activation Mapping (CAM)**: metodo sviluppato per le reti neurali convoluzionali, che consente di generare mappe di attivazione evidenziando le regioni di un'immagine maggiormente rilevanti per la classificazione [52].
- **Integrated Gradients (IG)**: tecnica gradient-based che consente di stimare l'impatto dei singoli pixel integrando i gradienti della funzione di predizione lungo un percorso continuo che va da un input di riferimento (baseline) all'immagine reale. IG garantisce proprietà di completezza e coerenza, risultando particolarmente adatto all'analisi forense di immagini [51].

Nel contesto di questa tesi, la XAI è stata impiegata con tre obiettivi principali:

1. Analizzare le differenze di attenzione dei modelli tra immagini originali e perturbate da attacchi adversariali e anti-forensici, evidenziando come tali perturbazioni possano spostare il focus del classificatore verso regioni irrilevanti.
2. Confrontare il comportamento di modelli di diversa complessità architetturale (ResNet, EfficientNet, CLIP, BLIP, SVM), valutando non solo l'accuratezza numerica ma anche la coerenza semantica delle spiegazioni.
3. Fornire un livello di trasparenza necessario per la **validazione forense** dei modelli, rendendo espliciti punti di forza e vulnerabilità dei classificatori e supportando così l'adozione di AI in ambito probatorio secondo criteri di affidabilità e accountability [13, 65].

La spiegabilità diventa quindi non solo uno strumento tecnico per comprendere i modelli, ma anche un requisito metodologico ed epistemologico per integrare l'intelligenza artificiale nei

flussi investigativi e giudiziari, in linea con le raccomandazioni delle linee guida europee su AI e affidabilità [66]. In sintesi, l'Explainable AI non rappresenta una difesa diretta contro attacchi avversariali o anti-forensici, ma costituisce uno strumento fondamentale per comprendere e validare i processi decisionali dei modelli. La letteratura mostra un crescente interesse verso queste tecniche, ma mancano ancora studi che ne valutino l'efficacia in scenari forensi realistici, specialmente in presenza di input manipolati. La presente tesi intende colmare questa lacuna sperimentando l'applicazione di metodologie XAI a modelli di classificazione di immagini in condizioni ostili.

Classificazione delle strategie difensive

Le contromisure sviluppate per mitigare l'impatto delle perturbazioni sugli input — siano esse intenzionali o naturali — possono essere suddivise in due grandi famiglie concettuali: **difese proattive** e **difese reattive** [17, 42].

Difese proattive. Sono progettate per aumentare intrinsecamente la robustezza del modello durante la fase di addestramento o costruzione dell'architettura. Rientrano in questa categoria:

- l'*adversarial training*, che include nel set di addestramento esempi perturbati per rendere il modello meno sensibile a variazioni malevole [64];
- le tecniche di *data augmentation* mirate, che introducono corruzioni naturali o simulate per migliorare la *corruption robustness* [22];
- la progettazione di architetture con meccanismi intrinseci di regolarizzazione e attenuazione della sensibilità ai cambiamenti locali nello spazio delle feature.

L'obiettivo delle difese proattive è ridurre la superficie d'attacco prima che il modello venga distribuito in ambiente operativo.

Difese reattive. Agiscono sugli input o sulle decisioni del modello *a posteriori*, ovvero dopo la fase di addestramento, per individuare o neutralizzare perturbazioni potenzialmente dannose. Tra le strategie più comuni vi sono:

- la *pre-elaborazione dell'input* (es. filtraggio, riduzione della profondità di bit, compressione JPEG) per eliminare parte della perturbazione;
- i *moduli di rilevamento* (*adversarial example detectors*) basati su inconsistenze interne del modello o su modelli ausiliari per discriminare input anomali;
- la *randomizzazione controllata*, che introduce variabilità nel preprocessing o nell'architettura in fase di inferenza per ridurre la trasferibilità degli attacchi.

Le difese reattive sono particolarmente utili quando il modello è già in uso e non è possibile eseguire un riaddestramento completo.

Applicazioni in scenari anti-forensi. Nel dominio della **Digital Forensics**, l'adozione di difese proattive e reattive richiede un'attenzione particolare. Studi recenti, come quello di Nowroozi et al. [nowroozi2024robustnessrobustness], evidenziano come difese pensate per contesti generici di computer vision possano non essere direttamente trasferibili a scenari forensi, a causa della diversa distribuzione dei dati, della criticità probatoria e della presenza di attacchi specificamente progettati per eludere il rilevamento (*anti-forensics aware attacks*). Alcuni approcci emergenti propongono quindi l'addestramento congiunto su perturbazioni avversariali e anti-forensi, oppure l'integrazione di moduli di *forensic fingerprinting* capaci di rilevare manipolazioni anche in condizioni di degrado severo [67].

Questa distinzione tra difese proattive e reattive fornisce un quadro di riferimento utile per analizzare le tecniche esistenti e per valutare l'adequatezza delle soluzioni sviluppate nel presente lavoro rispetto al contesto forense.

Negli ultimi anni sono state proposte numerose strategie difensive per mitigare l'impatto degli attacchi avversariali, ciascuna con caratteristiche e limitazioni specifiche. Tali strategie si dividono principalmente in tre macro-categorie: *difese basate sull'addestramento*, *difese basate sulla trasformazione dell'input*, e *meccanismi di rilevamento*.

Difese basate sull'addestramento

Una delle tecniche più note è l'**Adversarial Training** [64], che consiste nell'includere durante la fase di training anche esempi avversari generati dinamicamente. Questo approccio consente al modello di imparare a riconoscere e neutralizzare le perturbazioni note, migliorando la sua resilienza a input manipolati. Tuttavia, l'addestramento avversariale è spesso costoso in termini computazionali, può ridurre l'accuratezza sui dati "puliti" e tende a sovra-specializzarsi rispetto a specifici tipi di attacchi.

Difese basate sulla trasformazione dell'input

Un'altra categoria di tecniche mira a **pre-elaborare l'input** prima della classificazione, con l'obiettivo di annullare o attenuare l'effetto delle perturbazioni. Tra queste si annoverano la **JPEG compression**, il **denoising**, il **bit-depth reduction** e il **total variance minimization** [68]. Questi metodi possono essere efficaci contro attacchi generati in white-box, ma risultano meno efficienti in scenari realistici o black-box, dove l'attaccante può adattare le perturbazioni per sopravvivere a tali trasformazioni.

Meccanismi di rilevamento

Sono stati inoltre sviluppati moduli di **adversarial example detection**, che cercano di distinguere gli input puliti da quelli manipolati prima della fase di classificazione vera e propria. Tali approcci si basano su misure di inconsistenza, distribuzioni delle attivazioni interne, autoencoder, e tecniche di outlier detection. In alcuni casi, possono essere efficaci nel bloccare attacchi noti, ma restano vulnerabili a tecniche di *adaptive attack* e possono introdurre falsi positivi, compromettendo l'usabilità del sistema.

Difese basate sulla randomizzazione e distillazione

Altri approcci mirano a rendere più imprevedibile il comportamento del modello o a regolarizzarne la sensibilità. La **randomizzazione** dell'input (es. ridimensionamento casuale, dropout al test-time) mira a ridurre l'efficacia degli attacchi generati per un'unica configurazione di rete. La **defensive distillation**, proposta inizialmente come metodo di compressione dei modelli, si è rivelata utile per ridurre la reattività dei classificatori a variazioni minime degli input, attenuando la vulnerabilità a FGSM e simili. Tuttavia, anche queste strategie si sono dimostrate insufficienti contro attacchi più sofisticati.

Criticità nel contesto forense

Nonostante la ricchezza di approcci sviluppati, **nessuna difesa si è dimostrata universalmente efficace**. Per ogni strategia pubblicata, la comunità di ricerca ha rapidamente proposto un metodo per aggirarla, evidenziando la fragilità strutturale dei modelli deep learning in ambienti ostili. Inoltre, la quasi totalità degli studi esistenti si basa su benchmark accademici (come CIFAR-10, MNIST, ImageNet), in condizioni fortemente controllate e lontane dalla complessità operativa della Digital Forensics.

In ambito forense, la posta in gioco è ben più alta: un errore di classificazione può avere ripercussioni giudiziarie, legali e reputazionali. Eppure, pochi lavori hanno indagato sistematicamente la robustezza dei modelli AI integrati in strumenti realmente utilizzati dagli investigatori digitali. Tale lacuna costituisce uno dei principali motivi che hanno spinto allo sviluppo del presente studio sperimentale, orientato a valutare la tenuta dei sistemi AI-based forensi contro manipolazioni realistiche e mirate [16].

La Figura 3.3 riassume le principali tecniche difensive discusse, mettendo in evidenza vantaggi, limitazioni e scenari di applicabilità. Nessuna tecnica si è dimostrata universalmente efficace, sottolineando la necessità di strategie difensive adattive e contestualizzate all’ambito forense.




Figure 3.3: Principali categorie di difesa contro attacchi adversariali: vantaggi e limiti in contesto forense.

3.5 Limiti della letteratura esistente e contributo della presente tesi

La revisione critica della letteratura attuale mette in evidenza alcune lacune rilevanti che limitano la generalizzabilità e l'applicabilità dei risultati ottenuti nel campo dell'Intelligenza Artificiale applicata alla Digital Forensics. Nonostante il crescente interesse per l'uso di tecniche AI-based nell'analisi automatizzata di contenuti digitali, diverse problematiche risultano ancora irrisolte, soprattutto in ottica operativa.

In particolare, si osservano i seguenti limiti:

- **Scarsa attenzione al contesto forense reale:** la maggior parte dei lavori esistenti è focalizzata su modelli teorici o ambienti controllati, mentre pochi studi affrontano l'uso effettivo dell'AI all'interno di strumenti forensi operativi, valutandone la sicurezza in presenza di input ostili o manipolati [phd'unisi'068552].
- **Assenza di benchmark realistici:** i dataset utilizzati in letteratura sono spesso costruiti artificialmente (es. CIFAR-10, ImageNet) e non riflettono la complessità delle immagini che si incontrano nelle indagini forensi, dove i contenuti provengono da fonti eterogenee come social media, dark web, piattaforme di messaggistica e archivi personali.
- **Focalizzazione su attacchi sintetici:** molti esperimenti utilizzano perturbazioni standardizzate e facilmente rilevabili, trascurando le tecniche anti-forensi concrete che un attore malevolo potrebbe impiegare per eludere i sistemi di classificazione (es. compressioni lossy, cropping mirato, occlusioni strategiche, mimetizzazione semantica).
- **Mancanza di valutazioni sui tool realmente in uso:** strumenti largamente impiegati in ambito investigativo — come *Magnet AXIOM*, *Cellebrite UFED*, *X-Ways Forensics* — non vengono quasi mai analizzati in letteratura per quanto riguarda la loro resistenza ad attacchi adversariali o a input corrotti da manipolazioni sofisticate.

-
- **Scarsa considerazione delle tecniche steganografiche come vettori di attacco:** benché largamente impiegate per occultare informazioni, le tecniche steganografiche sono raramente trattate come perturbazioni anti-forensi attive, in grado di eludere sistemi AI-based simulando contenuti apparentemente innocui ma semanticamente alterati.

Alla luce di tali lacune, il presente lavoro si propone di fornire un contributo concreto e sistematico attraverso un approccio sperimentale innovativo, articolato secondo i seguenti obiettivi:

- **Costruzione di un dataset composito e realistico,** costituito da immagini provenienti da fonti variegata (dataset pubblici, motori di ricerca, social network, deep web), in modo da rappresentare in maniera più fedele gli scenari tipici delle indagini digitali.
- **Applicazione mirata di attacchi avversariali, anti-forensi e steganografici,** con l'obiettivo di simulare perturbazioni realistiche e operative, testando la tenuta dei classificatori in condizioni avverse e ad alta criticità.
- **Valutazione comparativa della robustezza di strumenti AI-based utilizzati in ambito forense,** esaminando le prestazioni dei modelli integrati in software di uso professionale in presenza di immagini manipolate.

Questo approccio consente non solo di colmare un vuoto evidente nella letteratura, ma anche di offrire una valutazione concreta e riproducibile della **solidità operativa** dei sistemi di classificazione automatica nel dominio forense. I risultati ottenuti possono contribuire a sensibilizzare la comunità scientifica e investigativa sull'importanza della robustezza nei sistemi AI e a stimolare lo sviluppo di metodologie più resilienti, trasparenti e “avversario-consapevoli” (*adversary-aware*).

Un'ulteriore considerazione emersa dalla revisione della letteratura riguarda la quasi totale assenza di studi che analizzino in maniera sistematica **difese “adversary-aware”** progettate specificamente per il contesto della Digital Forensics. Sebbene in ambito di computer vision generale siano state proposte diverse strategie di robustezza, queste soluzioni raramente tengono conto delle peculiarità probatorie e operative delle indagini digitali, come la necessità di preservare l'integrità dell'evidenza, garantire la riproducibilità dell'analisi e operare in scenari ostili dove gli attacchi possono essere mirati a eludere controlli forensi.

Tale lacuna si accompagna alla mancanza di **protocolli comuni di valutazione** che permettano di confrontare in modo oggettivo le difese implementate in diversi strumenti AI-based forensi. In assenza di benchmark e metodologie condivise, risulta difficile misurare in maniera comparabile la reale efficacia delle contromisure, limitando la possibilità di trasferire le migliori pratiche dal contesto di ricerca a quello operativo. Questa constatazione rafforza ulteriormente la necessità di un approccio strutturato e riproducibile, come quello adottato nella presente tesi, che possa costituire un riferimento per studi futuri nel settore.

3.6 Sintesi comparativa dei contributi scientifici

La Tabella 3.3 riassume i principali contributi accademici rilevanti per questo studio, mettendo in evidenza:

- le tecniche proposte,
- l'ambito di applicazione,
- i limiti riscontrati in scenari con input manipolati.

Table 3.3: Sintesi dei principali contributi in letteratura sulla robustezza del Machine Learning in ambito forense

Autore	Tecnica / Approccio	Applicazione	Limiti in scenari avversariali
Biggio & Roli (2018) [43]	Definizione threat models, attacchi di evasione e poisoning	Classificatori di pattern, visione artificiale, cybersecurity	Modelli vulnerabili ad attacchi mirati anche con perturbazioni minime
Nowroozi et al. (2020, 2024) [nowroozi2024robustness, 18]	Adversarial ML per image forensics e intrusion detection	Rilevazione manipolazioni, intrusion detection AI-based	Mancanza di validazione su dataset realistici in ambito forense operativo
Costantini et al. (2019) [7]	Answer Set Programming (ASP) per analisi automatizzata delle evidenze	Supporto investigativo e ricostruzione scenari probatori	Non affronta la robustezza dei modelli AI a manipolazioni intenzionali
Hewling (2013) [hewling2013]	Framework integrato per digital forensics	Standardizzazione processi di acquisizione e analisi	Focus su processi e metodologie, non su AI e vulnerabilità avversariali

Questa analisi mostra come, nonostante l’elevato numero di studi teorici e framework proposti, manchi ancora una validazione sistematica su dataset realistici e in contesti operativi. Il presente lavoro intende colmare parzialmente questa lacuna attraverso un’analisi sperimentale controllata della robustezza di modelli AI-based in contesto forense.

Appendix A

Repository and Reproducibility Artifacts

Questa appendice raccoglie gli elementi tecnici necessari a documentare la riproducibilità del lavoro sperimentale. Il codice sorgente completo non viene riportato integralmente nel documento, ma è mantenuto nella repository associata alla tesi. Le sezioni seguenti descrivono la struttura logica del progetto, gli artefatti sperimentali principali, i manifest ufficiali, i meccanismi di tracciabilità, i comandi essenziali di esecuzione e alcuni esempi rappresentativi di output. Tale scelta consente di preservare la leggibilità della tesi, evitando la duplicazione integrale dei file sorgente e mantenendo il codice nella sede più adatta alla sua consultazione, verifica e aggiornamento.

A.1 Struttura della repository

La repository è organizzata in modo modulare, separando i dati grezzi, gli artefatti preparati, i manifest finali, gli split sperimentali, gli script della pipeline, gli output di valutazione e la documentazione della tesi. Tale organizzazione consente di distinguere chiaramente tra dati di input, fasi di trasformazione, artefatti congelati e risultati sperimentali.

```
1 msc-thesis-ai-robustness-in-digital-forensics/  
2   datasets/  
3     raw/  
4     prepared/  
5     final/  
6     splits/  
7     forensic_evaluation_bundle/  
8   datasets/scripts/  
9     prepared/  
10    final/  
11    splits/  
12    bundle/  
13  attacks/  
14    adversarial/  
15    anti_forensic/  
16  evaluation/  
17    clean/  
18    adversarial/  
19    anti_forensic/  
20    forensic_tools/  
21  explainability/  
22    outputs/  
23    manifests/  
24  results/  
25    metrics/  
26    tables/  
27    plots/
```

```

28     figures/
29     reports/
30 docs/
31     LatexThesis_ITA/

```

Listing A.1: Struttura semplificata della repository sperimentale.



Figure A.1: QR code per l'accesso diretto alla repository GitHub della tesi.

A.2 Artefatti sperimentali principali

La Tabella A.1 riassume i principali artefatti sperimentali utilizzati nella pipeline. Tali file costituiscono il riferimento operativo per la ricostruzione del dataset, la generazione degli split, la valutazione dei modelli e la predisposizione del bundle destinato agli strumenti forensi.

Table A.1: Principali artefatti sperimentali della pipeline.

Artefatto	Ruolo nella pipeline
<code>manual_selection_final_1500.csv</code>	Manifest ufficiale del dataset frozen, composto da 1500 immagini bilanciate nelle classi weapon , non_weapon e OOD.
<code>manual_selection_adversarial_subset.csv</code>	Manifest del subset binario utilizzato per gli esperimenti adversariali e anti-forensi, composto dalle sole classi weapon e non_weapon .
<code>manual_selection_protocol_db.csv</code>	Database operativo del protocollo di selezione manuale <i>human-in-the-loop</i> .
<code>manual_selection_removed.csv</code>	Manifest dei campioni esclusi durante la selezione finale.
<code>clean_folds_manifest.csv</code>	Manifest degli split puliti utilizzati per la valutazione baseline dei modelli.
<code>ood_eval_manifest.csv</code>	Manifest del set OOD utilizzato per la valutazione fuori distribuzione.
<code>bundle_manifest.csv</code>	Manifest globale del bundle di valutazione destinato agli strumenti forensi.
<code>bundle_hashes_sha256.csv</code>	File contenente gli hash SHA256 degli artefatti inclusi nel bundle forense.

A.3 Ambiente software e librerie utilizzate

La pipeline sperimentale è stata implementata prevalentemente in Python, utilizzando librerie per la gestione dei dati, l'elaborazione delle immagini, l'esecuzione dei modelli e la produzione degli output sperimentali. La Tabella A.2 riassume i principali strumenti software impiegati.

Table A.2: Principali librerie e strumenti software utilizzati nella pipeline sperimentale.

Libreria / Strumento	Funzione principale
Python	Linguaggio principale per la costruzione della pipeline sperimentale.
pandas	Gestione dei manifest, dei metadati e dei risultati sperimentali.
NumPy	Gestione numerica di array, immagini e matrici di perturbazione.
Pillow	Validazione, apertura e trasformazione delle immagini.
OpenCV	Elaborazione di immagini e applicazione di trasformazioni anti-forensi.
PyTorch	Esecuzione dei modelli neurali e generazione di alcune perturbazioni adversariali.
scikit-learn	Addestramento e valutazione della baseline SVM e calcolo delle metriche.
matplotlib	Produzione di grafici, curve e figure sperimentali.
CLIP	Classificazione zero-shot e confronto semantico immagine-testo.
BLIP	Captioning e analisi multimodale delle immagini.

A.4 Manifest, hash e tracciabilità

La tracciabilità degli artefatti sperimentali è garantita attraverso l'uso sistematico di manifest e hash crittografici. Ogni immagine viene associata a metadati tecnici e semantici che consentono di collegare il campione alla sorgente originaria, alla classe assegnata, allo split sperimentale, all'eventuale versione perturbata e agli output prodotti dai modelli o dagli strumenti forensi.

Il calcolo degli hash SHA256 costituisce un elemento centrale della pipeline, poiché consente di verificare l'identità dei file, individuare duplicati e mantenere un collegamento stabile tra immagini pulite, immagini trasformate e risultati sperimentali. Nel bundle di valutazione forense, gli hash rappresentano inoltre il principale criterio di raccordo tra gli artefatti importati nei tool professionali e gli output esportati dagli stessi strumenti.

A.5 Comandi principali per la riproducibilità

La pipeline sperimentale è organizzata in script separati, ciascuno dedicato a una fase specifica del workflow. Il Listato A.2 riporta la sequenza logica principale per ricostruire gli artefatti del dataset e predisporre il bundle di valutazione forense.

```

1 python datasets/scripts/prepared/08_build_prepared_dataset.py
2 python datasets/scripts/prepared/09_generate_review_manifest_full.py
3 python datasets/scripts/final/10_manual_selection_protocol_reviewer.py
4 python datasets/scripts/splits/11_generate_clean_and_ood_splits.py
5 python datasets/scripts/bundle/12_build_forensic_evaluation_bundle.py

```

Listing A.2: Sequenza principale di esecuzione della pipeline dataset.

A.6 Esempi di log e output

Durante l'esecuzione della pipeline, gli script producono log e report intermedi utili a verificare la correttezza delle operazioni effettuate. Il Listato A.3 mostra un esempio schematico di output relativo alla fase di preparazione tecnica del dataset.

```

1 [INFO] Scanning raw dataset sources...
2 [INFO] Valid images detected: ...
3 [INFO] Invalid images discarded: ...
4 [INFO] SHA256 hashes computed: ...
5 [INFO] Global duplicates removed: ...
6 [INFO] Prepared image pool written to datasets/prepared/final_pool/images/

```

```
7 [INFO] Metadata written to datasets/prepared/final_pool/metadata.csv
```

Listing A.3: Esempio schematico di output della fase di preparazione del dataset.

A.7 Repository e disponibilità del codice

Il codice completo utilizzato per la costruzione del dataset, la generazione degli split, la produzione delle perturbazioni, l'esecuzione delle valutazioni e la raccolta dei risultati è mantenuto nella repository associata alla tesi. La repository contiene inoltre i manifest principali, gli script della pipeline e la documentazione operativa necessaria alla riproduzione del workflow sperimentale.

- **Repository GitHub:** <https://github.com/lmolinario/msc-thesis-ai-robustness-in-digital-forensics>
- **Manifest ufficiale del dataset frozen:** `datasets/final/manifests/manual_selection_final_1500.csv`
- **Manifest del subset adversarial:** `datasets/final/manifests/manual_selection_adversarial_subset.csv`
- **Licenza:** da definire nella repository finale.

References

- [1] Simson L Garfinkel. ‘Digital forensics research: The next 10 years’. In: *Digital Investigation* 7 (2010), S64–S73.
- [2] Eoghan Casey. *Digital Evidence and Computer Crime: Forensic Science, Computers, and the Internet*. Academic Press, 2011.
- [3] Gary Palmer. *A Road Map for Digital Forensic Research*. Tech. rep. Digital Forensic Research Workshop (DFRWS), 2001.
- [4] Matthew Reith, Clint Carr and Gregory Gunsch. ‘Examining the computer forensic process model’. In: *International Journal of Digital Evidence* 1.3 (2002), pp. 1–9.
- [5] K. Kent et al. *Guide to Integrating Forensic Techniques into Incident Response*. Tech. rep. SP 800-86. NIST, 2006. URL: <https://nvlpubs.nist.gov/nistpubs/Legacy/SP/nistspecialpublication800-86.pdf>.
- [6] International Organization for Standardization. *ISO/IEC 27037:2012 – Guidelines for identification, collection and preservation of digital evidence*. <https://www.iso.org/standard/44381.html>. Accessed: 2025-06-13. 2012.
- [7] Stefania Costantini, Giovanni De Gasperis and Raffaele Olivieri. ‘Digital Forensics and Investigations Meet Artificial Intelligence’. In: *Annals of Mathematics and Artificial Intelligence* 86.1 (2019), pp. 193–229. DOI: 10.1007/s10472-019-09632-y.
- [8] Jonathan Clough. *Principles of Cybercrime*. Cambridge University Press, 2015.
- [9] Silvia Lucia Sanna et al. *Exploring the Robustness of AI-Driven Tools in Digital Forensics: A Preliminary Study*. Preprint submitted to Digital Forensics Research Conference Europe 2025. 2024. DOI: 10.48550/arXiv.2412.01363. arXiv: 2412.01363 [cs.CV].
- [10] Silvia Lucia Sanna et al. ‘Pixel Perfect or Perfectly Fake? Exploring the Robustness of Digital Forensic Tools Against Facial Deepfakes and Morphed Images’. In: *Proceedings of the 33rd European Signal Processing Conference (EUSIPCO 2025)*. Preprint / conference paper. Cagliari, Italy, 2025.
- [11] Silvia Lucia Sanna et al. ‘Improving Cybercrime Detection and Digital Forensics Investigations with Artificial Intelligence’. In: *APWG-EU 2025: Tech Summit and Researchers Forum*. Conference paper. Cagliari, Italy, 2025.
- [12] A. Adadi and M. Berrada. ‘Peeking inside the black-box: A survey on Explainable Artificial Intelligence (XAI)’. In: *IEEE Access* 6 (2018), pp. 52138–52160.
- [13] F. Doshi-Velez and B. Kim. ‘Towards a rigorous science of interpretable machine learning’. In: *arXiv preprint arXiv:1702.08608* (2017).
- [14] Ian J Goodfellow, Jonathon Shlens and Christian Szegedy. ‘Explaining and harnessing adversarial examples’. In: *arXiv preprint arXiv:1412.6572* (2015).
- [15] Nicolas Papernot et al. ‘The limitations of deep learning in adversarial settings’. In: *2016 IEEE European Symposium on Security and Privacy (EuroS&P)* (2016), pp. 372–387.
- [16] Nicholas Carlini and David Wagner. ‘Towards evaluating the robustness of neural networks’. In: *IEEE Symposium on Security and Privacy (SP)*. IEEE. 2017, pp. 39–57. DOI: 10.1109/SP.2017.49.

-
- [17] Xiaoyong Yuan et al. ‘Adversarial Examples: Attacks and Defenses for Deep Learning’. In: *IEEE Transactions on Neural Networks and Learning Systems* 30.9 (2019), pp. 2805–2824. DOI: 10.1109/TNNLS.2018.2886017.
- [18] Ehsan Nowroozi. ‘Machine Learning Techniques for Image Forensics in Adversarial Setting’. PhD thesis. University of Siena, 2020.
- [19] Mauro Barni, Ehsan Nowroozi and Benedetta Tondi. ‘Adversarial attacks against deep neural network-based image forensics’. In: *2018 25th IEEE International Conference on Image Processing (ICIP)* (2018), pp. 3758–3762.
- [20] Matthew C. Stamm, Min Wu and K. J. Ray Liu. ‘Information Forensics: An Overview of the First Decade’. In: *IEEE Access* 1 (2013), pp. 167–200. DOI: 10.1109/ACCESS.2013.2260814.
- [21] Ehsan Nowroozi et al. ‘Verifying the Robustness of Machine Learning based Intrusion Detection Against Adversarial Perturbation’. In: *TechRxiv Preprint* (2024). DOI: 10.36227/techrxiv.172297438.84425389/v1.
- [22] Dan Hendrycks and Thomas G. Dietterich. ‘Benchmarking neural network robustness to common corruptions and perturbations’. In: *International Conference on Learning Representations (ICLR)*. 2019. URL: <https://openreview.net/forum?id=HJz6tiCqYm>.
- [23] Francesco Croce and Matthias Hein. ‘RobustBench: A standardized adversarial robustness benchmark’. In: *arXiv preprint arXiv:2010.09670* (2020). URL: <https://arxiv.org/abs/2010.09670>.
- [24] Raed S. A. Faqir. ‘Digital Criminal Investigations in the Era of Artificial Intelligence: A Comprehensive Overview’. In: *International Journal of Cyber Criminology* 17.2 (2023), pp. 77–94.
- [25] Jean-Paul A. Yaacoub et al. ‘Digital forensics vs. anti-digital forensics: Techniques, limitations and recommendations’. In: *arXiv preprint arXiv:2103.17028* (2021).
- [26] *Codice di procedura penale*. D.P.R. 22 settembre 1988, n. 447. Repubblica Italiana, 1988.
- [27] *Regulation (EU) 2024/1689 laying down harmonised rules on Artificial Intelligence (AI Act)*. European Union, 2024.
- [28] Scientific Working Group on Digital Evidence. *SWGDE Best Practices and Guidelines*. <https://www.swgde.org/documents>. Accessed: 2025-06-13. 2023.
- [29] European Network of Forensic Science Institutes. *ENFSI Forensic IT Working Group - Best Practice Manual*. <https://enfsi.eu/documents/>. Accessed: 2025-06-13. 2022.
- [30] Hany Farid. *Photo Forensics*. MIT Press, 2016.
- [31] Alin C. Popescu and Hany Farid. ‘Exposing Digital Forgeries by Detecting Resampling’. In: *IEEE Transactions on Signal Processing* 53.2 (2005), pp. 758–767.
- [32] Christopher M Bishop. *Pattern Recognition and Machine Learning*. Springer, 2006.
- [33] Rafael C. Gonzalez and Richard E. Woods. *Digital Image Processing*. 4th ed. Pearson, 2018.
- [34] Corinna Cortes and Vladimir Vapnik. ‘Support-vector networks’. In: *Machine Learning* 20.3 (1995), pp. 273–297.
- [35] Kaiming He et al. ‘Deep Residual Learning for Image Recognition’. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2016, pp. 770–778. DOI: 10.1109/CVPR.2016.90.
- [36] Mingxing Tan and Quoc V Le. ‘EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks’. In: *International Conference on Machine Learning (ICML)*. PMLR. 2019, pp. 6105–6114.
- [37] Alec Radford et al. ‘Learning Transferable Visual Models From Natural Language Supervision’. In: *International Conference on Machine Learning (ICML)*. OpenAI. 2021. URL: <https://openai.com/research/clip>.
-

-
- [38] Junnan Li et al. ‘BLIP: Bootstrapping Language-Image Pre-training for Unified Vision-Language Understanding and Generation’. In: *Proceedings of the 39th International Conference on Machine Learning*. Vol. 162. Proceedings of Machine Learning Research. PMLR, 2022, pp. 12888–12900.
 - [39] Dan Hendrycks and Kevin Gimpel. ‘A baseline for detecting misclassified and out-of-distribution examples in neural networks’. In: *arXiv preprint arXiv:1610.02136* (2017).
 - [40] Stanley Fort, Jiaming Ren and Balaji Lakshminarayanan. ‘Exploring the limits of out-of-distribution detection’. In: *Advances in Neural Information Processing Systems*. 2021.
 - [41] Christian Szegedy et al. ‘Intriguing properties of neural networks’. In: *arXiv preprint arXiv:1312.6199* (2013).
 - [42] Naveed Akhtar and Ajmal Mian. ‘Threat of adversarial attacks on deep learning in computer vision: A survey’. In: *IEEE Access* 6 (2018), pp. 14410–14430. DOI: 10.1109/ACCESS.2018.2807385.
 - [43] Battista Biggio and Fabio Roli. ‘Wild Patterns: Ten Years After the Rise of Adversarial Machine Learning’. In: *Pattern Recognition* 84 (2018), pp. 317–331. DOI: 10.1016/j.patcog.2018.07.023.
 - [44] Jiawei Su, Danilo Vargas and Kouichi Sakurai. ‘One pixel attack for fooling deep neural networks’. In: *IEEE Transactions on Evolutionary Computation* 23.5 (2019), pp. 828–841.
 - [45] Seyed-Mohsen Moosavi-Dezfooli, Alhussein Fawzi and Pascal Frossard. ‘DeepFool: a simple and accurate method to fool deep neural networks’. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition* (2016), pp. 2574–2582.
 - [46] Alireza Abdolpourostam, Mahed Abroshan and Seyed-Mohsen Moosavi-Dezfooli. ‘SuperDeepFool: A New Fast and Accurate Minimal Adversarial Attack’. In: *Advances in Neural Information Processing Systems 37 (NeurIPS 2024)*. Poster presentation. 2024. URL: <https://openreview.net/forum?id=pqD7ckR8AF>.
 - [47] Matthew Stamm and K. J. Ray Liu. ‘Anti-Forensics of Digital Image Compression’. In: *IEEE Transactions on Information Forensics and Security* 6.3 (2010), pp. 1050–1065.
 - [48] Nicholas Ford et al. ‘Adversarial examples are a natural consequence of test error in noise’. In: *International Conference on Machine Learning (ICML)*. 2019. URL: <https://arxiv.org/abs/1901.10513>.
 - [49] Marco Tulio Ribeiro, Sameer Singh and Carlos Guestrin. ‘“Why should I trust you?” Explaining the predictions of any classifier’. In: *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. 2016, pp. 1135–1144.
 - [50] Scott M. Lundberg and Su-In Lee. ‘A Unified Approach to Interpreting Model Predictions’. In: *Advances in Neural Information Processing Systems (NeurIPS)*. 2017.
 - [51] Mukund Sundararajan, Ankur Taly and Qiqi Yan. ‘Axiomatic attribution for deep networks’. In: *Proceedings of the 34th International Conference on Machine Learning (ICML)*. 2017, pp. 3319–3328.
 - [52] Bolei Zhou et al. ‘Learning Deep Features for Discriminative Localization’. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2016, pp. 2921–2929.
 - [53] D. V. Carvalho, E. M. Pereira and J. S. Cardoso. ‘Machine learning interpretability: A survey on methods and metrics’. In: *Electronics* 8.8 (2019), p. 832.
 - [54] Mariangela Biasiotti and Federica Turchi. ‘Handling and Exchanging Electronic Evidence Across Different Jurisdictions’. In: *Handling and Exchanging Electronic Evidence Across Different Jurisdictions*. IGI Global, 2018.
 - [55] *Regulation (EU) 2016/679 of the European Parliament and of the Council (General Data Protection Regulation)*. European Union, 2016.
 - [56] Paul Voigt and Axel Von dem Bussche. *The EU General Data Protection Regulation (GDPR): A Practical Guide*. Springer, 2017.
-

-
- [57] Ben Martini and Kim-Kwang Raymond Choo. ‘Cloud storage forensics: An overview, issues, and future directions’. In: *Digital Investigation* 40 (2022), p. 301472. DOI: 10.1016/j.diin.2022.301472.
- [58] Farhood Daryabar, Ali Dehghantanha and Kim-Kwang Raymond Choo. ‘Cloud forensics: State-of-the-art and future directions’. In: *Future Generation Computer Systems* 115 (2021), pp. 350–369. DOI: 10.1016/j.future.2020.09.028.
- [59] Lo’ai Tawalbeh et al. ‘IoT forensics: Challenges, open issues, and future directions’. In: *Future Generation Computer Systems* 128 (2022), pp. 337–353. DOI: 10.1016/j.future.2021.10.019.
- [60] M.K. Rogers and K.C. Seigfried-Spellar. ‘AI and Digital Forensics: Emerging Challenges’. In: *Digital Investigation* 32 (2020), p. 200905. DOI: 10.1016/j.diin.2020.200905.
- [61] Francesco Marra et al. ‘Do GANs Leave Artificial Fingerprints?’ In: *arXiv preprint arXiv:1812.11842* (2019). <https://arxiv.org/abs/1812.11842>.
- [62] Christian Szegedy et al. ‘Intriguing Properties of Neural Networks’. In: *arXiv preprint arXiv:1312.6199* (2013). <https://arxiv.org/abs/1312.6199>.
- [63] Claudio Michaelis et al. ‘Benchmarking robustness in object detection: Autonomous driving when winter is coming’. In: *arXiv preprint arXiv:1907.07484* (2019). URL: <https://arxiv.org/abs/1907.07484>.
- [64] Aleksander Madry et al. ‘Towards Deep Learning Models Resistant to Adversarial Attacks’. In: *International Conference on Learning Representations (ICLR)*. <https://arxiv.org/abs/1706.06083>. 2018.
- [65] A. Barredo Arrieta et al. ‘The role of transparency in artificial intelligence’. In: *Nature Communications* 11.1 (2020), pp. 1–17.
- [66] European Commission High-Level Expert Group on AI. *Ethics Guidelines for Trustworthy AI*. <https://ec.europa.eu/futurium/en/ai-alliance-consultation>. 2020.
- [67] Davide Cozzolino, Giovanni Poggi and Luisa Verdoliva. ‘Recasting residual-based local descriptors as convolutional neural networks: An application to image forgery detection’. In: *Proceedings of the 5th ACM Workshop on Information Hiding and Multimedia Security*. ACM. 2017, pp. 159–164. DOI: 10.1145/3082031.3083246.
- [68] Chuan Guo et al. ‘Countering Adversarial Images using Input Transformations’. In: *International Conference on Learning Representations (ICLR)*. Original preprint: arXiv:1711.00117. 2018. URL: <https://arxiv.org/abs/1711.00117>.